



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н. Э. Баумана (национальный
исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

Метод построения синтаксических деревьев для ограниченного естественного русского языка на основе наиболее употребимых грамматик

Группа: ИУ7-84Б
Студент: Бугаков Иван Сергеевич
Научный руководитель: Строганов Юрий Владимирович

2026 г.

Актуальность

В отечественной корпусной и прикладной лингвистике преобладающим формализмом в области синтаксического анализа являются системы зависимостей.

В недавнем времени появились работы, посвященные альтернативным формализмам и их использованию в прикладной и корпусной лингвистике, например:

- работы по созданию корпуса с синтаксической разметкой систем составляющих;
- работы по созданию корпуса с разметкой систем синтаксических групп;
- работы по созданию методов автоматического построения систем составляющих, на основе уже существующих разметок систем зависимостей.

Данные работы свидетельствуют о необходимости разработки автоматизированных методов построения систем составляющих для русского языка.

Системы составляющих в прикладной и компьютерной лингвистике позволяют решать задачи:

- генерации текстов;
- автоматического реферирования текстов;
- установления авторства текстов;
- информационного поиска;
- машинного перевода;
- семантической разметки.

Цель и задачи работы

Цель работы — разработка метода построения синтаксических деревьев для ограниченного естественного русского языка на основе наиболее употребимых грамматик.

Задачи:

- проанализировать предметную область автоматизированного построения синтаксических деревьев ограниченного естественного русского языка;
- провести сравнительный анализ существующих методов построения синтаксических деревьев и сформулировать требования к разрабатываемому методу;
- формализовать постановку задачи в виде IDEF0-диаграммы;
- разработать метод построения синтаксических деревьев ограниченного естественного русского языка;
- обосновать выбор программных средств реализации и разработать программное обеспечение реализующее описанный метод;
- определить зависимость времени построения синтаксических деревьев от количества словоформ в предложении, оценить точность и полноту разработанного метода.

Системы зависимостей


Если P — конечное линейное упорядоченное множество, то всякое дерево D , для которого P служит множеством узлов, называется **деревом синтаксического подчинения (зависимостей) на P** .

Размеченное дерево зависимостей — это упорядоченная четверка:

$$\langle P, \rightarrow, Z, \psi \rangle,$$

где

- $\langle P, \rightarrow \rangle$ — дерево зависимостей на P ;
- Z — конечное множество меток;
- ψ — разметка, отображение множества дуг дерева в Z .



Системы составляющих

Множество C отрезков конечного линейно упорядоченного множества Π называется **системой составляющих на Π** , если оно удовлетворяет следующим условиям:


- C содержит в качестве элементов само Π и все элементы Π ;
- любые два отрезка из C либо не пересекаются, либо один из них содержится в другом.

Размеченная система составляющих — упорядоченная тройка:

$$\langle C, W, \varphi \rangle,$$

где

- C — система составляющих;
- W — конечное множество меток;
- φ — отображение C в множество всех непустых подмножеств W .




Системы синтаксических групп

Пусть C — некоторое множество непустых подмножеств P . **Синтаксическими группами (СГ)** называются элементы множества C .

Системой синтаксических групп называется граф $\langle C, \rightarrow \rangle$, для которого выполняются следующие условия:

- C содержит P и все одноэлементные подмножества P ;
- если $E_1, E_2 \in C$ то либо $E_1 \cap E_2 = \varnothing$, либо $E_1 \subseteq E_2$, либо $E_2 \subseteq E_1$;
- если $E_1, E_2 \in C$, то E_1 и E_2 не зацепляются;
- если $E_1 \rightarrow E_2$, то E_1 и E_2 непосредственно вложены в одну и ту же СГ;
- СГ E не может зависеть от самой себя;
- если $E_1 \rightarrow E_2$ и $E_2 \rightarrow E_1$, то $E_1 = E_2$;
- если $E_1 \rightarrow E_2$ и E — произвольная СГ, то множества E и $E_1 \cup E_2$ не зацепляются;
- если $E_1 \rightarrow E_2$, $E_3 \rightarrow E_4$, то множества $E_1 \cup E_2$ и $E_3 \cup E_4$ не зацепляются.



Сравнение систем синтаксической разметки

	Системы зависимостей	Системы составляющих	Системы синтаксических групп
Выделение фразовых категорий	Нет	Да	Да
Поддержка непроективных предложений	Нет	Да	Да
Возможность построения нескольких деревьев разбора	Нет	Да	Да
Использование системы как порождающей грамматики	Да	Да	Нет
Общедоступные корпуса с разметкой таким видом систем	Да	Да	Нет


Алгоритмы построения систем составляющих

Алгоритм Кока–Янгера–Касами (СΥΚ)

Два этапа:

1. построение таблицы составляющих;
2. рекурсивное восстановление деревьев составляющих по полученной таблице.

Book	the	flight	through	Houston
S, VP, Verb Nominal, Noun (0,1)		S, VP, X2 (0,3)		S, VP, X2 (0,5)
	Det (1,2)	NP (1,3)		NP (1,5)
		Nominal, Noun (2,3)		Nominal (2,5)
			Prep (3,4)	PP (3,5)
				NP, Proper- Noun (4,5)



$$dp_{i,j} = dp_{i,j} \cup \{A \mid A \rightarrow BC \in P, \\ B \in dp_{i,k}, C \in dp_{k,j}\}$$

Алгоритм Эрли

Два этапа:

1. заполнение массива состояний построенных поддеревьев;
2. рекурсивное восстановление деревьев составляющих по заполненному массиву.


Три используемые операции:

- операция предсказания — добавление выводов из нетерминала в текущем состоянии;
- операция чтения терминала — увеличение длины обработанного префикса при совпадении терминала в текущем состоянии с соответствующей словоформой входного предложения;
- операция завершения разбора правила — замена разобранного в данном состоянии нетерминала на его разбор во всех других состояниях данной позиции.


Сравнение алгоритмов построения систем составляющих

Критерий	Алгоритм СΥΚ	Алгоритм Эрли
Вычислительная сложность в худшем случае	$O(n^3)$	$O(n^3)$
Требуется предварительное приведение к НФХ	Да	Нет
Максимальная длина правой части правила без преобразования	2	Не ограничена
Число параметров, определяющих разбор подотрезка предложения	2	3
Число типов операций для построения составляющей	1	3
Оценка числа состояний, худший случай	$O(n^2 N)$	$O(n^3 P)$
Оценка памяти в худшем случае	$O(n^2)$	$O(n^3)$
Построение таблицы составляющих предложения	Да	Нет
Возможность вероятностного выбора синтаксической единицы для разрешения неоднозначности разбора	Да	Да


Постановка задачи



Формальная модель метода




Алгоритм построения таблицы составляющих




Восстановление деревьев составляющих

Алгоритм восстановления деревьев составляющих





Алгоритм обработки унарных правил на отрезке длины 1





Восстановление деревьев составляющих


Алгоритм обработки бинарных правил



Алгоритм обработки унарных правил на отрезке длины больше 1



Реализация разработанной системы




Выбранные языки и технологии:

- Python — язык реализации разработанного метода и серверной составляющей web-приложения;
- PyMorphu — используемый морфологический анализатор;
- FastApi — фреймворк реализации серверной составляющей web-приложения;
- TypeScript — язык реализации клиентской составляющей web-приложения;
- React — фреймворк реализации клиентской составляющей web-приложения;
- PyTest — библиотека реализации модульного тестирования.

Покрытие строк кода по результатам модульного тестирования:

- функции построения таблицы составляющих — 97.6%;
- функций восстановления деревьев составляющих — 90.6%.

Пример работы программы



Дерево составляющих предложения: «Его тело с визгом остановилось, каблуки зависли в дюйме от бетонного пола нижнего этажа.»

Зависимость времени выполнения от числа словоформ



Аппроксимация:

$$T_{table}(n) \approx 7.85 \cdot 10^{-6} n^3 - 1.29 \cdot 10^{-4} n^2 + 1.01 \cdot 10^{-3} n - 1.56 \cdot 10^{-3}$$



Аппроксимация:

$$T_{tree}(n) \approx 4.52 \cdot 10^{-3} n^3 - 1.26 \cdot 10^{-1} n^2 + 1.42 n - 11.86$$

Точность и полнота разработанного метода

Число словоформ в исходном предложении	Число восстановленных деревьев составляющих
1	1
2	3
3	2
4	4
5	16
6	8
7	96
8	44
9	268
10	1436
11	362
12	480
13	11032
14	1600
15	8748
16	3362
17	13374
18	937755
19	157544
20	2776928

Полученные значения точности и полноты:

- точность — 0.68;
- полнота — 0.71;
- F1-мера — 0.69.

Сравнение с методами построения деревьев составляющих по готовым деревьям зависимостей:

Синтаксический анализатор	Точность	Полнота	F1-мера
Stanza	0.83	0.83	0.83
SpaCy	0.70	0.69	0.70
Разработанный метод	0.68	0.71	0.69
Natasha	0.68	0.49	0.57

Заключение

Цель работы — разработка метода построения синтаксических деревьев для ограниченного естественного русского языка на основе наиболее употребимых грамматик — была достигнута.

В ходе выполнения выпускной квалификационной работы были выполнены следующие задачи:

- проанализирована предметная область автоматизированного построения синтаксических деревьев ограниченного естественного русского языка;
- проведен сравнительный анализ существующих методов построения синтаксических деревьев и сформулированы требования к разрабатываемому методу;
- формализована постановка задачи в виде IDEF0-диаграммы;
- разработан метод построения синтаксических деревьев ограниченного естественного русского языка;
- обоснован выбор программных средств реализации и разработано программное обеспечение реализующее описанный метод;
- определена зависимость времени построения синтаксических деревьев от количества словоформ в предложении, оценена точность и полнота разработанного метода.

Дальнейшее развитие

Дальнейшее развитие может быть достигнуто за счет:

- более высокой «детализации» используемой грамматики, выделения подъединиц текущих синтаксических единиц, ввода новых правил грамматики;
- использования более подробного морфологического анализатора, охватывающего все существующие в языке части речи и их морфологические характеристики;
- внедрения возможности автоматического разрешения неоднозначности среди всех возвращаемых методом деревьев составляющих;
- оптимизации временных затрат этапа восстановления деревьев составляющих.