Е. В. Грудева

КОРПУСНАЯ ЛИНГВИСТИКА

Учебное пособие

ФЛИНТА

Е.В. Грудева

Корпусная лингвистика

Учебное пособие

2-е издание, стереотипное

Москва
Издательство «ФЛИНТА»
2012

УДК 81(075.8)
ББК 81.1
Г90

Рецензенты :
Л.Н. Чурилина, д-р филол. наук, проф. (Магнитогорский государственный университет);
Е.М. Иванова, канд. филол. наук, доцент (ГОУ ВПО ЧГУ)
Н а уч н ы й редактор : *Л.Н. Чурилина*, д-р филол. наук, проф.

Грудева Е.В.
Г90 Корпусная лингвистика [Электронный ресурс] : учеб. пособие / Е.В. Грудева. – 2-е изд., стер. – М. : ФЛИНТА, 2012. – 165 с.

ISBN 978-5-9765-1497-3

Учебное пособие «Корпусная лингвистика» адресовано студентам-бакалаврам, обучающимся по программе «Прикладная филология» в рамках направления 032700 «Филология». Издание содержит развёрнутую програм-му лекционного курса и краткие конспекты лекций, задания для самостоя-тельной работы, глоссарий, списки рекомендованной литературы, а также приложение, в которое вошли труднодоступные в силу разных причин тексты. Основная цель пособия – помочь учащимся в усвоении лекционного кур-са по корпусной лингвистике и в организации самостоятельной работы.

Пособие может оказаться полезным студентам, обучающимся по другим программам в рамках направления «Филология», а также аспирантам, препо-давателям и всем тем, кого интересуют новые технологии в работе с языковым материалом и текстами, а также в целом новые направления в современной лингвистике.

УДК 81(075.8)
ББК 81.1

© Е.В. Грудева, 20112
© Издательство «□□ И□□□ », 201

ISBN 978-5-9765-1497-3

Оглавление

Предисловие 4
Учебная программа дисциплины «Корпусная лингвистика» 9
Итоговая домашняя контрольная работа 14
Вопросы к зачёту 15
Рекомендуемая литература 16
Тематика лекционных занятий 25
Тема 1. Корпусная лингвистика: объект, предмет, метод 25
Тема 2. Корпусная лингвистика и смежные дисциплины 28
Тема 3. Корпус и Web: сходства и различия 32
Тема 4. История создания электронных языковых корпусов 34
Тема 5. Типология языковых корпусов 39
Тема 6. Национальный корпус и требования к его созданию 42
Тема 7. Метатекстовая разметка 43
Тема 8. Виды лингвистического аннотирования 47
Тема 9. Различные технологии разметки 49
Тема 10. Многокомпонентные единицы в аннотированном корпусе: корпусный и психолингвистический подходы 51
Тема 11. Морфологическое аннотирование: проблемы и решения 59
Тема 12. Семантическая разметка 60
Тема 13. Синтаксическая разметка 72
Тема 14. Словари, созданные на базе корпуса 73
Тема 15. Возможные задачи и способы их решения путем обращения к имеющимся электронным языковым ресурсам (корпусам) 76
Глоссарий 78
Приложения 82

ПРЕДИСЛОВИЕ

Главная цель дисциплины «Корпусная лингвистика» – научить специалистов в области прикладной филологии базовым технологиям работы с различными языковыми корпусами с целью быстрого получения необходимого языкового материала. Не секрет, что до сих пор многие начинающие и опытные лингвисты собирают языковой материал по старинке – путём фиксации «случайно» обнаруженного интересного факта, путём прочитывания с целью обнаружить и собрать необходимый для анализа языковой материал большого числа источников. При этом Национальный корпус русского языка, позволяющий по заданным лингвистическим – семантическим и грамматическим – параметрам в считанные минуты получить тысячи контекстов (в корпусе имеется возможность поиска и по заданной языковой единице разного формата), был открыт для широкого пользования ещё в 2004 году (адрес общедоступного бесплатного ресурса – http://www.ruscorpora.ru).

В то же время неофиты, открывшие для себя возможность использования корпуса в профессиональной деятельности, нередко преувеличивают возможности последнего. Так, корпус крайне ненадёжен в работе с малочастотными явлениями. По этой же причине к нему нужно с осторожностью прибегать при работе с лексическим материалом (в отличие от грамматики).

В настоящее время существует довольно большое число языковых корпусов, в том числе и корпусов русского языка, которые отличаются друг от друга по самым разным параметрам. Этот факт необходимо учитывать, поскольку многое в организации работы лингвиста с корпусом зависит от характеристик самого корпуса: его объёма; степени разнообразия и хронологических рамок текстов, вошедших в корпус; его соответствия критерию репрезентативности и т.п. При выборе того или иного корпуса для работы немаловажным представляется и учёт собственно лингвистического фак-

тора: кто составлял корпус и на каких лингвистических основаниях он сделан, какая из конкурирующих в лингвистике теорий положена в основу, например, морфологической или синтаксической разметки корпуса.

Наконец, для пользователя важной является информация о том, в соответствии с какими технологическими принципами выполнена разметка текстов. Так, если разметка корпуса проводится в автоматическом режиме, без так называемого «ручного» постредактирования (иначе – без снятия «вручную» оператором-лингвистом языковой омонимии в широком смысле), в корпусе заведомо будет определённое число ошибок, и пользователь должен быть заранее предупреждён об этом, чтобы выработать своё отношение к ним, чтобы правильно выстроить свои пользовательские ожидания и верно интерпретировать полученные результаты.

Есть ещё один значимый аспект проблемы, связанный с *созданием* корпуса. Многие выдающиеся лингвисты-«корпусники», занимавшиеся разработкой корпуса «с нуля» (У.Н. Фрэнсис, Дж. М. Синклер и др.), с удивлением обнаружили и громогласно заявили, что благодаря корпусу мы узнаём нечто новое о языке; мы получаем такие факты, которые никогда не смогли бы получить в докорпусную эпоху; у нас открываются новые перспективы в отношении языка. Современные авторы корпусных исследований неоднократно подтверждают данный тезис. Так, в рецензии Э. Брокхойзена (Broekhuizen 2001) на издание трудов конференции «Корпусная лингвистика и лингвистическая теория: Труды 20-й Международной конференции по исследованию английского языка с использованием компьютерных корпусов – Фрайбург-им-Брайсгау, 1999» утверждается: «Лингвистический анализ компьютеризированных текстовых корпусов, который [ещё недавно] был занятием маргинальных (и обычно именно так воспринимаемых) исследовательских групп, передвинулся [ныне] в центр исследований в области английского языка. В ходе этого процесса получены впечатляющие результаты, которые, помимо и «сверх» их интереса для англистов, вынуждают нас переосмыслить, причём кардинально и систематически, про-

блемы лингвистической теории[1]» (разрядка моя. – *Е.Г.*). Представляется, что для гуманитария-специалиста в области прикладной филологии эта составляющая корпусной лингвистики также важна.

В нашей стране на сегодняшний день известен только один учебник в области корпусной лингвистики (Гвишиани 2008), посвящённый работе с «Международным корпусом английского языка: Великобритания»; имеется также несколько кратких учебно-методических пособий по корпусной лингвистике, изданных небольшими тиражами (например, Захаров 2005; Шаламова, Фильченко 2004). Ситуация, сложившаяся за рубежом (прежде всего в Великобритании), где корпусная лингвистика достаточно давно институализирована (существуют отделения корпусной лингвистики в университетах, издаются специализированные журналы, в частности «International Journal of Corpus Linguistics», регулярно проводятся конференции, создана соответствующая международная ассоциация), принципиально иная, поскольку там уже имеется богатая учебная литература по корпусной лингвистике (см., например, Kennedy G. An Introduction to Corpus Linguistics. London, 1998; McEnery T., Wilson A. Corpus Linguistics. Edinburgh, 1997).

Сказанное позволяет рассматривать предлагаемое учебное пособие как издание, отчасти заполняющее лакуну в области литературы, обеспечивающей учебный процесс по дисциплине «Корпусная лингвистика».

Лекционный курс «Корпусная лингвистика» рассчитан на студентов бакалавриата, обучающихся по программе «Прикладная филология» в рамках специальности 032700 «Филология», он читается в пятом семестре и предполагает дополнение в шестом семестре соответствующим практикумом. Данное учебное пособие призвано обеспечить сопровождение лекционного курса.

Программа и структура курса «Корпусная лингвистика» в целом были апробированы в рамках проводимых автором учебного посо-

[1] Перевод дан по статье: Вербицкая Л.А., Казанский Н.Н., Касевич В.Б. Некоторые проблемы создания Национального корпуса русского языка // Научно-техническая информация. Сер. 2. 2003. № 6. С. 2.

бия спецкурсов и спецсеминаров по корпусной лингвистике для студентов, обучающихся по направлению 031001 – Филология по программе «Русский язык и литература». Однако переход к двухуровневой подготовке специалистов позволил существенно расширить программу курса.

Студенты, прослушавшие курс лекций «Корпусная лингвистика», должны овладеть прежде всего комплексом теоретических знаний: о предметной области «корпусная лингвистика»; о типологии языковых корпусов и истории их создания; о *национальном* корпусе и требованиях к созданию корпуса такого типа; о различных типах корпусного аннотирования – внешнего (метатекстовая разметка) и внутреннего, собственно лингвистического (акцентная, морфологическая, синтаксическая, семантическая и др. виды разметки). В ходе изучения курса у студентов должно сформироваться представление о задачах, которые можно решать с помощью языковых корпусов. Практические же навыки работы с конкретными корпусами предполагается сформировать на следующем этапе овладения курсом.

На самостоятельную работу студентов согласно требованиям к подготовке бакалавров отводится примерно такое же количество часов, что и на работу в аудитории. Этим определяется большое внимание к организации самостоятельной работы студентов, нашедшее отражение в учебном пособии: в приложение включены фрагменты работ ведущих отечественных специалистов в области корпусных исследований, которые сопровождаются системой вопросов и специальных заданий. Такое решение продиктовано стремлением активизировать процесс усвоения лекционного материала и помочь студентам в организации процесса подготовки к итоговой аттестации.

Композиция учебного пособия определена поставленными целями, оно состоит из трех частей.

1. Первую часть составляет развёрнутая **Программа курса**, включающая списки рекомендуемой учебной и научной литературы (основной и дополнительной).

2. Во вторую часть – **Тематика лекционных занятий** – включены учебно-методические материалы для подготовки к лекционным занятиям и задания для самостоятельной работы.

3. В **Приложение** включены фрагменты наиболее значимых теоретических научных работ, в силу тех или иных причин малодоступных студентам.

Кроме того, в пособии представлен **Глоссарий**, так называемый терминологический минимум, в котором студенты найдут толкование основных терминов, без знания которых невозможно осмысленно читать учебную и научную литературу по дисциплине.

В заключение отметим, что корпусная лингвистика по сути своей является междисциплинарной областью исследования. Прежде всего здесь осуществляется связь между информационными, компьютерными технологиями и собственно лингвистикой. Создание национального корпуса предполагает проведение глубокой филологической, текстологической экспертизы текстов. Здесь лингвистика традиционно смыкается с литературоведением и текстологией. Таким образом, предлагаемое учебное пособие может оказаться полезным и для специалистов широкого круга, в той или иной степени связанных с исследованием текста. Сведения о языке, речи, тексте и коммуникации, полученные в ходе изучения традиционных дисциплин гуманитарного цикла, могут быть существенно дополнены благодаря использованию новых технологий получения и обработки информации.

УЧЕБНАЯ ПРОГРАММА ДИСЦИПЛИНЫ «КОРПУСНАЯ ЛИНГВИСТИКА»

Смежные дисциплины по учебному плану

Введение в языкознание. Прикладная филология (теория и методика). Современная лингвистическая парадигма. Русский язык (теоретический курс). Информационная эвристика (компьютерные технологии в филологии). Практикум по корпусной лингвистике (компьютерные технологии в филологии).

Количество часов на дисциплину: 4 единицы (144 часа).

Количество аудиторных часов на дисциплину: 2 единицы (72 часа), из них лекционные – 2 единицы (72 часа).

Количество внеаудиторных часов на дисциплину: 2 единицы (72 часа).

Форма аттестации: зачёт.

Цели дисциплины:

– сформировать в сознании специалистов гуманитарного профиля необходимые для научной и педагогической деятельности базовые представления о корпусной лингвистике;

– представить полученные ранее знания о языке, речи, тексте и коммуникации с точки зрения корпусной лингвистики;

– привить осознанные навыки пользования корпусами русского языка;

– освоить новейшие технологии быстрого получения необходимого языкового материала при учёте правильного формирования пользовательского запроса.

Задачи дисциплины

Формирование у гуманитариев-специалистов в сфере прикладной филологии научной и коммуникативной компетенции в области корпусной лингвистики, которая предполагает:

– представление об основных типах корпусов и методах их создания;

– овладение специальной терминологией, базовым понятийным аппаратом и основными технологиями работы с корпусом;

– знание истории зарождения и развития корпусной лингвистики;

– представление о различных видах информации, которую можно извлечь из языковых корпусов;

– умение сопоставить различные корпусы с точки зрения базовых требований, предъявляемых к созданию языковых корпусов;

– умение выбирать тот или иной электронный ресурс (корпус) для решения конкретной задачи;

– использование полученных знаний в профессиональной филологической деятельности.

Тематическое распределение лекций

Наименование разделов и тем	Количество часов	
	Всего	Лекционные
1. Корпусная лингвистика: объект, предмет, метод	4	4
2. Корпусная лингвистика и смежные дисциплины	4	4
3. Корпус и Web: сходства и различия	4	4
4. История создания электронных языковых корпусов	6	6
5. Типология языковых корпусов	6	6
6. Национальный корпус и требования к его созданию	4	4
7. Метатекстовая разметка	4	4
8. Виды лингвистического аннотирования	6	6
9. Различные технологии разметки	4	4
10. Многокомпонентные единицы в аннотированном корпусе: корпусный и психолингвистический подходы	6	6
11. Морфологическое аннотирование: проблемы и решения	6	6
12. Семантическая разметка	4	4
13. Синтаксическая разметка	4	4
14. Словари, созданные на базе корпуса	6	6
15. Возможные задачи и способы их решения путем обращения к имеющимся электронным языковым ресурсам (корпусам)	4	4

Основные темы и краткое их содержание

Корпусная лингвистика: объект, предмет, метод. Цели и задачи корпусной лингвистики. Лингвистический корпус (корпус текстов). Формирование корпуса текстов. Программное обеспечение: корпус-менеджер. Круг потенциальных пользователей лингвистических корпусов. Получение конкордансов и словников. Корпус данных.

Корпусная лингвистика и смежные дисциплины. Корпусная лингвистика и традиционная лингвистика. Корпусная лингвистика и компьютерная лингвистика. Корпусная лингвистика и психолингвистика.

Корпус и Web: сходства и различия. Корпус как репрезентативная выборка текстов. Web как несбалансированный набор текстов. Возможности Web'а в лингвистических исследованиях.

История создания электронных языковых корпусов. Брауновский корпус: авторы, объём, принципы отбора материала. Ланкастерско-Осло-Бергенский корпус (LOB). Лондонско-Лундский корпус. Бирмингемский корпус. Британский национальный корпус. Упсальский корпус русского языка. Машинный фонд русского языка. Национальный корпус русского языка. Корпус русского литературного языка. Компьютерный корпус газетных текстов русского языка конца XX века. Хельсинкский аннотированный корпус русского языка. Фундаментальные корпусы других славянских языков: Чешский национальный корпус, Словацкий национальный корпус, Хорватский национальный корпус.

Типология языковых корпусов. Корпус языка в целом (фундаментальный корпус). Корпус подъязыка. Исследовательские и иллюстративные корпусы. Динамические и статические корпусы текстов. Моноязычные корпусы. Корпусы параллельных текстов. Диахронические корпусы.

Национальный корпус и требования к его созданию. Понятие «национальный» в терминологическом словосочетании «национальный корпус». Размер корпуса. Хронологический охват языка. Репрезентативность (представительность) корпуса. Филологическая экспертиза текстов. Типы аннотирования в национальном корпусе.

Многофункциональность национального корпуса. Общедоступность.

Метатекстовая разметка. Метаразметка как часть поискового аппарата корпуса. Классификация текстов для создания представительных корпусов. Стандарт EAGLES. Классификация текстов Синклера – Шарова.

Виды лингвистического аннотирования. Понятие лингвистического аннотирования (разметки). Акцентная разметка. Морфологическая разметка. Синтаксическая разметка. Семантическая разметка. Фонетическая разметка. Метрическая разметка поэтических текстов. Выравнивание в параллельных корпусах.

Различные технологии разметки. Автоматическая, полуавтоматическая, ручная разметка. Языковые препятствия, возникающие на пути автоматической разметки: многозначность и омонимия, идиомы, «составные слова».

Многокомпонентные единицы в аннотированном корпусе: корпусный и психолингвистический подходы. Понятие многокомпонентной единицы. Идиоматические сочетания: проблемы аннотирования. «Составные слова», или «эквиваленты слова»: проблемы аннотирования и результаты поиска. Аналитические формы: проблемы аннотирования и результаты поиска. Корпусный и психолингвистический подходы к аннотированию многокомпонентных единиц: возможное соотношение теоретических и технологических решений.

Морфологическое аннотирование: проблемы и решения. Понятие морфологического стандарта. Морфологический стандарт в Национальном корпусе русского языка.

Семантическая разметка. Семантическая разметка: принципы и основания. Связь семантической разметки с разметкой синтаксической и морфологической. Принципы семантической разметки в Национальном корпусе русского языка.

Синтаксическая разметка. Виды синтаксической разметки. Связь синтаксической разметки с разметкой морфологической. Принципы синтаксической разметки Национального корпуса русского языка. Принципы синтаксической разметки Хельсинкского аннотированного корпуса русского языка (ХАНКО). Проблема синтаксических нулей.

Словари, созданные на базе корпуса. Традиционные словари, созданные на базе корпуса. Электронные словари, созданные на базе корпуса. Частотные словари разного типа: с входной единицей – лексемой, с входной единицей – словоформой. Словарь омографов русского языка. Частотный словарь словоформ русского языка. Электронные словари, созданные на базе Национального корпуса русского языка.

Возможные задачи и способы их решения путем обращения к имеющимся электронным языковым ресурсам (корпусам).

Использование корпусных методов в лингвистике. Применение корпуса в филологических и текстологических исследованиях. Корпусная лингвистика и социолингвистические изыскания. Использование корпусов в практике преподавания языка. Корпус и судебно-лингвистическая экспертиза.

Основные понятия

Корпусная лингвистика, корпус, корпус-менеджер, лингвистическое аннотирование, парсер, репрезентативность, национальный корпус, параллельный корпус, исторический корпус, корпус разговорного языка, звучащий корпус, поэтический корпус, диалектный корпус, акцентуированный корпус, Web как корпус, лемматизация, тэггирование, метатекстовая разметка, морфологическая разметка, синтаксическое выравнивание, автоматическая разметка, полуавтоматическая разметка, электронные словари.

Организация самостоятельной работы

Самостоятельная работа студентов предполагает:

– изучение и обязательное конспектирование базовой научной литературы по проблемам корпусной лингвистики;

– работу с фрагментами научных работ, помещенными в приложении к данному учебному пособию, с целью выполнения заданий для самостоятельной работы;

– выполнение контрольной работы по теме «Морфологическая разметка: проблемы и решения»;

– подготовку к терминологическому диктанту по теме «Корпусная лингвистика».

ИТОГОВАЯ ДОМАШНЯЯ КОНТРОЛЬНАЯ РАБОТА

1. Ознакомьтесь с принципами морфологической разметки в трёх корпусах русского языка: Национальном корпусе русского языка (www.ruscorpora.ru), Корпусе русского литературного языка (www.narusco.ru) и Хельсинкском аннотированном корпусе (http://www.helsinki.fi/venaja/russian/e-material/hanco/index.htm). Сопоставьте эти принципы. Обратите внимание на их сходства и различия, а также на соответствие принятых принципов традиционным лингвистическим теориям. Попытайтесь понять, чем обусловлены отклонения от традиционных решений.

2. Разметьте все словоформы в высказывании «*Когда видишь её, кажется, нет на свете человека красивее и милее*» (И. Грекова. «Под фонарем»), пользуясь системой разметки в трёх вышеназванных корпусах (таким образом, итоговый ответ должен содержать указание всех отличительных нюансов в данных системах).

ВОПРОСЫ К ЗАЧЁТУ

1. Корпусная лингвистика: проблема объекта и предмета исследования.
2. Корпусная лингвистика и традиционная лингвистика.
3. Корпусная лингвистика и психолингвистика.
4. История лингвистических корпусов: от картотеки к корпусу.
5. Корпус и база данных: сходства и различия.
6. Корпус и Web: сходства и различия.
7. Типология корпусов: принципы классификации.
8. Корпусы русского языка: сходства и отличия.
9. Корпусная лингвистика в России.
10. Национальный корпус языка и требования к его созданию.
11. Автоматическая, ручная и полуавтоматическая технология разметки корпуса: достоинства и недостатки.
12. Корпус параллельных текстов: проблема выравнивания.
13. Метатекстовая разметка: возможные подходы.
14. Виды лингвистического аннотирования.
15. Понятие морфологического стандарта.
16. Многокомпонентные единицы: проблемы разметки.
17. Синтаксическая разметка: возможные подходы и решения.
18. Возможности семантической разметки.
19. Семантическая разметка в Национальном корпусе русского языка.
20. Словари, созданные на базе корпуса.
21. Лингвистические исследования, базирующиеся на корпусах.
22. Возможные нелингвистические задачи и способы их решения путём обращения к языковым корпусам.

РЕКОМЕНДУЕМАЯ ЛИТЕРАТУРА

Основная

1. *Андрющенко В.М.* Концепция и архитектура машинного фонда русского языка / Отв. ред. А.П. Ершов. М., 1989.

2. *Апресян Ю.Д., Богуславский И.М., Иомдин Б.Л.* и др. Синтаксически и семантически аннотированный корпус русского языка: современное состояние и перспективы // Национальный корпус русского языка: 2003 – 2005. М.: Индрик, 2005.

3. *Баранов А.Н.* Корпусная лингвистика // Баранов А.Н. Введение в прикладную лингвистику. М., 2001. С. 112 – 137.

4. *Богуславский И.М.* и др. Аннотированный корпус русских текстов: Концепция, инструменты разметки, типы информации // Труды Международного семинара по компьютерной лингвистике и ее приложениям «Диалог-2000». Протвино, 2000.

5. *Венцов А.В., Грудева Е.В.* Акцентно размеченный Корпус русского литературного языка как источник новых словарей («Словарь омографов русского языка» и «Частотный словарь словоформ русского языка») // Проблемы истории, филологии, культуры. 2009. Т. 24. № 2. С. 631 – 635.

6. *Венцов А.В., Грудева Е.В., Касевич В.Б., Ягунова Е.В.* Национальный корпус русского литературного языка: некоторые результаты, приложения и задачи // Научно-техническая информация. Сер. 2. 2005. № 6. С. 35 – 40.

7. *Вербицкая Л.А., Казанский Н.Н., Касевич В.Б.* Некоторые проблемы создания Национального корпуса русского языка // Научно-техническая информация. Сер. 2. 2003. № 6. С. 2 – 8.

8. *Добровольский Д.О.* Корпус параллельных текстов в исследовании культурно-специфичной лексики // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 383 – 400.

9. *Захаров В.П.* Веб-пространство как языковой корпус // Компьютерная лингвистика и интеллектуальные технологии: Труды Международной конференции «Диалог'2005» (Звенигород, 1 – 6 июня, 2005 г.) / Под ред. И.М. Кобозевой, А.С. Нариньяни, В.П. Селегея. М.: Наука, 2005.

10. *Захаров В.П.* Корпусная лингвистика: Учеб.-метод. пособие. СПб., 2005. 48 с.

11. *Захаров В.П.* Чешский национальный корпус текстов: организация и способы использования // Доклады научной конференции «Корпусная лингвистика и лингвистические базы данных» / Под ред. А.С. Герда. СПб., 2002. С. 72 – 79.

12. *Касевич В.Б., Ягунова Е.В.* Корпус русского языка и восприятие речи // Научно-техническая информация. Сер. 2. 2003. № 6. С. 25 – 32.

13. *Копотев М.В., Мустайоки А.* Современная корпусная русистика // Slavica Helsingiensia 34. Инструментарий русистики: корпусные подходы / Под ред. А. Мустайоки, М.В. Копотева, Л.А. Бирюлина, Е.Ю. Протасовой. Хельсинки, 2008.

14. *Копотев М.В., Янда Л.* Национальный корпус русского языка (www.ruscorpora.ru) (*рец.*) // Вопросы языкознания. 2006. № 5. С. 149 – 155.

15. *Копотев М.В., Мустайоки А.* Принципы создания Хельсинкского аннотированного корпуса русских текстов (ХАНКО) в сети Интернет // Научно-техническая информация. Сер. 2. 2003. № 6. С. 33 – 36.

16. *Копотев М.В.* Между Сциллой языкознания и Харибдой языка: о русскоязычных корпусах текстов // Компьютерная лингвистика и интеллектуальные технологии: Труды Международной конференции «Диалог'2005» (Звенигород, 1 – 6 июня, 2005 г.) / Под ред. И.М. Кобозевой, А.С. Нариньяни, В.П. Селегея. М.: Наука, 2005.

17. Корпусные исследования по русской грамматике: Сб. статей. М., 2009.

18. *Кустова Г.И., Ляшевская О.Н., Падучева Е.В., Рахилина Е.В.* Опыт семантического расширения морфологической разметки: таксономическая классификация лексики в Национальном корпусе русского языка // Научная и техническая информация. Сер. 2. Информационные процессы и системы. 2005. № 6.

19. *Леонтьева Н.Н.* Корпусная лингвистика и системы автоматического понимания текста // Московский лингвистический журнал. 2004. Т. 9. № 1. С. 5 – 15.

20. *Ляшевская О.Н., Плунгян В.А., Сичинава Д.В.* О морфологическом стандарте Национального корпуса русского языка // Национальный корпус русского языка: 2003 – 2005. Результаты и перспективы. М., 2005. С. 111 – 135.

21. Научно-техническая информация. Сер. 2. 2003. № 6. Тематический выпуск «Корпусная лингвистика в России».

22. Научно-техническая информация. Сер. 2. 2005. № 3. Тематический выпуск «Корпусная лингвистика: Национальный корпус русского языка».

23. Национальный корпус русского языка: 2003 – 2005. М.: Индрик, 2005.

24. Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009.

25. *Плунгян В.А.* Корпус как инструмент и как идеология // Национальный корпус русского языка и проблемы гуманитарного образования. Материалы Международной научной конференции (Москва, 19 – 20 апреля 2007 г.). М., 2007. С. 64 – 66.

26. *Плунгян В.А.* Зачем нужен Национальный корпус русского языка? Неформальное введение // Национальный корпус русского языка: 2003 – 2005. М.: Индрик, 2005. С. 6 – 20.

27. *Резникова Т.И.* Славянская корпусная лингвистика: современное состояние ресурсов // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы. СПб.: Нестор-История, 2009. С. 402 – 461.

28. *Резникова Т.И., Копотев М.В.* Лингвистически аннотированные корпуса русского языка (обзор общедоступных ресурсов) // Национальный корпус русского языка: 2003 – 2005. Результаты и перспективы. М., 2005. С. 31 – 61.

29. *Савчук С.О.* Метатекстовая разметка в Национальном корпусе русского языка: базовые принципы и основные функции // Национальный корпус русского языка: 2003 – 2005. Результаты и перспективы. М., 2005. С. 62 – 88. URL: http://ruscorpora.ru/sbornik2005/05savchuk.pdf

30. *Савчук С.О., Сичинава Д.В.* Обучающий корпус русского языка и его использование в преподавательской практике // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 317 – 334.

31. *Фрэнсис У.Н.* Проблемы формирования и машинного представления большого корпуса текстов // Новое в зарубежной лингвистике. Вып. XIV. Проблемы и методы лексикографии. М.: Прогресс, 1983. С. 334 – 352.

32. *Чардин И.С.* Лингвистические корпуса с синтаксической разметкой и их применение // Научно-техническая информация. Сер. 2. 2003. № 6. С. 18 – 24.

33. *Шаров С.А.* Представительный корпус русского языка в контексте мирового опыта // Научно-техническая информация. Сер. 2. 2003. № 6. С. 9 – 17.

Дополнительная

1. *Баскулина Ю.Н.* Идиоматические сочетания в русском языке: теоретические и прикладные аспекты (на материале Национального корпуса русского литературного языка): Автореф. дис. … канд. филол. наук. СПб., 2008.

2. *Баскулина Ю.Н.* Составные слова и их представление в аннотированных корпусах русского языка // Материалы Всероссийской научной конференции с международным участием «Актуальные проблемы теоретической и прикладной лингвистики и оптимизации преподавания иностранных языков» (Тольятти, октябрь 2005 г.). Тольятти, 2005. С. 61 – 66.

3. *Баскулина Ю.Н., Грудева Е.В.* Составные слова в русском языке и возможные подходы к их изучению // Вестник Череповецкого государственного университета. 2006. № 1. С. 75 – 78.

4. *Венцов А.В.* «Составные слова» и перцептивный словарь // Череповецкие научные чтения – 2009: Материалы Всероссийской научно-практической конференции, посвященной Дню города Череповца (2 – 3 ноября 2009 г.) / Ч. 1. Литературоведческие и лингвистические науки в начале XXI в. Череповец: ГОУ ВПО ЧГУ, 2010. С. 44 – 46.

5. *Венцов А.В., Грудева Е.В.* Аналитические формы в Национальном корпусе русского литературного языка // Труды Международной конференции «Корпусная лингвистика – 2006» (10 – 14 октября 2006 г., Санкт-Петербург). СПб., 2006. С. 75 – 80.

6. *Венцов А.В., Грудева Е.В.* К вопросу о создании частотного словаря словоформ русского языка // Русская языковая личность: Материалы шестой выездной школы-семинара. Череповец: ГОУ ВПО ЧГУ, 2007. С. 70 – 80.

7. *Венцов А.В., Касевич В.Б., Сведенцова Е.А.* Омография, омофония и восприятие речи // Человек пишущий и читающий: проблемы и наблюдения: Материалы Междунар. конф. (14 – 16 марта 2002 г., С.-Петербург). СПб.: Изд-во С.-Петербург. ун-та, 2004. С. 182 – 189.

8. *Венцов А.В., Грудева Е.В., Касевич В.Б.* Морфологическая проблематика в Национальном корпусе русского литературного языка // Международная конференция «Корпусная лингвистика – 2004»: Тезисы докладов (12 – 14 октября 2004 г., С.-Петербург). СПб.: СПбГУ, 2004. С. 18 – 20.

9. *Венцов А.В., Грудева Е.В., Касевич В.Б., Ягунова Е.В.* Идиомы в Национальном корпусе русского литературного языка // Международная конференция «Корпусная лингвистика – 2004»: Тезисы докладов (12 – 14 октября 2004 г., С.-Петербург). СПб.: СПбГУ, 2004. С. 17 – 18.

10. *Венцов А.В., Касевич В.Б., Ягунова Е.В.* Идиома, слово, фонетическое слово // Язык и речь: проблемы и решения: Сб. науч. трудов к юбилею проф. Л. В. Златоустовой / Под ред. Г.Е. Кедровой и В.В. Потапова. М.: МАКС Пресс, 2004. С. 357 – 363.

11. *Венцов А.В., Касевич В.Б., Ягунова Е.В.* Об идиомах в Национальном корпусе русского языка // Научные чтения – 2003 (Санкт-Петербург, 15 – 17 декабря 2003 г.): Материалы конференции. Приложение к журналу «Язык и речевая деятельность». Т. 5. СПб., 2004. С. 8 – 11.

12. Доклады научной конференции «Корпусная лингвистика и лингвистические базы данных» / Под ред. А.С. Герда. СПб., 2002.

13. *Копотев М.В., Мустайоки А.* К вопросу о статусе эквивалентов слова типа ПОТОМУ ЧТО, В ЗАВИСИМОСТИ ОТ, К СОЖАЛЕНИЮ // Вопросы языкознания. 2004. № 3. С. 88 – 107.

14. *Копотев М.В.* «Несмотря на» «потому что», или Многокомпонентные единицы в аннотированном корпусе русских текстов // Компьютерная лингвистика и интеллектуальные технологии: Труды Междунар. конференции «Диалог-2004» («Верхневолжский», 2 – 7 июня 2004 г.) / Под ред. И.М. Кобозевой и др. М., 2004. С. 335 – 339. URL: http://www.dialog-21.ru/Archive/2004/Kopotev.htm

15. *Венцов А.В., Грудева Е.В., Касевич В.Б., Сведенцова Е.А., Слепокурова Н.А.* О морфологии в Национальном корпусе русского языка // Материалы XXXIII Международной филологической конференции (15 – 20 марта 2004 г., Санкт-Петербург). Вып. 24. Секция общего языкознания. Ч. 2. СПб.: ОНУТ Филол. ф-та СПбГУ, 2004. С. 3 – 8.

16. *Венцов А.В., Касевич В.Б., Ягунова Е.В.* Корпус русского языка и восприятие речи // Научно-техническая информация. Сер. 2. 2003. № 6. С. 25 – 32.

17. *Венцов А.В., Касевич В.Б., Ягунова Е.В.* Корпус русских текстов и модель восприятия речи // III Всероссийская конференция «Теория и практика речевых исследований» (АРСО-2003). 8 – 10 сентября 2003 года, Москва, МГУ им. М. Ломоносова. М.: Филол. ф-т МГУ, 2003. С. 21 – 26.

18. *Венцов А.В., Касевич В.Б., Ягунова Е.В.* Национальный корпус русского литературного языка и разработка модели восприятия речи // Международная конференция «Корпусная лингвистика – 2004»: Тезисы докладов (12 – 14 октября 2004 г., С.-Петербург). СПб.: Изд-во Санкт-Петербург. ун-та, 2004. С. 20 – 21.

19. *Волков С.Св., Захаров В.П.* Параметры описания текстов для корпуса русского языка XIX века // Международная конференция «Корпусная лингвистика – 2004»: Тезисы докладов (12 – 14 октября 2004 г., С.-Петербург). СПб.: СПбГУ, 2004. С. 23 – 25.

20. *Гвишиани Н.Б.* Практикум по корпусной лингвистике = English on Computer. A Tutorial in Corpus Linguistics: Учеб. пособие по английскому языку. М.: Высшая школа, 2008.

21. *Гришина Е.А., Корчагин К.М., Плунгян В.А., Сичинава Д.В.* Поэтический корпус в рамках НКРЯ: общая структура и перспективы использования // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 71 – 113.

22. *Гришина Е.А., Савчук С.О.* Корпус устных текстов в НКРЯ: состав и структура // Национальный корпус русского языка: 2006–2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 129 – 148.

23. *Добрушина Н.Р.* Корпусные методики обучения русскому языку // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 335 – 351.

24. *Копотев М.В.* Корпусная лингвистика в Финляндии (обзор ресурсов) // Научно-техническая информация. Сер. 2. 2003. № 6. С. 37 – 41.

25. *Копотев М.В., Гурин Г.Б.* Принципы синтаксической разметки Хельсинкского аннотированного корпуса русских текстов ХАНКО // Компьютерная лингвистика и интеллектуальные технологии: Труды Международной конференции «Диалог-2006». М.: РГГУ, 2006. С. 280 – 284.

26. *Копотев М.В., Гурин Г.Б.* Разметка синтаксической неполноты в корпусе // Компьютерная лингвистика и интеллектуальные технологии: Труды Международной конференции «Диалог-2007». М.: РГГУ, 2007. С. 307 – 309.

27. *Копотев М.В., Гурин Г.Б.* Принеси то, не знаю что: представление и поиск синтаксических нулевых знаков и смежных явлений в аннотированном корпусе // Труды Международной конференции «Корпусная лингвистика – 2006». СПб.: СПГУ, 2006. С. 166 – 173.

28. *Кретов А.А.* Анализ семантических помет в НКРЯ // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы. СПб.: Нестор-История, 2009. С. 240 – 257.

29. *Кронгауз М.А.* Методы семантики // Кронгауз М.А. Семантика. М., 2001. С. 92 – 103.

30. *Кустова Г.И., Ляшевская О.Н., Падучева Е.В., Рахилина Е.В.* Национальный корпус русского языка как инструмент семантико-грамматического исследования лексики // Международная конференция «Корпусная лингвистика – 2004»: Тезисы докладов. СПб.: СПбГУ, 2004. С. 50 – 51.

31. *Кустова Г.И., Толдова С.Ю.* НКРЯ: семантические фильтры для разрешения многозначности глаголов // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 258 – 275.

32. *Леонтьева Н.Н.* Автоматическое понимание текстов: системы, модели, ресурсы: Учеб. пособие. М.: Академия, 2006.

33. *Леонтьева Н.Н.* Роль связей в семантической разметке корпуса текстов // Труды Международной конференции «Корпусная лингвистика – 2004». СПб.: СПбГУ, 2004. С. 196 – 205.

34. *Летучий А.Б.* Диалектный корпус: состав и особенности разметки // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 114 – 128.

35. *Ляшевская О.Н.* О частотном словаре Национального корпуса русского языка // Слово и словарь = Vocabulum et vocabularium: Сб. науч. тр. по лексикографии. Гродно: ГрГУ, 2007.

36. *Ляшевская О.Н., Шаров С.А.* Частотный словарь Национального корпуса русского языка: концепция и технология создания // Компьютерная лингвистика и интеллектуальные технологии: По материалам ежегодной Международной конференции «Диалог» (Бекасово, 4 – 8 июня 2008 г.). Вып. 7 (14). М.: РГГУ, 2008. С. 345 – 351.

37. *Недолужко А., Гаич Я.* и др. Синтаксически аннотированный корпус чешского языка // Компьютерная лингвистика и интеллектуальные технологии: По материалам ежегодной Международной конференции «Диалог» (Бекасово, 4 – 8 июня 2008 г.). Вып. 7 (14). М.: РГГУ, 2008. С. 400 – 406.

38. *Перцов Н.В.* О роли корпусов в лингвистических исследованиях // Труды Международной конференции «Корпусная лингвистика – 2006» (Санкт-Петербург, 10 – 14 октября 2006 г.). СПб., 2006. С. 318 – 331.

39. *Пильщиков И.А., Старостин А.С.* Основные проблемы автоматизации базовых процедур ритмико-синтаксического анализа силлабо-тонических текстов // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 298 – 315.

40. *Плунгян В.А.* Зачем мы делаем Национальный корпус русского языка? // Отечественные записки: Журнал для медленного чтения. 2005. № 2. URL: http://www.strana-oz.ru/?article=1051&numid=23

41. *Рыков В.В.* Прагматически ориентированный корпус текстов // Тверской лингвистический меридиан. Вып. 3. Тверь, 1999. С. 89 – 96. URL: http://rykov-cl.narod.ru/t.html

42. Труды Международного семинара по компьютерной лингвистике и ее приложениям «Диалог-2000», «Диалог-2001», «Диалог-2002», «Диалог-2003», «Диалог-2004», «Диалог-2005», «Диалог-2006», «Диалог-2007», «Диалог-2008», «Диалог-2009», «Диалог-2010».

43. Труды Международной научной конференции «Корпусная лингвистика – 2004» / Под ред. А.С. Герда. СПб., 2004.

44. Труды Международной конференции «Корпусная лингвистика – 2006». СПб., 2006.

45. Труды Международной конференции «MEGALING'2005. Прикладная лингвистика в поиске новых путей». СПб.: Изд-во «Осипов», 2005.

46. *Шаламова Н.Н., Фильченко А.Ю.* Корпусная лингвистика и её использование в профильно-ориентированном преподавании иностранных языков. Томск: ТПУ, 2004.

47. *Шаров С.А.* Формат выходного представления корпуса текстов. URL: http://bokrcorpora.narod.ru/format.html

48. *Шаров С.А.* Централизованное планирование vs. стихия рынка: сравнение лексического и жанрового разнообразия в Национальном корпусе рус-

ского языка и Интернете // Компьютерная лингвистика и интеллектуальные технологии: Труды Международной конференции «Диалог-2007» (Бекасово, 30 мая – 3 июня 2007 г.) / Под ред. Л.Л. Иомдина, Н.И. Лауфер, А.С. Нариньяни, В.П. Селегея. М.: Изд-во РГГУ, 2007. С. 573 – 581.

49. *Broekhuizen E., van.* [Rec. ad op.:] Mair Ch. & M. Hundt (eds.) Corpus Linguistics and Linguistic Theory. Papers from the Twentieth International Conference on English Language Research on Computerized Corpora (ICAME 20). Amsterdam; Atlanta, 1999 // LINGUIST List. 2001. Vol. 12 – 272.

50. *Fillmore Ch.J.* «Corpus Linguistics» or «Computer-aided armchair linguistics» // Directions in Corpus Linguistics. Berlin; N.-Y., 1992. P. 35 – 60.

51. *Kennedy G.* An Introduction to Corpus Linguistics. London, 1998.

52. *McEnery T., Wilson A.* Corpus Linguistics. Edinburgh, 1997.

Словари

1. Англо-русский словарь по лингвистике и семиотике. Около 9000 терминов. Изд. 2-е, испр. и доп. / А.Н. Баранов, Д.О. Добровольский, М.Н. Михайлов и др.; Под ред. А.Н. Баранова и Д.О. Добровольского. М.: Азбуковник, 2001.

2. *Венцов А.В., Грудева Е.В.* Частотный словарь словоформ русского языка (проект). Череповец: Изд-во ЧГУ, 2008. 204 с. URL: http://www.-narusco.ru/STAT004/

3. *Венцов А.В., Грудева Е.В., Касевич В.Б.,* Словарь омографов русского языка / Ред. А.В. Венцов, В.Б. Касевич. СПб.: Филол. ф-т СПбГУ, 2004.

4. *Засорина Л.Н.* (ред.). Частотный словарь русского языка. М., 1977.

5. *Лённгрен Л.* (ред.). Частотный словарь современного русского языка. Uppsala, 1993.

6. *Штейнфельдт Э.А.* Частотный словарь современного русского литературного языка. Таллин, 1963.

7. *Baker P.* A Glossary of Corpus Linguistics / P. Baker, A. Hardie, T. McEnery. Edinburg: Edinburg University Press Ltd, 2006.

Электронные словари, созданные на базе Национального корпуса русского языка (www.ruscorpora.ru)

1. *Гришина Е.А., Ляшевская О.Н.* Грамматический словарь новых слов русского языка. URL: http://dict.ruslang.ru/gram.php

2. *Ляшевская О.Н., Шаров С.А.* Новый частотный словарь русской лексики. URL: http://dict.ruslang.ru/freq.php

3. *Кустова Г.И.* Словарь русской идиоматики. Сочетания слов со значением высокой степени. URL: http://dict.ruslang.ru/magn.php

4. *Бирюк О.Л., Гусев В.Ю., Калинина Е.Ю.* Словарь глагольной сочетаемости непредметных имён русского языка. URL: http://dict.ruslang.ru/abstr_noun.php

Интернет-ресурсы

1. Национальный корпус русского языка. URL: http://www.ruscorpora.ru
2. Корпус русского литературного языка. URL: http://www.narusco.ru
3. Корпусная лингвистика. URL: http://ru.wikipedia.org
4. Сайт, посвящённый семинару по корпусной лингвистике в Институте лингвистических исследований РАН. URL: http://corpora.iling.spb.ru/
5. Форум, посвящённый корпусной лингвистике, на сайте «Диалог». URL: http://www.dialog-21.ru/forum/actualtopics.aspx?bid=2
6. Персональный сайт В.В. Рыкова, посвящённый корпусной лингвистике. URL: http://rykov-cl.narod.ru/
7. Видеолекция В.А. Плунгяна «Почему современная лингвистика должна быть лингвистикой корпусов». URL: http://www.polit.ru/lectures/2009/10/23/corpus.html
8. Презентация доклада М.В. Копотева «Синтаксическая разметка в ХАНКО: проблемы и достижения». URL: http://corpora.iling.spb.ru/seminar.htm/kopotev_syntax
9. *Шаров С.А.* Параметры описания текстов корпуса. URL: http: // bokrcorpora.narod.ru/header.html.
10. *Рыков В.В.* Корпусная лингвистика и лексикография – проблема репрезентативности. URL: http://rykov-cl.narod.ru/t32.html
11. *Чардин И.С.* Лингвистические корпуса с синтаксической разметкой и их применение. URL: http://www.viniti.ru/cgi-bin/nti/nti.pl?action=show&year=2_2003&issue=6&page=18
12. *Захаров В.П., Коваль С.А.* Корпусная лингвистика и лингвистические базы данных. URL: http://www.viniti.ru/cgi-bin/nti/nti.pl?action=show&year=2_2002&issue=7&page=24

ТЕМАТИКА ЛЕКЦИОННЫХ ЗАНЯТИЙ

Тема 1

КОРПУСНАЯ ЛИНГВИСТИКА: ОБЪЕКТ, ПРЕДМЕТ, МЕТОД

(4 часа)

Цели и задачи корпусной лингвистики. Лингвистический корпус (корпус текстов). Формирование корпуса текстов. Программное обеспечение: корпус-менеджер. Круг потенциальных пользователей лингвистических корпусов. Получение конкордансов и словников. Корпус данных.

Корпусная лингвистика – раздел прикладной лингвистики, связанный с разработкой общих принципов построения и использования лингвистических корпусов (корпусов текстов) с использованием компьютерных технологий.

Предмет корпусной лингвистики – теоретические основы и практические механизмы создания и использования представительных массивов языковых данных, предназначенных для лингвистических исследований в интересах широкого круга пользователей.

Корпус текстов – вид корпуса данных, единицами которого являются тексты или их достаточно значительные фрагменты, включающие, например, какие-то полные фрагменты макроструктуры текстов определённой проблемной области.

Конкорданс – список всех употреблений данного слова в контексте со ссылками на источник.

Корпус-менеджер (англ. corpus manager) – специализированная поисковая система, включающая программные средства для поиска данных в корпусе, получения статистической информации и предоставления результатов пользователю в удобной форме.

Предпосылки создания и использования корпусов

(*по: Захаров 2005*)

1. Достаточно большой (репрезентативный) объем корпуса гарантирует типичность данных и обеспечивает полноту представления всего спектра языковых явлений.

2. Данные разного типа находятся в корпусе в своей естественной контекстной форме, что создает возможность их всестороннего и объективного изучения.

3. Однажды созданный и подготовленный массив данных может использоваться многократно, многими исследователями и в различных целях.

Требования к формированию корпуса текстов

1. *Репрезентативность* (необходимо-достаточное и пропорциональное представление в корпусе текстов различных периодов, жанров, стилей, авторов и т.п.).

2. *Электронный формат*.

3. *Аннотирование*, или *разметка* (в зависимости от типа корпуса и исследовательских задач корпус может содержать метаразметку, структурную разметку и собственно лингвистическую – акцентологическую, морфологическую, синтаксическую, семантическую и т.п. – разметку).

4. *Компьютерная поддержка* (комплекс программ по обработке данных).

5. *Размер* (в зависимости от типа корпуса и исследовательских задач корпус может быть большего или меньшего размера; для общеязыкового (национального) корпуса в настоящее время принят минимальный размер в 100 млн словоупотреблений).

Потенциальный круг пользователей языковых корпусов

1. Лингвисты, филологи, текстологи.
2. Программисты, работающие в области автоматической обработки текстов.
3. Преподаватели как родного, так и иностранного языка.
4. Иностранцы, изучающие данный язык.
5. Журналисты, редакторы газет и журналов.
6. Так или иначе все специалисты, работающие со словом.

Задания для самостоятельной работы

1. Познакомьтесь с фрагментом статьи С.А. Шарова «Представительный корпус русского языка в контексте мирового опыта», включённым в приложение 1. Какие три понимания корпуса рассматриваются в данной статье? Что понимается под корпусом текстов в современной корпусной лингвистике?

2. Прочитайте фрагмент статьи В.А. Плунгяна «Зачем нужен Национальный корпус русского языка? Неформальное введение», включённый в приложение 1. Каким группам пользователей корпус может послужить необходимым инструментом в профессиональной деятельности, по мысли автора статьи? Прокомментируйте приведённые в статье примеры использования корпуса. Приведите свои примеры задач, которые можно было бы решить путём обращения к корпусу.

3. Ознакомьтесь с представленным в приложении 1 фрагментом статьи Н.В. Перцова «О роли корпусов в лингвистических исследованиях». Какую роль, по мысли автора статьи, могут сыграть корпуса текстов в лингвистических исследованиях?

4. Ознакомьтесь с включённым в приложение 1 фрагментом статьи А.В. Венцова, Е.В. Грудевой, В.Б. Касевича, Е.В. Ягуновой «Национальный корпус русского литературного языка: некоторые результаты, приложения и задачи». Какие сложности с выделением корпусной лингвистики как самостоятельной отрасли знаний видят авторы статьи?

Список литературы

1. *Баранов А.Н.* Корпусная лингвистика // Баранов А.Н. Введение в прикладную лингвистику. Изд. 3-е. М., 2007. С. 112 – 137.

2. *Венцов А.В.*, *Грудева Е.В.*, *Касевич В.Б.*, *Ягунова Е.В.* Национальный корпус русского литературного языка: некоторые результаты, приложения и задачи // Научно-техническая информация. Сер. 2. 2005. № 6. С. 35 – 40.

3. *Вербицкая Л.А.*, *Казанский Н.Н.*, *Касевич В.Б.* Некоторые проблемы создания Национального корпуса русского языка // Научно-техническая информация. Сер. 2. 2003. № 6. С. 2 – 8.

4. *Захаров В.П.* Корпусная лингвистика: Учеб.-метод. пособие. СПб., 2005.

5. *Перцов Н.В.* О роли корпусов в лингвистических исследованиях // Труды Международной конференции «Корпусная лингвистика – 2006» (Санкт-Петербург, 10 – 14 октября 2006 г.). СПб., 2006. С. 318 – 331.

6. *Плунгян В.А.* Зачем мы делаем Национальный корпус русского языка? // Отечественные записки: Журнал для медленного чтения. 2005. № 2. URL: http://www.strana-oz.ru/?article=1051&numid=23

7. *Плунгян В.А.* Почему современная лингвистика должна быть лингвистикой корпусов: Лекция. URL: http://www.polit.ru/lectures/2009/10/23/corpus.html

8. *Фрэнсис У.Н.* Проблемы формирования и машинного представления большого корпуса текстов // Новое в зарубежной лингвистике. Вып. XIV. Проблемы и методы лексикографии. М.: Прогресс, 1983. С. 334 – 352.

Тема 2
КОРПУСНАЯ ЛИНГВИСТИКА И СМЕЖНЫЕ ДИСЦИПЛИНЫ
(4 часа)

Корпусная лингвистика и традиционная лингвистика. Корпусная лингвистика и компьютерная лингвистика. Корпусная лингвистика и психолингвистика.

Сопоставление корпусной и традиционной лингвистик
(по: *Рыков http://rykov-cl.narod.ru/*)

Корпусная лингвистика	Традиционная лингвистика
1	2
1. Основное внимание – изучение речи	Основное внимание – изучение языка
2. Цель – описание языка в том виде, как он проявил себя в речи, представленной в виде специально подобранного корпуса текстов	Цель – описание и объяснение языка

Продолжение табл.

1	2
3. В своих исследованиях опирается на данные корпуса текста	В своих исследованиях идёт от теории к её объяснению и подтверждению в фактах речи
4. Предпочитает квантитативные методы	Предпочитает квалитативные методы
5. Видит себя частью традиций, базирующихся на эмпирических методах	Видит себя частью традиций, базирующихся на рационалистических методах
6. Текст рассматривается как некоторая физическая сущность	Текст рассматривается как некоторая абстракция
7. Составление грамматики конкретных языков	Изучает языковые универсалии
8. Основное внимание уделяется форме	Основное внимание – не только форме, но и содержанию
9. Рассматривает тексты в глобальной перспективе	Рассматривает тексты в локальной перспективе
10. Фокусирует своё внимание на как можно более широком взгляде на текст, не ограниченном никакими догмами	Анализирует некоторую конкретную, искусственно ограниченную, проблемную область
11. В своих выводах опирается на наблюдение речевой деятельности, проявленной в виде текстов	Опирается на интуицию в отборе речевого материала, в отборе эмпирических материалов своих исследований
12. Часто пользуется вероятностными методами и статистикой для первичной обработки речевого материала	Предпочитает логические рассуждения
13. Проводится работа с лингвистическими данными (словоупотреблениями) в том виде, в каком они встречались в контексте	Предпочитает искусственные примеры, а также примеры из изолированных от текста словоупотреблений

Окончание табл.

1	2
14. Предпочитает индуктивные методы обработки эмпирического словесного материала, считает их сутью научного метода	Предпочитает дедуктивные методы обработки эмпирического словесного материала
15. Верит в научные открытия, основанные на обработке эмпирических данных	Верит в открытия, основанные на процедурах, оценках, сравнениях и т.д., т.е. как результат многовековых исследований

Задания для самостоятельной работы

1. На основе изученных материалов попытайтесь сформулировать основные сходства и различия в подходах к сбору языкового материала в традиционной лингвистике и в корпусной лингвистике.

2. Какие достоинства и недостатки, на ваш взгляд, содержат указанные подходы?

3. Ознакомьтесь с представленными в приложении 2 фрагментами из работ А.В. Венцова, Е.В. Грудевой «О корпусе русского литературного языка», С.А. Шарова «Представительный корпус русского языка в контексте мирового опыта», У.Н. Фрэнсиса «Проблемы формирования и машинного представления большого корпуса текстов». Попытайтесь прокомментировать пункт 5 в таблице, предложенной В.В. Рыковым, с опорой на данные материалы.

4. Как могут быть связаны исследования в области психолингвистики и корпусной лингвистики (по статье А.В. Венцова, В.Б. Касевича, Е.В. Ягуновой «Корпус русского языка и восприятие речи», фрагмент которой представлен в приложении 2)?

5. Ознакомьтесь со статьёй Н.Н. Леонтьевой «Корпусная лингвистика и системы автоматического понимания текста», включённой в приложение 2. Попытайтесь ответить на следующие вопросы: а) какую связь видит автор статьи между корпусной лингвистикой и системами автоматического понимания текста (прикладной лингвистикой); б) как решается в статье проблема омонимии/неоднозначности языковых явлений?

Список литературы

1. *Баранов А.Н.* Корпусная лингвистика // Баранов А.Н. Введение в прикладную лингвистику. Изд. 3-е. М., 2007. С. 112 – 137.

2. *Венцов А.В., Касевич В.Б., Ягунова Е.В.* Корпус русских текстов и модель восприятия речи // III Всероссийская конференция «Теория и практика речевых исследований» (АРСО-2003). 8 – 10 сентября 2003 года, Москва, МГУ им. М. Ломоносова. М.: Филол. ф-т МГУ, 2003. С. 21 – 26.

3. *Венцов А.В., Касевич В.Б., Ягунова Е.В.* Национальный корпус русского литературного языка и разработка модели восприятия речи // Международная конференция «Корпусная лингвистика – 2004»: Тезисы докладов (12 – 14 октября 2004 г., С.-Петербург). СПб.: Изд-во Санкт-Петербург. ун-та, 2004. С. 20 – 21.

4. *Вербицкая Л.А., Казанский Н.Н., Касевич В.Б.* Некоторые проблемы создания Национального корпуса русского языка // Научно-техническая информация. Сер. 2. 2003. № 6. С. 2 – 8.

5. *Захаров В.П.* Корпусная лингвистика: Учеб.-метод. пособие. СПб., 2005.

6. *Касевич В.Б, Ягунова Е.В.* Корпус русского языка и восприятие речи // Научно-техническая информация. Сер. 2. 2003. № 6. С. 25 – 32.

7. *Леонтьева Н.Н.* Корпусная лингвистика и системы автоматического понимания текста // Московский лингвистический журнал. 2004. Т. 9. № 1. С. 5 – 15.

8. *Плунгян В.А.* Корпус как инструмент и как идеология // Национальный корпус русского языка и проблемы гуманитарного образования. Материалы Международной научной конференции (Москва, 19 – 20 апреля 2007 г.). М., 2007. С. 64 – 66.

9. *Плунгян В.А.* Почему современная лингвистика должна быть лингвистикой корпусов: Лекция. URL: http://www.polit.ru/lectures/2009/10/23/corpus.html

10. *Шаров С.А.* Представительный корпус русского языка в контексте мирового опыта // Научно-техническая информация. Сер. 2. 2003. № 6. С. 9 – 17. URL: http://www.viniti.ru/cgi-bin/nti/nti.pl?action=show&year=2_2003&issue=6&page=9&magnify=100

Тема 3

КОРПУС И WEB: СХОДСТВА И РАЗЛИЧИЯ

(4 часа)

Корпус как репрезентативная выборка текстов. Web как несбалансированный набор текстов. Возможности Web'а в лингвистических исследованиях.

Веб-пространство (Web) – информационное наполнение сети Интернет.

Недостатки Web'а в сравнении с корпусом

(по: *Шаров 2007*)

1. Web не является сбалансированным корпусом: набор текстов в Интернете отражает предпочтения и интересы его активных пользователей.
2. Поисковые машины ориентированы на информационный поиск и не работают с лингвистическими параметрами.
3. Невозможно провести статистическую оценку результата поиска.

Достоинства корпуса в сравнении с Web'ом

1. Корпус является сбалансированным (в отношении жанров и функциональных стилей) собранием текстов, что даёт возможность проводить статистически достоверные исследования лингвистических феноменов.
2. Пользовательский запрос может быть сформирован по лингвистическим критериям (например, по грамматическим или семантическим признакам).
3. Возможна статистическая оценка результатов.

Задания для самостоятельной работы

Ознакомьтесь со статьёй В.И. Беликова и М.В. Ахметовой «Статистическая оценка функциональных свойств лексики по материа-

лам Интернета», включённой в приложение 3. Почему при работе с лексическим материалом, по мысли авторов статьи, корпус оказывается недостаточно надёжным инструментом? Каким образом и для решения каких задач предлагают использовать текстовые массивы в Интернете авторы статьи?

Список литературы

1. *Беликов В.И., Ахметова М.В.* Статистическая оценка функциональных свойств лексики по материалам Интернета // Компьютерная лингвистика и интеллектуальные технологии: По материалам ежегодной Международной конференции «Диалог-2009» (Бекасово, 27 – 31 мая 2009 г.). Вып. 8 (15). М.: РГГУ, 2009. С. 25 – 30. URL: http://www.dialog-21.ru/dialog2009/materials/-html/05.htm

2. *Захаров В.П.* Корпусная лингвистика: Учеб.-метод. пособие. СПб., 2005.

3. *Захаров В.П.* Веб-пространство как языковой корпус // Компьютерная лингвистика и интеллектуальные технологии: Труды Международной конференции «Диалог-2005» (Звенигород, 1 – 6 июня, 2005 г.) / Под ред. И.М. Кобозевой, А.С. Нариньяни, В.П. Селегея. М.: Наука, 2005.

4. *Шаров С.А.* Представительный корпус русского языка в контексте мирового опыта // Научно-техническая информация. Сер. 2. 2003. № 6. С. 9 – 17. URL: http://www.viniti.ru/cgi-bin/nti/nti.pl?action=show&year=2_2003&issue=6&page=9&magnify=100

5. *Шаров С.А.* Централизованное планирование vs. стихия рынка: сравнение лексического и жанрового разнообразия в Национальном корпусе русского языка и Интернете // Компьютерная лингвистика и интеллектуальные технологии: Труды Международной конференции «Диалог-2007» (Бекасово, 30 мая – 3 июня 2007 г.) / Под ред. Л.Л. Иомдина, Н.И. Лауфер, А.С. Нариньяни, В.П. Селегея. М.: Изд-во РГГУ, 2007. С. 573 – 581.

Тема 4

ИСТОРИЯ СОЗДАНИЯ ЭЛЕКТРОННЫХ ЯЗЫКОВЫХ КОРПУСОВ

(6 часов)

Брауновский корпус: авторы, объём, принципы отбора материала. Ланкастерско-Осло-Бергенский корпус (LOB). Лондонско-Лундский корпус. Бирмингемский корпус. Британский национальный корпус. Упсальский корпус русского языка. Машинный фонд русского языка. Национальный корпус русского языка. Корпус русского литературного языка. Компьютерный корпус газетных текстов русского языка конца XX века. Хельсинкский аннотированный корпус русского языка. Фундаментальные корпусы других славянских языков: Чешский национальный корпус, Словацкий национальный корпус, Хорватский национальный корпус.

Основные вехи в истории создания фундаментальных языковых корпусов

Брауновский корпус американского варианта современного английского языка (Brown Corpus, BC)

Время и место создания – 1962 – 1963 гг., Брауновский университет, США.

Объём – 1 млн словоупотреблений.

Состав – 500 фрагментов объёмом по 2000 словоупотреблений из текстов, изданных в 1961 г. в США, разных жанров: газетные статьи, религиозная литература, научно-популярная литература, беллетристика, образцы деловой прозы и пр.

Виды аннотирования – изначально только структурная разметка текстов с выделением абзацев, заголовков, цитат и т.п.

Доступ в Интернете – http://icame.uib.no/brown/bcm.html#bc3

Ланкастерско-Осло-Бергенский корпус британского варианта современного английского языка (The Lancaster-Oslo/Bergen Corpus of British English, LOB)

Время и место создания – 1970 – 1978 гг., университет Ланкастера, университет Осло, Норвежский вычислительный центр для гуманитарных наук в Бергене.

Объём – 1 млн словоупотреблений.

Состав – 500 текстов, изданных в 1961 г. в Великобритании, объёмом по 2000 словоупотреблений, разных жанров: газетные статьи, религиозная литература, научно-популярная литература, беллетристика, образцы деловой прозы и пр.

Виды аннотирования – изначально только структурная разметка текстов с выделением абзацев, заголовков, цитат и т.п.

Доступ в Интернете – http://khnt.hit.uib.no/icame/manuals/lob/index.htm

Британский национальный корпус (British National Corpus, BNC)

Время и место создания – 1991 – 1994 гг., Оксфордский университет, университет Ланкастера.

Объём – 100 млн словоупотреблений.

Состав – письменные (90 %) и устные (10 %) тексты второй половины XX века разных жанров: газетные статьи, религиозная литература, научно-популярная литература, беллетристика, специализированная литература, образцы деловой прозы, транскрибированные записи неофициальной речи, радио-шоу, правительственной речи и пр.

Виды аннотирования – метатекстовая разметка, частеречная разметка, выделение фраз с опорой на знаки препинания.

Доступ в Интернете – http://www.natcorp.ox.ac.uk/

Корпусы русского языка

Упсальский корпус русского языка (The Uppsala Russian Corpus)

Время и место создания – конец 1980-х – начало 1990-х гг., университет Упсалы, Швеция.

Объём – 1 млн словоупотреблений.

Состав – 600 фрагментов из художественных текстов (художественная литература, написанная и изданная в период с 1960-го по 1988 г.; 40 писателей) и из информативных текстов (газетная и журнальная проза периода 1985 – 1989 гг.) в примерно равных пропорциях.

Виды аннотирования – изначально только структурная разметка текстов с выделением абзацев, заголовков, цитат и т.п.

Доступ в Интернете – http://www.slaviska.uu.se/korpus.htm

Национальный корпус русского языка (НКРЯ)

Время и место создания – 2003 – 2010 гг., ассоциация «Национальный корпус русского языка», г. Москва.

Объём – 163 млн словоупотреблений.

Состав – сбалансированный корпус с 1950 г. (в том числе устные тексты), художественная литература, научные тексты и публицистика с середины XVIII до середины XX века.

Виды аннотирования – метатекстовая, морфологическая, семантическая, акцентная, синтаксическая разметка.

Доступ в Интернете – http://ruscorpora.ru/index.html

Тюбингенский корпус русского языка (ТК)

Время и место создания – 1999 – 2004 гг., Тюбингенский университет, Германия.

Объём – 25 млн словоупотреблений.

Состав – набор различных коллекций текстов – Упсальский корпус; публицистика (1996 – 2002 гг.); художественная литература XIX – XX вв.

Виды аннотирования – морфологическая разметка.

Доступ в Интернете – http://www.sfb441.uni-tuebingen.de/b1/en/korpora.html

Корпус русского литературного языка (КРЛЯ)

Время и место создания – 2001 – 2006 гг., Санкт-Петербургский университет.

Объём – 1 млн словоупотреблений.

Состав – сбалансированный корпус, включающий беллетристику, научно-популярные, публицистические, а также драматургические тексты начиная с середины XX в.

Виды аннотирования – метатекстовая, акцентная разметка.

Доступ в Интернете – http://www.narusco.ru

Компьютерный корпус газетных текстов русского языка конца XX века (КГТ)

Время и место создания – 2000 – 2002 гг., Лаборатория общей и компьютерной лексикологии и лексикографии МГУ им. М.В. Ломоносова.

Объём – 200 тыс. словоупотреблений.

Состав – полные тексты избранных номеров ряда российских газет на русском языке, опубликованных в 1994 – 1997 гг.

Виды аннотирования – метатекстовая, морфологическая, синтаксическая (размечены предложные группы), семантическая разметка.

Доступ в Интернете – http://www.philol.msu.ru/~lex/corpus/

Хельсинкский аннотированный корпус русского языка (ХАНКО)

Время и место создания – с 2001 г. по настоящее время, Отделение славянских и балтийских языков и литератур Хельсинкского университета, Финляндия.

Объём – 100 тыс. словоупотреблений.

Состав – все крупные статьи из журнала «Итоги» за январь 2001 г.

Виды аннотирования – морфологическая, синтаксическая разметка.

Доступ в Интернете – http://www.helsinki.fi/venaja/russian/e-material/hanco/index.htm

Фундаментальные корпусы других славянских языков

Чешский национальный корпус (Český národní korpus, ČNK)

Время и место создания – с 1994 г. по настоящее время, Карлов университет Праги.

Объём – 502 млн 300 тыс. словоупотреблений.

Состав – коллекция сбалансированных и специализированных корпусов письменного языка (1990 – 2004 гг.) объёмом 500 млн словоупотреблений; записи устной речи из разных регионов Чехии объёмом 2 млн 300 тыс. словоупотреблений.

Виды аннотирования – метатекстовая, морфологическая разметка.

Доступ в Интернете – http://ucnk.ff.cuni.cz/

Словацкий национальный корпус (Slovenský národný korpus, SNK)

Время и место создания – с 2002 г. по настоящее время, Институт языкознания Словацкой академии наук.

Объём – 339 млн словоупотреблений.

Состав – письменные тексты разных типов (1955 – 2006 гг.).

Виды аннотирования – метатекстовая, морфологическая разметка.

Доступ в Интернете – http://korpus.juls.savba.sk/

Хорватский национальный корпус (Hrvatski nacionalni korpus, (HNK)

Время и место создания – с 1996 г. по настоящее время, Институт лингвистики Загребского университета.

Объём – 101 млн словоупотреблений.

Состав – газеты, журналы (1990 – 2005 гг.), художественная литература с XVI в.

Виды аннотирования – метатекстовая, морфологическая разметка.

Доступ в Интернете – http://www.hnk.ffzg.hr/

Список литературы

1. *Баранов А.Н.* Корпусная лингвистика // Баранов А.Н. Введение в прикладную лингвистику. Изд. 3-е. М., 2007. С. 112 – 137.

2. *Захаров В.П.* Корпусная лингвистика: Учеб.-метод. пособие. СПб., 2005.

3. *Копотев М.В., Мустайоки А.* Современная корпусная русистика // Slavica Helsingiensia 34. Инструментарий русистики: корпусные подходы / Под ред. А. Мустайоки, М.В. Копотева, Л.А. Бирюлина, Е.Ю. Протасовой. Хельсинки, 2008.

4. *Резникова Т.И., Копотев М.В.* Лингвистически аннотированные корпуса русского языка (обзор общедоступных ресурсов) // Национальный корпус русского языка: 2003 – 2005. Результаты и перспективы. М., 2005. С. 31 – 61.

5. *Резникова Т.И.* Корпуса славянских языков в Интернете: Обзор ресурсов // Die Welt der Slaven LIII, 2008, 10 – 38.

6. *Резникова Т.И.* Славянская корпусная лингвистика: современное состояние ресурсов // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы. СПб.: Нестор-История, 2009. С. 402 – 461.

7. *Шаров С.А.* Представительный корпус русского языка в контексте мирового опыта // Научно-техническая информация. Сер. 2. 2003. № 6. С. 9 – 17 URL: http://www.viniti.ru/cgi-bin/nti/nti.pl?action=show&year=2_2003&issue=6&page=9&magnify=100

Тема 5

ТИПОЛОГИЯ ЯЗЫКОВЫХ КОРПУСОВ

(6 часов)

Корпус языка в целом (фундаментальный корпус). Корпус подъязыка. Исследовательские и иллюстративные корпусы. Динамические и статические корпусы текстов. Моноязычные корпусы. Корпусы параллельных текстов. Диахронические корпусы.

Классификация корпусов
(по: *Захаров 2005*)

Признак	Типы корпусов
Тип данных	Письменные Речевые Смешанные
Язык текстов	Русский Английский и т.д.
«Параллельность»	Одноязычные Двуязычные Многоязычные
«Литературность», специфичность	Литературные Диалектные Разговорные Терминологические Смешанные
Жанр	Литературные Фольклорные Драматургические Публицистические
Доступность	Свободно доступные Коммерческие Закрытые
Назначение	Исследовательские Иллюстративные
Динамичность	Динамические (мониторные) Статические
Разметка	Размеченные Неразмеченные
Характер разметки	Морфологические Синтаксические Семантические Просодические и т.д.
Объем текстов	Полнотекстовые «Фрагментнотекстовые»
Хронологический аспект	Синхронические Диахронические
«Общность»	Общие Одного писателя
Структура	Центральные и архивные Ядерные и периферийные

Классификация корпусов письменных текстов по принципу ширины охвата текстов

(по: *Сичинава* http://www.mccme.ru/ling/mitrius/article.html)

1. *Полный корпус* (все печатные тексты на данном языке, возможный параметр – время).

2. *Культурно-репрезентативный корпус* (собрание культурно значимых текстов на данном языке).

3. *«Эталонный» корпус* (тексты, написанные «стандартным» языком – языком, лишённым по возможности сознательных стилевых и лексических экспериментов, но в то же время «гладким» и профессиональным).

Список литературы

1. *Баранов А.Н.* Корпусная лингвистика // Баранов А.Н. Введение в прикладную лингвистику. Изд. 3-е. М., 2007. С. 112 – 137.

2. *Гришина Е.А., Корчагин К.М., Плунгян В.А., Сичинава Д.В.* Поэтический корпус в рамках НКРЯ: общая структура и перспективы использования // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 71 – 113.

3. *Гришина Е.А., Савчук С.О.* Корпус устных текстов в НКРЯ: состав и структура // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 129 – 148.

4. *Захаров В.П.* Корпусная лингвистика: Учеб.-метод. пособие. СПб., 2005.

5. *Летучий А.Б.* Диалектный корпус: состав и особенности разметки // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 114 – 128.

6. *Сичинава Д.В.* К задаче создания корпусов русского языка. URL: http://www.mccme.ru/ling/mitrius/article.html

Тема 6

НАЦИОНАЛЬНЫЙ КОРПУС И ТРЕБОВАНИЯ К ЕГО СОЗДАНИЮ

(4 часа)

Понятие «национальный» в терминологическом словосочетании «национальный корпус». Размер корпуса. Хронологический охват языка. Репрезентативность (представительность) корпуса. Филологическая экспертиза текстов. Типы аннотирования в национальном корпусе. Многофункциональность национального корпуса. Общедоступность.

Основные требования к созданию национального корпуса

1. Необходимый и достаточный объём (по современным требованиям – 100 млн словоупотреблений).
2. Достаточно протяжённый хронологический охват языка.
3. Репрезентативность выборки текстов (учёт всех жанровых и функциональных разновидностей языка в соответствующих соотношениях).
4. Тексты должны пройти филологическую экспертизу.
5. Тексты должны быть представлены в электронной форме.
6. Многопрофильная система аннотирования (метатекстовая, акцентная, морфологическая, синтаксическая, семантическая разметка).
7. Многофункциональность корпуса (национальный корпус должен предоставлять широкие возможности работы с языковым материалом).
8. Общедоступность.

Задания для самостоятельной работы

Прочитайте фрагмент статьи В.А. Плунгяна «Зачем нужен Национальный корпус русского языка? Неформальное введение», представленный в приложении 4. На какие существенные признаки

Национального корпуса указывает автор статьи и как реализуются эти признаки в Национальном корпусе русского языка?

Список литературы

1. *Вербицкая Л.А., Казанский Н.Н., Касевич В.Б.* Некоторые проблемы создания Национального корпуса русского языка // Научно-техническая информация. Сер. 2. 2003. № 6. С. 2 – 8.

2. *Плунгян В.А*. Зачем мы делаем Национальный корпус русского языка? // Отечественные записки: Журнал для медленного чтения. 2005. № 2. URL: http://www.strana-oz.ru/?article=1051&numid=23

3. *Плунгян В.А*. Зачем нужен Национальный корпус русского языка? Неформальное введение // Национальный корпус русского языка: 2003 – 2005. М.: Индрик, 2005. С. 6 – 20.

Тема 7
МЕТАТЕКСТОВАЯ РАЗМЕТКА
(4 часа)

Метаразметка как часть поискового аппарата корпуса. Классификация текстов для создания представительных корпусов. Стандарт EAGLES. Классификация текстов Синклера – Шарова.

Метаразметка (метаописание) – приписывание тексту атрибутов, характеризующих обстоятельства его создания, автора, тематику, жанровые особенности и т.п.

Структура метаразметки Национального корпуса русского языка
(http://ruscorpora.ru/corpora-parameter.html)

I. «Паспорт текста»

Автор текста: имя, пол, дата рождения (или примерный возраст).

Название текста.

Время создания текста (может указываться точно или приблизительно; при поиске может использоваться формат «<не> раньше такой-то даты» или «<не> позже такой-то даты»).

Объем текста (в количестве слов; при поиске может использоваться формат «<не> более такого-то объема» или «<не> менее такого-то объема»). Дается пояснение: для художественных произведений принято, что обычная длина рассказа – менее 5 тыс. слов; обычная длина повести – от 5 до 15 тыс. слов; обычная длина романа – более 15 тыс. слов.

Блок II состоит из трех поисковых массивов: «нехудожественная проза», «художественная проза», «драматургия». Первые два массива имеют несколько разные структуры параметров, поэтому оформляются по отдельности.

II.1. Художественные тексты

Жанр текста (включается также помета «нежанровая проза»): историко-приключенческая, криминальная, любовная литература, сатира и юмор, фантастика и т.п.

Тип текста (при обозначении типа широко используется самоидентификация текста; список типов в принципе открытый и дается в окне поиска в алфавитном порядке): анекдот, боевик, детектив, повесть, притча, рассказ, роман, сказка, триллер, эпопея, эссе и т.п.

Хронотоп текста (приблизительное указание на место и время описываемых в тексте событий; включается также помета «хронотоп не определен»); в частности, различается доисторический период, античность, Средние века, Новое время, Россия: 19-й век, Россия: 20-й век (до 1914 г.), Россия/СССР: война 1914 – 1918 гг., революция, гражданская война, 20-е гг., 30-е гг., война 1941 – 1945 гг., послевоенный период (до 1952 г.), 50-е гг., 60 – 80-е гг., перестройка, Россия: постсоветский период. Для художественных текстов указание на хронотоп дается вместо указания на тематику (как более информативное).

II.2. Нехудожественные тексты

Сфера функционирования текста (параметр призван отражать в первую очередь языковые особенности): бытовая, официально-деловая, производственно-техническая, публицистическая, учебно-научная, церковно-богословская.

Тип текста (при обозначении типа широко используется самоидентификация текста; список типов в принципе открытый и дается в окне поиска в алфавитном порядке; включается также помета «тип не определен»): автобиография, акт, дневник, договор, документ, закон, заметка, заявление, инструкция, информационное сообщение, кодекс, комментарий, листовка, обзор, объявление, отзыв, отчет, очерк, письмо, постановление, проповедь, путеводитель, резюме, реклама, рекомендация, рецензия, рецепт, сочинение, справочник, статья, учебник, характеристика, хроника, эссе и т.п.

Тематика текста (в принципе, у одного текста тем может быть несколько; список открытый): бизнес, коммерция, экономика, финансы; война и вооруженные конфликты; дом и домашнее хозяйство; здоровье и медицина; зрелища и развлечения; искусство; криминал; наука (по разделам и отраслям); политика и общественная жизнь; право; производство; сельское хозяйство; спорт; природа; частная жизнь и т.п.

Внешние и внутренние факторы, легшие в основу классификации текстов Синклера – Шарова

***E*-факторы** – внешние, то есть внеязыковые факторы, которые могут повлиять на структуру или содержание текста.

***I*-факторы** – внутренние, то есть факторы, отражающие свойства языка, используемого в тексте.

Выделяются три группы *E*-факторов:

E_1 **(origin)** – факторы, относящиеся к созданию текста автором;

E_2 **(state)** – факторы, относящиеся к внешним признакам текста;

E_3 **(aims)** – факторы, относящиеся к целям создания текста и его влиянию на аудиторию.

Два основных *I*-фактора:

***I*₁ (topic)** – предметная область текста;

***I*₂ (style)** – стилистические особенности (частично зависящие от *E*-факторов).

Структура экстралингвистической разметки текстов

(по: *Волков, Захаров 2004*)

Структурная разметка «Внешняя» разметка (метаданные)

Структурная разметка

Текст
Раздел
Абзац
Предложение

«*Внешняя» разметка* (*метаданные*)

Библиографические данные (автор, выходные данные, год издания)

Типологические данные (тип текста, жанр, стиль)

Тематические данные (дескрипторы содержания, классификационные индексы)

Социологические данные (обстоятельства создания, бытования, использования текста)

Список литературы

1. *Волков С.Св., Захаров В.П.* Параметры описания текстов для корпуса русского языка XIX века // Международная конференция «Корпусная лингвистика – 2004»: Тезисы докладов (12 – 14 октября 2004 г., С.-Петербург). СПб.: Изд-во Санкт-Петербург. ун-та, 2004. С. 23 – 25.

2. *Захаров В.П.* Корпусная лингвистика: Учеб.-метод. пособие. СПб., 2005.

3. *Савчук С.О.* Метатекстовая разметка в Национальном корпусе русского языка: базовые принципы и основные функции // Национальный корпус русского языка: 2003 – 2005. Результаты и перспективы. М., 2005. С. 62 – 88. URL: http://ruscorpora.ru/sbornik2005/05savchuk.pdf

4. *Шаров С.А.* Представительный корпус русского языка в контексте мирового опыта // Научно-техническая информация. Сер. 2. 2003. № 6. С. 9 – 17. URL: http://www.viniti.ru/cgi-bin/nti/nti.pl?action=show&year=2_2003&issue=6&page=9&magnify=100

Тема 8
ВИДЫ ЛИНГВИСТИЧЕСКОГО АННОТИРОВАНИЯ
(6 часов)

Понятие лингвистического аннотирования (разметки). Акцентная разметка. Морфологическая разметка. Синтаксическая разметка. Семантическая разметка. Фонетическая разметка. Метрическая разметка поэтических текстов. Выравнивание в параллельных корпусах.

Разметка (англ. tagging, annotation) заключается в приписывании текстам и их компонентам специальных меток (англ. tag, tags) [*Захаров 2005*].

В англоязычной литературе термин *tagging* обычно обозначает грамматическую разметку. Ср. в «Англо-русском словаре по лингвистике и семиотике»:

tagging – грамматическое аннотирование, грамматическая разметка. Например, в компьютерном корпусе текстов. Выполняется в автоматическом, полуавтоматическом (интерактивном) или ручном режиме. Чаще всего с помощью специальных меток указывается грамматическая форма каждого слова, однако нередко выполняется и более сложная разметка – фонетическая, синтаксическая и даже семантическая… [*Англо-русский словарь… 2001*].

Лемма (lemma) – словарная форма слова, вокабула.

Лемматизация (lemmatization) – процедура восстановления словарной формы слова по его словоформе. Часто используется в кон-

кордансных программах для упрощения построения поискового запроса, а также для получения лемматизированных словников.

Лемматизатор (lemmatizing program) – программа, восстанавливающая словарную форму слова по его словоформе.

Парсер (parser) – компьютерная программа, осуществляющая приписывание предложению синтаксической структуры, а также алгоритм такой программы. Термин иногда используется и по отношению к программам морфологического и фонетического анализа.

Парсинг (parsing) – автоматический грамматический анализ, переводящий выражения языка-объекта в выражения метаязыка описания – внутреннего языка блока анализа.

[*Англо-русский словарь… 2001*]

Текстоформа – «аналог» словоформы в компьютерной лингвистике; на практике часто понимается как единица от пробела до пробела.

Лемма – «аналог» лексемы, результат автоматического сведения текстоформ к начальной форме.

[*Копотев 2006*]

Задания для самостоятельной работы

1. Ознакомьтесь с фрагментом рецензии М.В. Копотева и Л. Янды на Национальный корпус русского языка, помещённым в приложении 5. Каково отношение авторов рецензии к видам разметки, представленным в Национальном корпусе русского языка? В чём авторы рецензии видят причины теоретической эклектичности, неизбежной при разметке корпуса большого объёма?

2. Ознакомьтесь с фрагментом работы Д.О. Добровольского, А.А. Кретова, С.А. Шарова «Корпус параллельных текстов: архитектура и возможности использования» (приложение 5). Попытайтесь сформулировать основные проблемы, возникающие при разметке параллельных текстов, и охарактеризуйте возможные стратегии выравнивания параллельных текстов.

Список литературы

1. Англо-русский словарь по лингвистике и семиотике. Около 9000 терминов. Изд-е 2-е, испр. и доп. / А.Н. Баранов, Д.О. Добровольский, М.Н. Михайлов и др.; Под ред. А.Н. Баранова и Д.О. Добровольского. М.: Азбуковник, 2001.

2. *Баранов А.Н.* Корпусная лингвистика // Баранов А.Н. Введение в прикладную лингвистику. Изд. 3-е. М., 2007. С. 112 – 137.

3. *Добровольский Д.О., Кретов А.А., Шаров С.А.* Корпус параллельных текстов: архитектура и возможности использования // Национальный корпус русского языка: 2003 – 2005. М.: Индрик, 2005. С. 263 – 296.

4. *Вербицкая Л.А., Казанский Н.Н., Касевич В.Б.* Некоторые проблемы создания Национального корпуса русского языка // Научно-техническая информация. Сер. 2. 2003. № 6. С. 2 – 8.

5. *Захаров В.П.* Корпусная лингвистика: Учеб.-метод. пособие. СПб., 2005.

6. *Копотев М.В., Янда Л.* Национальный корпус русского языка (www.ruscorpora.ru) (*рец.*) // Вопросы языкознания. 2006. № 5. С. 149 – 155.

7. *Пильщиков И.А., Старостин А.С.* Основные проблемы автоматизации базовых процедур ритмико-синтаксического анализа силлабо-тонических текстов // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 298 – 315.

Тема 9
РАЗЛИЧНЫЕ ТЕХНОЛОГИИ РАЗМЕТКИ
(4 часа)

Автоматическая, полуавтоматическая, ручная разметка.

Языковые препятствия, возникающие на пути автоматической разметки: многозначность и омонимия, идиомы, «составные слова».

Задания для самостоятельной работы

1. Ознакомьтесь с фрагментом статьи О.Н. Ляшевской, В.А. Плунгяна, Д.В. Сичинавы, посвящённой морфологическому стандарту Национального корпуса русского языка (приложение 6).

Какие существуют основные («крайние», по выражению авторов статьи) подходы к морфологической разметке? В чём заключается их «крайность»? Какой вариант преодоления этих крайностей предлагают авторы статьи и как он реализуется в Национальном корпусе русского языка?

2. Ознакомьтесь с работой В.Б. Касевича, А.В. Венцова, Е.В. Грудевой, Н.А. Слепокуровой, Е.А. Сведенцовой «О морфологии в Национальном корпусе русского языка»[2] (приложение 6). Как относятся авторы статьи к автоматической разметке текстов? Какое решение в связи с этим предлагается в данной работе?

3. Ознакомьтесь с рецензией М.В. Копотева и Л. Янды на Национальный корпус русского языка (приложение 6). Как связаны, по мысли авторов статьи, такие показатели корпуса, как его объём и точность обработки языкового материала? Как с этих позиций авторы рецензии оценивают морфологическую разметку в Национальном корпусе русского языка?

Список литературы

1. *Венцов А.В., Грудева Е.В., Касевич В.Б., Ягунова Е.В.* Национальный корпус русского литературного языка: некоторые результаты, приложения и задачи // Научно-техническая информация. Сер. 2. 2005. № 6. С. 35 – 40.

2. *А.В. Венцов, Е.В. Грудева, В.Б. Касевич, Е.А. Сведенцова, Н.А. Слепокурова.* О морфологии в Национальном корпусе русского языка // Материалы XXXIII Международной филологической конференции (15 – 20 марта 2004 г., Санкт-Петербург). Вып. 24. Секция общего языкознания. Ч. 2. СПб.: ОНУТ Филол. ф-та СПбГУ, 2004. С. 3 – 8.

3. *Ляшевская О.Н., Плунгян В.А., Сичинава Д.В.* О морфологическом стандарте Национального корпуса русского языка // Национальный корпус русского языка: 2003 – 2005. Результаты и перспективы. М., 2005. С. 111 – 135.

4. *Копотев М.В., Янда Л.* Национальный корпус русского языка. (www.ruscorpora.ru) (*рец.*) // Вопросы языкознания. 2006. № 5. С. 149 – 155.

[2] В данной статье речь идёт о Корпусе, который позднее был переименован: в настоящий момент он носит название «Корпус русского литературного языка» (сокращённо – КРЛЯ) и размещён на сайте www.narusco.ru (сноска моя. – *Е.Г.*).

Тема 10

МНОГОКОМПОНЕНТНЫЕ ЕДИНИЦЫ В АННОТИРОВАННОМ КОРПУСЕ: КОРПУСНЫЙ И ПСИХОЛИНГВИСТИЧЕСКИЙ ПОДХОДЫ

(6 часов)

Понятие многокомпонентной единицы. Идиоматические сочетания: проблемы аннотирования. «Составные слова», или «эквиваленты слова»: проблемы аннотирования и результаты поиска. Аналитические формы: проблемы аннотирования и результаты поиска. Корпусный и психолингвистический подходы к аннотированию многокомпонентных единиц: возможное соотношение теоретических и технологических решений.

Результаты поиска словоформы «в» в частотном словаре Корпуса русского литературного языка (www.narusco.ru) (при поиске задана дополнительная опция «искать и как часть составной словоформы»)

Словоформа	**Число вхождений по жанрам** (в скобках приведено общее число словоформ в Корпусе)				
	Драма-тургия (196107)	**Беллет-ристика** (354618)	**Публи-цистика** (303110)	**Научно-популярная литература** (198980)	**Всего** (1052815)
1	2	3	4	5	6
в	3332	9103	9681	6320	28436
в_до+лг	1	0	2	0	3
в_счё+т	3	6	2	1	12
в_че+сть	1	5	3	1	10
в_но+чь	2	0	0	0	2
в_ло+б	0	3	2	1	6
в_зна+к	0	3	0	1	4
в_ла+д	0	1	0	0	1
в_сро+к	0	0	2	0	2

Продолжение табл.

1	2	3	4	5	6
в_фа+с	0	0	0	1	1
в_ку+рсе	6	3	1	1	11
в_го+сти	22	13	5	2	42
в_о+бщем	40	35	20	14	109
в_си+лах	2	10	6	8	26
в_ме+ру	3	8	2	2	15
в_смы+сле	7	1	4	2	14
в_го+лос	0	6	2	0	8
в_тя+гость	2	2	0	0	4
в_па+мять	1	2	3	1	7
в_си+лу	1	6	7	12	26
в_но+гу	2	0	0	0	2
в_це+лом	0	5	35	29	69
в_мо+де	0	1	1	0	2
в-тре+тьих	0	2	6	1	9
в_пи+ку	0	1	1	0	2
в_шу+тку	0	5	1	1	7
в_стру+нку	0	1	0	0	1
в_сре+днем	0	2	17	9	28
в_пла+не	0	1	1	1	3
в_но+ги	0	0	1	0	1
в-пя+тых	0	0	1	0	1
в_све+те	0	0	1	1	2
в_ко+рне	0	0	0	2	2
в_сто+рону	2	44	4	3	53
в_су+щности	6	13	12	6	37
в_о+бщем-то	6	5	10	2	23
в_у+жасе	0	12	1	0	13
в_при+нципе	3	15	13	14	45

Продолжение табл.

1	2	3	4	5	6
в_на+глую	1	0	0	0	1
в_ча+стности	0	4	46	45	95
в_то+чности	0	1	8	3	12
в_скла+дчину	0	1	0	0	1
в_слу+чае_чего^	2	3	0	0	5
в_связи+_с	3	6	26	24	59
в_гостя+х	5	2	2	1	10
в_обре+з	4	0	1	0	5
в_отве+т	1	19	4	2	26
в_упо+р	0	11	3	0	14
в_глаза+	7	1	1	0	9
в_нога+х	1	3	1	0	5
в_живы+х	2	6	6	2	16
в_ходу+	1	0	1	1	3
в_толчки+	1	0	0	0	1
в_сердца+х	0	5	1	0	6
в_струну+	0	1	0	0	1
в__лице+	0	0	8	0	8
в_обхо+д	0	0	3	1	4
в_цене+	0	0	1	1	2
в_отъе+зде	1	0	0	0	1
в_раска+чку	1	0	0	0	1
в_обни+мку	1	6	0	0	7
в_нату+ре	1	0	0	0	1
в_ажу+ре	2	0	0	0	2
в_дальне+йшем	1	1	14	11	27
в_прида+чу	1	4	1	0	6
в_поми+не	1	1	3	0	5
в_поря+дке	0	3	2	2	7

Продолжение табл.

1	2	3	4	5	6
в_ито+ге	0	5	12	6	23
в_нагру+зку	0	1	3	0	4
в_нови+нку	0	1	0	0	1
в_трево+ге	0	1	0	0	1
в_заты+лок	0	1	0	0	1
в_привы+чку	0	1	0	0	1
в_оха+пку	0	2	0	0	2
в_обме+н_на	0	1	4	0	5
в_отме+стку	0	1	0	2	3
в-четвё+ртых	0	0	3	0	3
в_избы+тке	0	0	1	0	1
в_обли+пку	0	0	1	0	1
в_обтя+жку	0	0	1	0	1
в_связи+_со	0	0	1	0	1
в_охо+тку	0	0	1	0	1
в_тече+ние	4	20	39	48	111
в_отде+льности	1	1	3	2	7
в_то^_вре+мя_как	0	8	10	9	27
в_сравне+нии_с	0	4	8	2	14
в_откры+тую	0	1	1	0	2
в_преддве+рии	0	1	2	1	4
в_расчё+те_на	0	0	2	1	3
в_отры+ве_от	0	0	2	0	2
в_отли+чие	0	0	0	1	1
в_отли+чие_от	6	8	21	21	56
в_осо+бенности	1	6	8	2	17
в_действи+тельности	1	2	7	8	18
в_после+дующем	0	0	0	2	2
в_зави+симости_от	0	1	9	19	29

Продолжение табл.

1	2	3	4	5	6
в_голова+х	1	3	0	0	4
в_стороне+	0	14	4	0	18
в_основно+м	1	6	38	32	77
в_унисо+н	0	0	1	0	1
в_большинстве+	0	0	0	1	1
в_раскоря+чку	1	0	0	0	1
в_одино+чку	2	5	5	4	16
в_ко^и_ве+ки	0	1	0	0	1
в_одноча+сье	0	1	2	0	3
в_аккура+те	0	1	0	0	1
в_соверше+нстве	0	0	1	1	2
в_беспоря+дке	0	0	0	1	1
в_состоя+нии	5	4	14	13	36
в_соотве+тствии_с	3	0	13	11	27
в_отдале+нии	0	9	0	0	9
в_одино+честве	3	2	1	3	9
в_продолже+ние	0	3	1	0	4
в_доверше+ние	1	0	0	0	1
в_заключе+ние	0	1	5	2	8
в_нетерпе+нии	0	1	0	1	2
в_отноше+нии	0	0	22	5	27
в_наруше+ние	0	0	2	0	2
в_нереши+тельности	0	1	0	0	1
в_противове+с	0	1	0	1	2
в_ко^и-то_ве+ки	0	0	1	0	1
в_противополо+жность	0	0	1	0	1
ко^е__в__чё+м	0	2	0	0	2
не_в_счё+т	3	0	1	0	4
ни_в_жи+сть	1	0	0	0	1

Продолжение табл.

1	2	3	4	5	6
не_в_ду+хе	1	2	0	0	3
ни_в_ко+ем_слу^чае	7	10	10	2	29
не_в_себе+	2	3	0	0	5
не_в_приме+р	0	2	0	1	3
ни_в_глазу+	0	0	0	1	1
ни_в_каку+ю	1	0	0	0	1
то^чь-в-то+чь	2	4	0	0	6
бо+г_в_по+мощь	0	1	0	0	1
бо^г_зна+ет_в_чё+м	1	0	0	0	1
в_са+мом_де+ле	37	25	20	12	94
в_са+мом-то_де+ле	2	0	1	0	3
в_бо+га_ма+ть	1	0	0	0	1
в_пе+рвую_го+лову	1	0	0	0	1
в_са+мый_ра+з	1	2	2	0	5
в_о+бщем_и_це+лом	0	1	1	0	2
в_не+котором_ро+де	0	1	1	0	2
в_э+той_связи+	0	1	8	1	10
в_по+те_лица+	0	3	1	1	5
в_пе+рвую_о+чередь	0	4	10	4	18
в_кра+йнем_слу+чае	1	0	1	0	2
в_конце+_концо+в	29	40	19	4	92
в_свою+_о+чередь	1	8	10	17	36
в_поря+дке_веще+й	1	1	1	0	3
глаза+_в_глаза+	0	2	0	0	2
де+нь_в_де+нь	1	0	0	0	1
дру+г__в__дру+ге	0	1	0	1	2
дру+г__в__дру+га	0	1	0	1	2
душа+_в_ду+шу	3	1	0	0	4
из_го+да_в_го+д	1	1	1	1	4

Окончание табл.

1	2	3	4	5	6
изо_дня+_в_де+нь	2	2	1	1	6
из_стороны+_в_сто+рону	0	2	2	1	5
как_ни_в_чё+м_не_быва+ло	8	8	1	0	17
ло+б_в_ло+б	0	0	1	0	1
ни_в_зу+б_ного+й	0	1	0	0	1
ни_в_одно+м_глазу+	1	0	0	0	1
одна+__в__другу+ю	0	1	0	1	2
оди+н_в_друго+й	0	0	0	1	1
сто+л_в_сто+л	1	0	0	0	1
сва+йка_в_сва+йку	0	1	0	0	1
тю+телька_в_тю+тельку	1	0	0	0	1
хво+ст_в_хво+ст	0	0	0	1	1

Задания для самостоятельной работы

1. Ознакомьтесь со статьёй А.В. Венцова, В.Б. Касевича, Е.В. Ягуновой «Об идиомах в Национальном корпусе русского языка», представленной в приложении 7. Что предлагается понимать под идиомами? Какие критерии предлагают авторы статьи для опознания идиом? Каким образом идиомы могут быть представлены в корпусе?

2. Сравните различные подходы к морфологической разметке аналитических форм, описанные в статьях О.Н. Ляшевской, В.А. Плунгяна, Д.В. Сичинавы – с одной стороны, и А.В. Венцова, Е.В. Грудевой – с другой (приложение 7). В чём вы видите сходства и различия? Какие достоинства и недостатки можно обнаружить у каждого из предлагаемых решений?

Список литературы

1. *Баскулина Ю.Н.* Идиоматические сочетания в русском языке: теоретические и прикладные аспекты (на материале Национального корпуса русского литературного языка): Автореф. дис. … канд. филол. наук. СПб., 2008.

2. *Баскулина Ю.Н.* Составные слова и их представление в аннотированных корпусах русского языка // Материалы Всероссийской научной конференции с международным участием «Актуальные проблемы теоретической и прикладной лингвистики и оптимизации преподавания иностранных языков» (Тольятти, октябрь 2005 г.). Тольятти, 2005. С. 61 – 66.

3. *Баскулина Ю.Н.*, *Грудева Е.В.* Составные слова в русском языке и возможные подходы к их изучению // Вестник Череповецкого государственного университета. 2006. № 1. С. 75 – 78.

4. *Венцов А.В.* «Составные слова» и перцептивный словарь // Череповецкие научные чтения – 2009: Материалы Всероссийской научно-практической конференции, посвященной Дню города Череповца (2 – 3 ноября 2009 г.). Ч. 1. Литературоведческие и лингвистические науки в начале XXI в. Череповец: ГОУ ВПО ЧГУ, 2010. С. 44 – 46.

5. *Венцов А.В.*, *Грудева Е.В.* Аналитические формы в Национальном корпусе русского литературного языка // Труды Международной конференции «Корпусная лингвистика – 2006» (10 – 14 октября 2006 г., Санкт-Петербург). СПб., 2006. С. 75 – 80.

6. *Венцов А.В.*, *Касевич В.Б.*, *Ягунова Е.В.* Идиома, слово, фонетическое слово // Язык и речь: проблемы и решения: Сб. науч. трудов к юбилею проф. Л. В. Златоустовой / Под ред. Г.Е. Кедровой и В.В. Потапова. М.: МАКС Пресс, 2004. С. 357 – 363.

7. *Венцов А.В.*, *Касевич В.Б.*, *Ягунова Е.В.* Об идиомах в Национальном корпусе русского языка // Научные чтения – 2003 (Санкт-Петербург, 15 – 17 декабря 2003 г.): Материалы конференции. Приложение к журналу «Язык и речевая деятельность». Т. 5. СПб., 2004. С. 8 – 11.

8. *Венцов А.В.*, *Грудева Е.В.*, *Касевич В.Б.*, *Ягунова Е.В.* Идиомы в Национальном корпусе русского литературного языка // Международная конференция «Корпусная лингвистика – 2004»: Тезисы докладов (12 – 14 октября 2004 г., С.-Петербург). СПб.: Изд-во Санкт-Петербург. ун-та, 2004. С. 17 – 18.

9. *Копотев М.В.*, *Мустайоки А.* К вопросу о статусе эквивалентов слова типа ПОТОМУ ЧТО, В ЗАВИСИМОСТИ ОТ, К СОЖАЛЕНИЮ // Вопросы языкознания. 2004. № 3. С. 88 – 107.

10. *Копотев М.В.* «Несмотря на» «потому что», или Многокомпонентные единицы в аннотированном корпусе русских текстов // Компьютерная лингвистика и интеллектуальные технологии: Труды Междунар. конференции «Диалог-2004» («Верхневолжский», 2 – 7 июня 2004 г.) / Под ред. И.М. Кобозевой и др. М., 2004. С. 335 – 339. URL: http://www.dialog-21.ru/Archive/2004/Kopotev.htm

11. *Ляшевская О.Н.*, *Плунгян В.А.*, *Сичинава Д.В.* О морфологическом стандарте Национального корпуса русского языка // Национальный корпус русского языка: 2003 – 2005. Результаты и перспективы. М., 2005. С. 111 – 135.

Тема 11

МОРФОЛОГИЧЕСКОЕ АННОТИРОВАНИЕ: ПРОБЛЕМЫ И РЕШЕНИЯ

(6 часов)

Понятие морфологического стандарта. Морфологический стандарт в Национальном корпусе русского языка.

Опция «Грамматические признаки» для выбора грамматических параметров поиска в Национальном корпусе русского языка (http://ruscorpora.ru/reqgrm.html)

Часть речи	Падеж	Наклонение / Форма	Степень / Краткость
☐ существительное	☐ именительный	☐ изъявительное	☐ сравнительная
☐ прилагательное	☐ звательный*	☐ повелительное	☐ сравнительная 2*
☐ числительное	☐ родительный	☐ повелительное 2	☐ превосходная
☐ числ-прил	☐ родительный 2	☐ инфинитив	☐ полная форма
☐ глагол	☐ дательный	☐ причастие	☐ краткая форма
☐ наречие	☐ винительный	☐ деепричастие	
☐ предикатив	☐ винительный 2*	**Время**	**Переходность**
☐ вводное слово	☐ творительный	☐ настоящее	☐ переходный*
☐ мест-сущ	☐ предложный	☐ будущее	☐ непереходный*
☐ мест-прил	☐ предложный 2	☐ прошедшее	
☐ мест-предикатив	☐ счётная форма		
☐ местоименное наречие	**Число**	**Лицо**	**Прочее**
☐ предлог	☐ единственное	☐ первое	☐ словарная форма
☐ союз	☐ множественное	☐ второе	☐ цифровая запись
☐ частица		☐ третье	☐ аномальная форма*
☐ междометие			☐ искаженная форма*
Антропонимы	**Род**	**Залог**	☐ несловарная форма**
☐ фамилия	☐ мужской	☐ действительный	☐ инициал*
☐ имя	☐ женский	☐ страдательный	☐ сокращение*
☐ отчество	☐ средний	☐ медиальный	☐ несклоняемое*
	☐ общий*		
	Одушевленность	**Вид**	
	☐ одушевленное	☐ совершенный	
	☐ неодушевленное	☐ несовершенный	

* – только в корпусе со снятой омонимией;
** – только в корпусе с неснятой омонимией

Задания для самостоятельной работы

1. Ознакомьтесь с морфологическим стандартом Национального корпуса русского языка (в приложении 8 представлена статья О.Н. Ляшевской, В.А. Плунгяна, Д.В. Сичинавы на эту тему). Какие принципы положены в основу морфологического стандарта создателями НКРЯ?

Список литературы

1. *Венцов А.В., Грудева Е.В., Касевич В.Б.* Морфологическая проблематика в Национальном корпусе русского литературного языка // Международная конференция «Корпусная лингвистика – 2004»: Тезисы докладов (12 – 14 октября 2004 г., С.-Петербург). СПб.: Изд-во Санкт-Петербург. ун-та, 2004. С. 18 – 20.
2. *Ляшевская О.Н., Плунгян В.А., Сичинава Д.В.* О морфологическом стандарте Национального корпуса русского языка // Национальный корпус русского языка: 2003 – 2005. Результаты и перспективы. М., 2005. С. 111 – 135.
3. *Венцов А.В., Грудева Е.В.* Аналитические формы в Национальном корпусе русского литературного языка // Труды Международной конференции «Корпусная лингвистика – 2006» (10 – 14 октября 2006 г., Санкт-Петербург). СПб., 2006. С. 75 – 80.
4. *Венцов А.В., Грудева Е.В., Касевич В.Б., Сведенцова Е.А., Слепокурова Н.А.* О морфологии в Национальном корпусе русского языка // Материалы XXXIII Международной филологической конференции (15 – 20 марта 2004 г., Санкт-Петербург). Вып. 24. Секция общего языкознания. Ч. 2. СПб.: ОНУТ Филол. ф-та СПбГУ, 2004. С. 3 – 8.

Тема 12
СЕМАНТИЧЕСКАЯ РАЗМЕТКА
(4 часа)

Семантическая разметка: принципы и основания. Связь семантической разметки с разметкой синтаксической и морфологической. Принципы семантической разметки в Национальном корпусе русского языка.

Структура лексико-семантической информации в Национальном корпусе русского языка (www.ruscorpora.ru)

Лексико-семантическая информация, приписываемая произвольному слову в тексте, состоит из трех групп помет:

1. разряд (например, имя собственное, возвратное местоимение);

2. собственно лексико-семантические характеристики (например, тематический класс лексемы, признаки каузативности, оценки);

3. деривационные (словообразовательные) характеристики (например, «диминутив», «отадъективное наречие»).

Лексико-семантическая информация имеет различную структуру для разных частей речи. Кроме того, каждый из разрядов существительных – имена предметные, непредметные и собственные – имеет свою структуру помет.

Собственно лексико-семантические пометы сгруппированы по следующим полям:

1) таксономия (тематический класс лексемы) – для имен существительных, прилагательных, глаголов и наречий;

2) мереология (указание на отношения «часть – целое», «элемент – множество») – для предметных и непредметных имен;

3) топология (топологический статус обозначаемого объекта) – для предметных имен;

4) каузация – для глаголов;

5) служебный статус – для глаголов;

6) оценка – для предметных и непредметных имен, прилагательных и наречий.

Словообразовательные характеристики включают несколько типов:

1) морфо-семантические словообразовательные признаки (например, «диминутив», «каритив», «семельфактив»);

2) разряд производящего слова (например, отглагольное существительное или отадъективное наречие);

3) лексико-семантический (таксономический) тип производящего слова (например, наречие, образованное от прилагательного размера);

4) морфологический тип словообразования (субстантивация, сложное слово).

В основу метаязыка лексико-семантических помет, ввиду предполагаемой широкой международной аудитории пользователей Корпуса, положена система сокращенных помет («тегов») на основе англоязычной нотации. В то же

время предусмотрена возможность использования при поиске традиционных названий категорий на русском языке (в форме «семантические признаки»). Ниже приводится инвентарь всех доступных в настоящее время для поиска в Корпусе семантических помет. Для пояснения в скобках даются примеры.

Имена существительные (*S*)

Разряды

r:concr – предметные имена (*девочка, стол, молоко*)

r:abstr – непредметные имена (*вождение, яркость, время*)

r:propn – имена собственные (*Иван, Эйнштейн, Петроград*)

Предметные имена

Лексико-семантические пометы

Таксономия:

t:hum – лица (*человек, учитель*)

t:hum:etn – этнонимы (*эфиоп, итальянка*)

t:hum:kin – имена родства (*брат, бабушка*)

t:hum:supernat – сверхъестественные существа (*русалка, инопланетянин*)

t:animal – животные (*корова, жираф, сорока, ящерица, муравей*)

t:plant – растения (*береза, роза, трава*)

t:stuff – вещества и материалы (*вода, песок, тесто, жесть, шелк*)

t:space – пространство и место (*космос, город, тайга, овраг, вход*)

t:constr – здания и сооружения (*дом, шалаш, мост*)

t:tool – инструменты и приспособления (*молоток, палка, пуговица, машина*)

t:tool:instr – инструменты (*молоток, штопор, игла, карандаш*)

t:tool:device – механизмы и приборы (*телефон, сеялка, градусник*)

t:tool:transp – транспортные средства (*автобус, поезд, сани*)

t:tool:weapon – оружие (*сабля, пистолет, гаубица*)

t:tool:mus – музыкальные инструменты (*рояль, скрипка, колокол*)

t:tool:furn – мебель (*стол, диван, шкаф*)

t:tool:dish – посуда (*чашка, кастрюля, фляжка*)

t:tool:cloth – одежда и обувь (*платье, шляпа, ботинки*)

t:food – еда и напитки (*пирог, каша, молоко*)

t:text – тексты (*рассказ, книга, афиша*)

Мереология:

pt:part – части (*верхушка, кончик, половина*)

pt:partb & pc:hum – части тела и органы человека (*голова, сердце, ноготь*)

pt:partb & pc:animal – части тела и органы животных (*хвост, жало*)

pt:part & pc:plant – части растений (*лист, ветка, корень*)

pt:part & pc:constr – части зданий и сооружений (*комната, дверь, арка*)

pt:part & pc:tool – части приспособлений (*деталь, лопасть, крышка*)

pt:part & pc:tool:instr – части инструментов (*топорище, лезвие*)

pt:part & pc:tool:device – части механизмов и приборов (*дисплей, корпус, кнопка*)

pt:part & pc:tool:transp – части транспортных средств (*руль, колесо, капот*)

pt:part & pc:tool:weapon – части оружия (*дуло, курок, эфес*)

pt:part & pc:tool:mus – части музыкальных инструментов (*струна, гриф*)

pt:part & pc:tool:furn – части предметов мебели (*сиденье, подлокотник*)

pt:part & pc:tool:dish – части предметов посуды (*носик, горлышко*)

pt:part & pc:tool:cloth – части одежды и обуви (*рукав, каблук*)

pt:qtm – кванты и порции вещества (*капля, комок, порция*)

pt:set | pt:aggr – множества и совокупности объектов (*набор, букет, мебель, человечество*)

hi:class – имена классов (*животное, ягода, инструмент*)

Топология:

top:contain – вместилища (*кошелек, комната, озеро, ниша*)

top:horiz – горизонтальные поверхности (*пол, площадка*)

Оценка:

ev – оценка (неопределенная по признаку «положительная/отрицательная») (*озорник, махина*)

ev:posit – положительная (*умница, светило*)

ev:neg – отрицательная (*негодяй, вертихвостка*)

Словообразовательные пометы

d:dim – диминутивы (*зайчик, коробочка*)

d:aug – аугментативы (*детина, домище*)

d:sing – сингулятивы (*пылинка, изюминка*)

d:nag – nomina agentis (*писатель, создатель, докладчик*)

d:fem – nomina feminina (*немка, генеральша, доярка*)

Непредметные имена

Лексико-семантические пометы

Таксономия (тематический класс):

t:move – движение (*беготня, вынос, качка*)

t:move:body – изменение положения тела, части тела (*поклон*)

t:put – помещение объекта (*размещение, расстановка, погрузка, намотка*)

t:impact – физическое воздействие (*удар, втирание, обмолот*)

t:impact:creat – создание физического объекта (*лепка, отливка, плетение, сооружение, строительство*)

t:impact:destr – уничтожение (*слом, сожжение*)

t:changest – изменение состояния или признака (*укрепление, затвердение, осушение, конденсация, осложнение*)

t:be – бытийная сфера

t:be:exist – существование (*жизнь, наличие, бытие*)

t:be:appear – начало существования (*возникновение, рождение, формирование, учреждение, творение*)

t:be:disapp – прекращение существования (*смерть, казнь, ликвидация*)

t:loc – местонахождение (*местоположение*)

t:loc:body – положение тела в пространстве (*лежание*)

t:contact – контакт и опора (*прикосновение, объятие*)

t:poss – посессивная сфера (*обладание, приобретение, покупка, потеря, лишение*)

t:ment – ментальная сфера (*знание, абстракция, воображение, воспоминание, догадка*)

t:perc – восприятие (*осязание, слух, видимость, взгляд, зрелище*)

t:psych – психическая сфера (*апатия, безумие, вдохновение, спокойствие*)

t:psych:emot – эмоция (*восторг, раскаяние, печаль*)

t:psych:volit – воля (*намерение, решение*)

t:speech – речь (*дискуссия, молва, ахинея, реплика, подковырка*)

t:physiol – физиологическая сфера (*жажда, кровоизлияние, судорога, утомление, икота*)

t:weather – природное явление (*зарница, вьюга, зной*)

t:sound – звук (*шум, перезвон, хлопок, аплодисменты, диссонанс*)

t:color – цвет (*окраска, колорит, желтизна, прозелень*)

t:light – свет (*луч, полумрак, светлынь, иллюминация*)

t:taste – вкус (*вкуснота, горчинка, кислятина*)

t:smell – запах (*аромат, перегар*)

t:temper – температура (*прохлада, стужа, нагрев*)

t:time – время (*весна, годовщина, минута, современность*)

t:time:period – период (*межсезонье, путина, сенокос, стаж*)

t:time:moment – момент (*миг, мгновение*)
t:time:week – день недели (*понедельник*)
t:time:month – месяц (*январь*)
t:time:age – возраст (*детство, молодость, двадцатилетие*)
t:humq – свойство человека (*порядочность, безволие, остроумие*)
t:behav – поведение и поступки человека (*разгильдяйство, подхалимаж, неповиновение, ребячество, предательство*)
t:inter – взаимодействие и взаимоотношение (*взаимопомощь, вражда, схватка, драка*)
t:action – мероприятие (*аукцион, вернисаж, вечеринка, выборы, именины, заседание, культпоход*)
t:disease – болезнь (*ангина, диабет*)
t:game – игра (*жмурки, покер, домино, волейбол*)
t:sport – спорт (*спартакиада, акробатика, баскетбол*)
t:param – параметр (*высота, грузоподъемность*)
t:unit – единица измерения (*балл, килограмм, метр, минута*)

Мереология:
pt:part – часть (*начало, финал*)
pt:qtm – квант (*оборот, прыжок, кивок*)
pt:set – множество (*система, выборка, алгоритм*)

Оценка:
ev – оценка (*озорник, махина*)
ev:posit – положительная (*благоухание, загляденье, изюминка*)
ev:neg – отрицательная (*безвкусица, ахинея*)

Словообразовательные пометы
der:v – отглагольные имена (*выбор, демонстрация*)
der:a – отадъективные имена (*краснота, жадность*)

Имена собственные

Лексико-семантические пометы

Таксономия:
t:hum | t:hum:supernat – лица (*Людмила, Черномор*)
t:persn – имена (*Александр*)
t:patrn – отчества (*Сергеевич*)
t:famn – фамилии (*Пушкин*)

t:topon – топонимы (*Европа, Волга, Эльбрус, Москва, Преображенка*)

Словообразовательные пометы
d:dim – диминутивы (*Саша, Женечка, Николаич*)

Имена прилагательные (*A*)

Разряды
r:qual – качественные (*хороший, большой*)
r:rel – относительные (*деревянный, лунный*)
r:poss – притяжательные (*божий, отцов, мужнин*)
r:invar – неизменяемые (*беж, джерси*)

Лексико-семантические пометы
t:size – размер (*высокий, короткий*)
t:size:max – большой (*высокий, длинный*)
t:size:min – малый (*низкий, короткий*)
t:size:abs – абсолютный (*двухэтажный*)
t:dist – расстояние (*далекий, соседний*)
t:dist:max – большое (*дальний, отдаленный*)
t:dist:min – малое (*близкий, недалекий*)
t:quant – количество (*большой, достаточный, трехкратный*)
t:quant:max – большое (*обильный, многочисленный*)
t:quant:min – малое (*ничтожный, малочисленный*)
t:quant:abs – абсолютное (*двухтысячный, восьмимиллионный*)
t:place – место (*левый, придорожный, теменной*)
t:dir – направление (*обратный, подветренный*)
t:time – время (*прошлый, ночной*)
t:time:dur – длительность (*долгий, краткий*)
t:time:dur:max – большая (*долгий, продолжительный*)
t:time:dur:min – малая (*краткий, кратковременный*)
t:time:dur:abs – абсолютная (*восьмичасовой*)
t:time:age – возраст (*зрелый*)
t:time:age:max – большой (*старый, древний*)
t:time:age:min – малый (*молодой, малолетний*)
t:time:age:abs – абсолютный (*трехлетний*)
t:speed – скорость (*проворный*)
t:speed:max – большая (*скорый, быстрый*)
t:speed:min – малая (*медленный, тягучий*)
t:physq – физические свойства (*мягкий, вязкий*)

t:physq:form – форма (*кривой, круглый*)
t:physq:color – цвет (*красный, бесцветный*)
t:physq:taste – вкус (*кислый, приторный*)
t:physq:smell – запах (*ароматный, тухлый*)
t:physq:temper – температура (*горячий, ледяной*)
t:physq:weight – вес (*тяжелый, легкий*)
t:humq – качества человека (*умный, верный, ловкий*)

Оценка:
ev – оценка (*толковый, мешковатый*)
ev:posit – положительная (*везучий, ладный*)
ev:neg – отрицательная (*продажный, сварливый*)

Словообразовательные пометы
d:dim – диминутивы (*тихонький, крохотный*)
d:aug – аугментативы (*здоровенный, злющий*)
d:atten – аттенуативы (*угловатый, жуликоватый*)
d:habit – хабитивы (*глазастый, пузатый*)
d:carit – каритивы (*безглазый, бездыханный*)
d:potent | d:impot – потенциальные (*плавучий, недееспособный*)
d:potent – поссибилитивы (*плавучий, плодородный, занимательный*)
d:impot – импоссибилитивы (*несоизмеримый, недееспособный*)
der:s – отыменные прилагательные (*домашний, железный*)
der:v – отглагольные прилагательные (*ковкий, навязчивый, кочевой*)
der:adv – отадвербиальные прилагательные (*поздний, здешний*)

Имена числительные (*NUM, A-NUM*)

Разряды
r:card – количественные (*два, пять, десять*)
r:card:pauc – числительные малого количества (*два, три, четыре, оба, пол, полтора*)
r:ord – порядковые (*первый, второй, десятый*)

Местоимения, в том числе:
S-PRO – местоимения-существительные (*он, кто*)
A-PRO – местоимения-прилагательные (*его, какой*)
ADV-PRO – местоимения-наречия (*где, как*)

Разряды
r:pers – личные (*я, он*)

r:ref – возвратные (*себя*)
r:poss – притяжательные (*мой, его, свой*)
r:rel – вопросительные/относительные (*кто, который, когда*)
r:dem – указательные (*этот, такой*)
r:indet – неопределенные (*некоторый, некогда*)
r:neg – отрицательные (*никакой, ничей*)
r:spec – кванторные (определительные) (*всякий, каждый, любой*)

Глаголы (*V*)

Лексико-семантические пометы

t:move – движение (*бежать, дергаться, бросить, нести*)

t:move:body – изменение положения тела, части тела (*согнуть, нагнуться, примоститься*)

t:put – помещение объекта (*положить, вложить, спрятать*)

t:impact – физическое воздействие (*бить, колоть, вытирать*)

t:impact:creat – создание физического объекта (*выковать, смастерить, сшить*)

t:impact:destr – уничтожение (*взорвать, сжечь, зарезать*)

t:changest – изменение состояния или признака (*взрослеть, богатеть, расширить, испачкать*)

t:be – бытийная сфера (*жить, возникнуть, убить*)

t:be:exist – существование (*жить, происходить*)

t:be:appear – начало существования (*возникнуть, родиться, сформировать, создать*)

t:be:disapp – прекращение существования (*умереть, убить, улетучиться, ликвидировать, искоренить*)

t:loc – местонахождение (*лежать, стоять, положить*)

t:loc:body – положение тела в пространстве (*сидеть*)

t:contact – контакт и опора (*касаться, обнимать, облокотиться*)

t:poss – посессивная сфера (*иметь, дать, подарить, приобрести, лишиться*)

t:ment – ментальная сфера (*знать, верить, догадаться, помнить, считать*)

t:perc – восприятие (*смотреть, слышать, нюхать, чуять*)

t:psych – психическая сфера (*гипнотизировать, сочувствовать, настроиться, терпеть*)

t:psych:emot – эмоция (*радоваться, обидеть*)

t:psych:volit – воля (*решить*)

t:speech – речь (*говорить, советовать, спорить, каламбурить*)

t:behav – поведение человека (*куролесить, привередничать*)
t:physiol – физиологическая сфера (*кашлять, икать*)
t:weather – природное явление (*бушевать, вьюжить*)
t:sound – звук (*гудеть, шелестеть*)
t:light – свет (*гаснуть, лучиться*)
t:smell – запах (*пахнуть, благоухать*)

Каузация:
ca:caus – каузативные глаголы (*показать, вертеть*)
ca:noncaus – некаузативные глаголы (*видеть, вертеться*)

Служебные глаголы:
aux:phase – фазовые (*начать, продолжать, прекратить*)
aux:caus – служебные каузативные (*вызвать, привести (к)*)

Словообразовательные пометы
d:pref – приставочные глаголы (*забегать, оглядеть*)
d:semelf – семельфактивы (*кивнуть, чихнуть, боднуть, качнуться*)
d:impf – вторичные имперфективы (-ива-, -ва-, -а-) (*выпивать, вбивать, прогонять*)

Наречия (*ADV*)

Лексико-семантические пометы
t:place – место (*здесь, посередине*)
t:dir – направление (*туда, наверх*)
t:dist – расстояние (*далеко, близко*)
t:dist:max – большое (*далеко, вдали, вдалеке*)
t:dist:min – малое (*близко, вблизи*)
t:time – время (*тогда, поздно*)
t:time:dur – длительность (*вечно, недолго*)
t:time:dur:max – большая (*вечно, подолгу, всегда*)
t:time:dur:min – малая (*временно, недолго*)
t:speed – скорость (*быстро, медленно*)
t:speed:max – большая (*быстро, мигом*)
t:speed:min – малая (*медленно, неторопливо*)
t:quant – количество (*столько, достаточно*)
t:quant:max – большое (*много, навалом*)

t:quant:min – малое (*мало, чуть-чуть*)

Оценка:
ev – оценка (*беспечно, бойко*)
ev:posit – положительная (*бойко, безупречно*)
ev:neg – отрицательная (*бездарно, неловко*)

Словообразовательные пометы
d:dim – диминутивы (*немножко, быстренько*)
d:atten – аттенуативы (*рановато, суховато*)
der:s – отыменные наречия (*вверху, дома*)
der:v – отглагольные наречия (*отродясь, стоймя*)
der:a – отадъективные наречия (*быстро, обычно*)

Таксономия производящего слова-прилагательного
der:a & dt:size – размер (*высоко, коротко*)
der:a & dt:size:max – большой (*высоко, бесконечно*)
der:a & dt:size:min – малый (*коротко, низко*)
der:a & dt:physq – физические свойства (*твердо, плотно*)
der:a & dt:physq:form – форма (*плоско, прямо*)
der:a & dt:physq:color – цвет (*красно, добела*)
der:a & dt:physq:taste – вкус (*горько, вкусно*)
der:a & dt:physq:smell – запах (*смрадно, зловонно*)
der:a & dt:physq:temper – температура (*тепло, прохладно*)
der:a & dt:physq:weight – вес (*тяжело, легко*)
der:a & dt:humq – качества человека (*внимательно, грубо*)

Задания для самостоятельной работы

Ознакомьтесь с фрагментом статьи Г.И. Кустовой, О.Н. Ляшевской, Е.В. Падучевой, Е.В. Рахилиной «Семантическая разметка лексики в Национальном корпусе русского языка: принципы, проблемы, перспективы» (приложение 9) и ответьте на следующие вопросы:

а) какие задачи могут быть решены с помощью семантически размеченного корпуса;

б) как связана в НКРЯ семантическая разметка с разметкой морфологической;

в) опираясь на материалы статьи, а также на представленную выше структуру лексико-семантической информации в Национальном корпусе русского языка, охарактеризуйте основные принципы семантической разметки в НКРЯ.

Список литературы

1. *Апресян Ю.Д., Богуславский И.М., Иомдин Б.Л.* и др. Синтаксически и семантически аннотированный корпус русского языка: современное состояние и перспективы // Национальный корпус русского языка: 2003 – 2005. М.: Индрик, 2005.

2. *Кретов А.А.* Анализ семантических помет в НКРЯ // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы. СПб.: Нестор-История, 2009. С. 240 – 257.

3. *Кустова Г.И., Ляшевская О.Н., Падучева Е.В., Рахилина Е.В.* Национальный корпус русского языка как инструмент семантико-грамматического исследования лексики // Международная конференция «Корпусная лингвистика – 2004»: Тезисы докладов. СПб.: СПбГУ, 2004. С. 50 – 51.

4. *Кустова Г.И., Ляшевская О.Н., Падучева Е.В., Рахилина Е.В.* Опыт семантического расширения морфологической разметки: таксономическая классификация лексики в Национальном корпусе русского языка // Научная и техническая информация. Сер. 2. Информационные процессы и системы. 2005. № 6.

5. *Кустова Г.И., Ляшевская О.Н., Падучева Е.В., Рахилина Е.В.* Семантическая разметка лексики в Национальном корпусе русского языка: принципы, проблемы, перспективы // Национальный корпус русского языка: 2003 – 2005. Результаты и перспективы. М., 2005. С. 155 – 174.

6. *Рахилина Е.В., Кобрицов Б.П., Кустова Г.И., Ляшевская О.Н., Шеманаева О.Ю.* Многозначность как прикладная проблема: лексико-семантическая разметка в Национальном корпусе русского языка // Компьютерная лингвистика и интеллектуальные технологии: Труды Международной конференции «Диалог-2006» (Бекасово, 31 мая – 4 июня 2006 г.) / Под ред. Н.И. Лауфер, А.С. Нариньяни, В.П. Селегея. М.: Изд-во РГГУ, 2006.

7. *Рахилина Е.В., Кустова Г.И., Ляшевская О.Н., Резникова Т.И., Шеманаева О.Ю.* Задачи и принципы семантической разметки лексики в НКРЯ // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы. СПб.: Нестор-История, 2009. С. 215 – 239.

Тема 13

СИНТАКСИЧЕСКАЯ РАЗМЕТКА

(4 часа)

Виды синтаксической разметки. Связь синтаксической разметки с разметкой морфологической. Принципы синтаксической разметки Национального корпуса русского языка. Принципы синтаксической разметки Хельсинкского аннотированного корпуса русского языка (ХАНКО). Проблема синтаксических нулей.

Синтаксическая разметка описывает синтаксические связи между лексическими единицами и различные синтаксические конструкции (например, придаточное предложение, глагольное словосочетание и т.п.).

Синтаксическая разметка является результатом синтаксического анализа, или парсинга (англ. parsing). Обычно парсинг выполняется на основе данных морфологического анализа.

Список литературы

1. *Апресян Ю.Д., Богуславский И.М., Иомдин Б.Л.* и др. Синтаксически и семантически аннотированный корпус русского языка: современное состояние и перспективы // Национальный корпус русского языка: 2003 – 2005. М.: Индрик, 2005.

2. *Копотев М.В., Гурин Г.Б.* Принципы синтаксической разметки Хельсинкского аннотированного корпуса русских текстов ХАНКО // Компьютерная лингвистика и интеллектуальные технологии: Труды Международной конференции «Диалог-2006». М.: РГГУ, 2006. С. 280 – 284.

3. *Копотев М.В., Гурин Г.Б.* Разметка синтаксической неполноты в корпусе // Компьютерная лингвистика и интеллектуальные технологии: Труды Международной конференции «Диалог-2007». М.: РГГУ, 2007. С. 307 – 309.

4. *Копотев М.В., Гурин Г.Б.* Принеси то, не знаю что: представление и поиск синтаксических нулевых знаков и смежных явлений в аннотированном корпусе // Труды Международной конференции «Корпусная лингвистика – 2006». СПб.: СПГУ, 2006. С. 166 – 173.

5. *Недолужко А., Гаич Я.* и др. Синтаксически аннотированный корпус чешского языка // Компьютерная лингвистика и интеллектуальные технологии: По материалам ежегодной Международной конференции «Диалог» (Бекасово, 4 – 8 июня 2008 г.). Вып. 7 (14). М.: РГГУ, 2008. С. 400 – 406.

6. *Чардин И.С.* Лингвистические корпуса с синтаксической разметкой и их применение // Научно-техническая информация. Сер. 2. 2003. № 6. С. 18 – 24.

Задания для самостоятельной работы

1. Ознакомьтесь со статьёй М.В. Копотева и Г.Б. Гурина «Принципы синтаксической разметки Хельсинкского аннотированного корпуса русских текстов ХАНКО» (приложение 10) и ответьте на следующие вопросы: а) какие три теории называют авторы статьи, считая их достаточными для полного описания русского синтаксиса; б) почему выбор синтаксической теории, которая удовлетворяла бы «постулату теоретической нейтральности», применительно к описанию русского языка представляется авторам статьи затруднительным?

2. Назовите и кратко прокомментируйте принятые разработчиками ХАНКО решения в области синтаксической разметки русских текстов. С какими трудностями столкнулись разработчики корпуса?

Тема 14
СЛОВАРИ, СОЗДАННЫЕ НА БАЗЕ КОРПУСА
(6 часов)

Традиционные словари, созданные на базе корпуса. Электронные словари, созданные на базе корпуса. Частотные словари разного типа: с входной единицей – лексемой, с входной единицей – словоформой. Словарь омографов русского языка. Частотный словарь словоформ русского языка. Электронные словари, созданные на базе Национального корпуса русского языка.

Список литературы

1. *Венцов А.В.*, *Грудева Е.В.* Акцентно размеченный Корпус русского литературного языка как источник новых словарей («Словарь омографов русского языка» и «Частотный словарь словоформ русского языка») // Проблемы истории, филологии, культуры. 2009. Т. 24. № 2. С. 631 – 635.

2. *Венцов А.В.*, *Грудева Е.В.* К вопросу о создании частотного словаря словоформ русского языка // Русская языковая личность: Материалы шестой выездной школы-семинара. Череповец: ГОУ ВПО ЧГУ, 2007. С. 70 – 80.

3. *Венцов А.В.*, *Грудева Е.В.*, *Касевич В.Б.*, *Корешкова Е.И.*, *Сведенцова Е.А.*, *Ягунова Е.В.* Словарь омографов русского языка. СПб.: Филол. ф-т СПбГУ, 2004.

4. *Венцов А.В.*, *Касевич В.Б.*, *Сведенцова Е.А.* Омография, омофония и восприятие речи // Человек пишущий и читающий: проблемы и наблюдения: Материалы Междунар. конф. (14 – 16 марта 2002 г., С.-Петербург). СПб.: Изд-во С.-Петербург. ун-та, 2004. С. 182 – 189.

5. *Ляшевская О.Н.* О частотном словаре Национального корпуса русского языка // Слово и словарь = Vocabulum et vocabularium: Сб. науч. тр. по лексикографии. Гродно: ГрГУ, 2007.

6. *Ляшевская О.Н.*, *Шаров С.А.* Частотный словарь национального корпуса русского языка: концепция и технология создания // Компьютерная лингвистика и интеллектуальные технологии: По материалам ежегодной Международной конференции «Диалог» (Бекасово, 4 – 8 июня 2008 г.). Вып. 7 (14). М.: РГГУ, 2008. С. 345 – 351.

Традиционные частотные словари русского языка, созданные на базе корпуса текстов

1. *Венцов А.В.*, *Грудева Е.В.* Частотный словарь словоформ русского языка (проект). Череповец: Изд-во ЧГУ, 2008. URL: http://www.narusco.ru/STAT004/

2. *Засорина Л.Н.* (ред.). Частотный словарь русского языка. М., 1977.

3. *Лённгрен Л.* (ред.). Частотный словарь современного русского языка. Uppsala, 1993.

4. *Штейнфельдт Э.А.* Частотный словарь современного русского литературного языка. Таллин, 1963.

Электронные словари, созданные на базе Национального корпуса русского языка (www.ruscorpora.ru)

1. *Гришина Е.А., Ляшевская О.Н.* Грамматический словарь новых слов русского языка. URL: http://dict.ruslang.ru/gram.php

2. *Ляшевская О.Н., Шаров С.А.* Новый частотный словарь русской лексики. URL: http://dict.ruslang.ru/freq.php

3. *Кустова Г.И.* Словарь русской идиоматики. Сочетания слов со значением высокой степени. URL: http://dict.ruslang.ru/magn.php

4. *Бирюк О.Л., Гусев В.Ю., Калинина Е.Ю.* Словарь глагольной сочетаемости непредметных имён русского языка. URL: http://dict.ruslang.ru/abstr_noun.php

Задания для самостоятельной работы

1. Ознакомьтесь со статьёй А.В. Венцова, Е.В. Грудевой «Акцентно размеченный Корпус русского литературного языка как источник новых словарей ("Словарь омографов русского языка" и "Частотный словарь словоформ русского языка")» (приложение 11). Какие новые лексикографические возможности были открыты благодаря созданию акцентно размеченного корпуса? Почему исследователи недооценивали роль омографии в русском языке?

2. Ознакомьтесь с введением к «Частотному словарю словоформ русского языка» А.В. Венцова, Е.В. Грудевой (приложение 11). В чём принципиальное отличие данного словаря от традиционных частотных словарей? За счёт чего стало возможным получить частотный словарь словоформ? Какие задачи могут быть решены путём обращения к частотному словарю словоформ?

3. Прочитайте вводную статью Г.И. Кустовой к электронному «Словарю русской идиоматики: сочетание слов со значением высокой степени» (приложение 11). По возможности ознакомьтесь с самим словарём на сайте http://dict.ruslang.ru. Попытайтесь объяснить, на каких принципах построен данный словарь? Какие преимущества даёт электронная форма словаря и его прямая (on-line) связь с Национальным корпусом русского языка?

Тема 15

ВОЗМОЖНЫЕ ЗАДАЧИ И СПОСОБЫ ИХ РЕШЕНИЯ ПУТЕМ ОБРАЩЕНИЯ К ИМЕЮЩИМСЯ ЭЛЕКТРОННЫМ ЯЗЫКОВЫМ РЕСУРСАМ (КОРПУСАМ)

(4 часа)

Использование корпусных методов в лингвистике. Применение корпуса в филологических и текстологических исследованиях. Корпусная лингвистика и социолингвистические изыскания. Использование корпусов в практике преподавания языка. Корпус и судебно-лингвистическая экспертиза.

Список литературы

1. *Добровольский Д.О.* Корпус параллельных текстов в исследовании культурно-специфичной лексики // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 383 – 400.

2. *Добровольский Д.О., Кретов А.А., Шаров С.А.* Корпус параллельных текстов: архитектура и возможности использования // Национальный корпус русского языка: 2003 – 2005. М.: Индрик, 2005. С. 263 – 296.

3. *Добрушина Н.Р.* Корпусные методики обучения русскому языку // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 335 – 351.

4. *Кронгауз М.А.* Методы семантики // Кронгауз М.А. Семантика. М., 2001. С. 92 – 103.

5. *Копотев М.В., Мустайоки А.* Современная корпусная русистика // Slavica Helsingiensia 34. Инструментарий русистики: корпусные подходы / Под ред. А. Мустайоки, М.В. Копотева, Л.А. Бирюлина, Е.Ю. Протасовой. Хельсинки, 2008.

6. *Савчук С.О., Сичинава Д.В.* Обучающий корпус русского языка и его использование в преподавательской практике // Национальный корпус русского языка: 2006 – 2008. Новые результаты и перспективы / Отв. ред. В.А. Плунгян. СПб.: Нестор-История, 2009. С. 317 – 334

Задания для самостоятельной работы

1. Ознакомьтесь с разделом «Источник и оценка языкового материала» из книги М.А. Кронгауза «Семантика» (приложение 12) и постарайтесь ответить на следующие вопросы: а) в какую группу методов сбора языкового материала и его оценки включает автор корпусный анализ и почему; б) какой тезис М.А. Кронгауз считает самым сильным и одновременно самым слабым местом в корпусном анализе и почему; в) какой подход к сбору и оценке языкового материала видится автору оптимальным; г) каково место корпусного анализа в этом подходе?

2. Ознакомьтесь с разделом «Корпусная лингвистика: сферы применения» из работы М.В. Копотева и А. Мустайоки «Современная корпусная русистика» (приложение 12). Постарайтесь кратко охарактеризовать круг задач, которые могут решаться и решаются с помощью корпусной лингвистики, по мысли авторов статьи. На какие черты, свойственные в целом корпусным методам, указывают авторы?

3. Ознакомьтесь со статьёй Д.О. Добровольского, А.А. Кретова, С.А. Шарова «Корпус параллельных текстов: архитектура и возможности использования» (приложение 12). В каких сферах и с какими целями может быть использован корпус параллельных текстов? Дайте развёрнутую характеристику филологическим направлениям, заинтересованным в результатах, предоставляемых корпусом параллельных текстов.

ГЛОССАРИЙ[3]

Автоматическая разметка – то же, что автоматическое аннотирование.

Автоматическое аннотирование – приписывание единицам и структурам текста некоторой лингвистической информации, которое происходит с помощью специально созданных программ.

Акцентная разметка – разметка текстов, связанная с простановкой словесных ударений.

Аннотирование текста – сообщение определённой дополнительной информации о тексте, которое реализуется посредством разметки в соответствии с определённой концепцией или теорией.

Аннотированный корпус – корпус, в котором специалистами внесена некоторая лингвистическая информация, что позволяет работать с языковым материалом, быстро осуществляя необходимый поиск по заданным параметрам.

Брауновский корпус – считается первым большим языковым корпусом. Создан в американском университете Брауна в 1960-е годы. Содержал 500 фрагментов текстов по 2 тысячи слов в каждом, которые были опубликованы на английском языке в США в 1961 году. Брауновский корпус задал стандарт в 1 млн словоупотреблений для создания представительных корпусов на других языках.

Британский национальный корпус – корпус английских текстов объёмом более 100 млн словоупотреблений. В корпусе прове-

[3] При составлении глоссария использовались: (1) Англо-русский словарь по лингвистике и семиотике. Около 9000 терминов. Изд-е 2-е, испр. и доп. / А.Н. Баранов, Д.О. Добровольский, М.Н. Михайлов и др.; Под ред. А.Н. Баранова и Д.О. Добровольского. М.: Азбуковник, 2001; (2) Захаров В.П. Корпусная лингвистика. СПб., 2005.

дена лемматизация. Британский национальный корпус во многом является эталоном для создания других национальных корпусов.

Веб-пространство (Web) – информационное наполнение сети Интернет.

Выравнивание параллельного текста – идентификация соответствующих друг другу предложений в обеих половинах параллельного текста.

«Докорпусная» эпоха – образная номинация длительного периода в лингвистике, когда собирать языковой материал приходилось традиционным способом (без обращения к автоматизированным системам) – путём прочитывания многих текстов и создания вручную картотеки языковых фактов, что занимало много времени и сил.

Конкорданс – список всех употреблений данного слова в контексте со ссылками на источник.

Корпус параллельных текстов – корпус текстов на двух или более языках.

Корпус текстов – вид корпуса данных, единицами которого являются тексты или их достаточно значительные фрагменты, включающие, например, какие-то полные фрагменты макроструктуры текстов определённой проблемной области.

Корпус-менеджер (англ. corpus manager) – специализированная поисковая система, включающая программные средства для поиска данных в корпусе, получения статистической информации и предоставления результатов пользователю в удобной форме.

Корпусная лингвистика – раздел прикладной лингвистики, связанный с разработкой общих принципов построения и использо-

вания лингвистических корпусов (корпусов текстов) с использованием компьютерных технологий.

Лемма – «аналог» лексемы, результат автоматического сведения текстоформ к начальной форме.

Лемматизатор (lemmatizing program) – программа, восстанавливающая словарную форму слова по его словоформе.

Лемматизация (lemmatization) – процедура восстановления словарной формы слова по его словоформе. Часто используется в конкордансных программах для упрощения построения поискового запроса, а также для получения лемматизированных словников.

Метаразметка (метаописание) – приписывание тексту атрибутов, характеризующих обстоятельства его создания, автора, тематику, жанровые особенности и т.п.

Параллельный корпус (англ. parallel corpora) – большие собрания параллельных текстов.

Параллельный текст (битекст) – текст на одном языке вместе с его переводом на другой язык.

Парсер (parser) – компьютерная программа, осуществляющая приписывание предложению синтаксической структуры, а также алгоритм такой программы. Термин иногда используется и по отношению к программам морфологического и фонетического анализа.

Парсинг (parsing) – автоматический грамматический анализ, переводящий выражения языка-объекта в выражения метаязыка описания – внутреннего языка блока анализа.

Разметка (англ. tagging, annotation) заключается в приписывании текстам и их компонентам специальных меток (англ. tag, tags). В англоязычной литературе термин *tagging* обычно обозначает грамматическую разметку.

Тэггирование, тэггинг (англ. tagging) – грамматическое аннотирование, грамматическая разметка. Например, в компьютерном корпусе текстов. Выполняется в автоматическом, полуавтоматическом (интерактивном) или ручном режиме. Чаще всего с помощью специальных меток указывается грамматическая форма каждого слова, однако нередко выполняется и более сложная разметка – фонетическая, синтаксическая и даже семантическая.

Текстоформа – «аналог» словоформы в компьютерной лингвистике; на практике часто понимается как единица от пробела до пробела.

Токенизация – разбиение на орфографические слова. Считается обязательным этапом при первичной разметке текстов любого корпуса.

Упсальский корпус – первый корпус русского языка, объёмом 1 млн словоупотреблений, созданный в Упсальском университете (Швеция).

Частотный словарь – словарь, частотные статьи которого упорядочены по частоте встречаемости слова, или словарь, содержащий информацию о частотности употребления лексических единиц.

Языковой корпус (то же **лингвистический корпус**) – совокупность текстов, собранных в соответствии с определёнными принципами, размеченных по определённому стандарту и обеспеченных специализированной поисковой системой.

ПРИЛОЖЕНИЯ

Приложение 1

Тема 1

КОРПУСНАЯ ЛИНГВИСТИКА: ОБЪЕКТ, ПРЕДМЕТ, МЕТОД

А.В. Венцов, Е.В. Грудева, В.Б. Касевич, Е.В. Ягунова

Национальный корпус русского литературного языка: некоторые результаты, приложения и задачи

«ВВЕДЕНИЕ И ЗАДАЧИ

Ситуация в области корпусной лингвистики – в которой теперь существует и русская «подобласть» – развивается достаточно бурно и в то же время не без определенных внутренних противоречий. С одной стороны, известен ответ Н. Хомского на вопрос интервьюера о том, как Хомский относится к корпусной лингвистике: «Таковой не существует». Реакция Хомского имеет под собой основания. Корпусную лингвистику можно считать усовершенствованной методикой сбора и обработки материала – традиционного «расписывания» текстов с последующим использованием как-то организованной картотеки для извлечения из «примеров» грамматической, лексикографической и иной информации, для проверки выдвинутых лингвистических гипотез и т.п.[1] Если это так, то говорить об особой корпусной лингвистике действительно не приходится; ведь не говорят же, кажется, в энтомологии о специальных теориях высушивания или накалывания бабочек.

С другой стороны, имеются работы, авторы которых обсуждают *прикладные* аспекты корпусной лингвистики, из чего логически должно следовать допущение о существовании *теоретической* корпусной лингвистики, т.е. дисциплины, обладающей собственным предметом, методом и теорией. Главное, конечно, – это именно последнее: реалистичность появления собственной теории корпусной лингвистики. Пока она очевидным образом отсутствует, хотя в принципе нельзя отрицать возможности разработки теории, ко-

[1] Мы отвлекаемся от того (на самом деле важного) обстоятельства, что даже технически корпус – не просто компьютеризованная картотека: опираясь на возможности компьютера, создатель корпуса не ограничивается извлечением и фиксацией отдельных предложений с указанием минимального контекста, но вводит в корпус целостные тексты и их обширные фрагменты.

торая отвечала бы на вопросы о том, как обеспечить репрезентативность корпуса, каким образом должно отражаться в корпусе соотношение синхронии и диахронии и т.п. Достаточно ли этого для признания корпусной лингвистики самостоятельной областью теоретического знания, пока не ясно. <…>»

(*Венцов А.В., Грудева Е.В., Касевич В.Б., Ягунова Е.В. Национальный корпус русского литературного языка: некоторые результаты, приложения и задачи // Научно-техническая информация. Сер. 2. 2005. № 6. С. 35*).

С.А. Шаров

Представительный корпус русского языка в контексте мирового опыта

«1. ВВЕДЕНИЕ

Исследования в области корпусной лингвистики обычно решают сразу две задачи: создание рабочих инструментов и использование этих инструментов для изучения лингвистических феноменов. При этом рабочие инструменты чаще всего предполагают более или менее конкретные лингвистические феномены, которые планируется изучить, а интересы исследователя связаны с возможностями, предоставляемыми рабочими инструментами. Впрочем, подобное взаимопроникновение, можно даже сказать симбиоз, доступных технологий и интересов исследователя характерен для многих областей науки.

Создание рабочих инструментов для анализа включает построение моно- и многоязыковых корпусов текстов в рамках области, интересующей исследователя, а также средства разметки корпусов, поиска в них и статистической обработки результатов поиска. Эти ресурсы используются в собственно лингвистических исследованиях, предполагающих анализ языка с экспериментальной точки зрения, т.е. исследование того, какие слова, выражения, грамматические конструкции, типы развития дискурса действительно употребляются носителями языка, как часто и для каких целей.

В настоящее время огромное количество текстов доступно в электронной форме, поэтому часто приходится слышать, что для русского языка собрано множество корпусов, которые используются в лингвистических исследованиях. Эта позиция предполагает, что корпусом является произвольная коллекция текстов по определённой тематике, которые доступны в электронной форме. Назовём такое употребление корпус$_1$. Более рестриктивной является позиция, в соответствии с которой корпус (корпус$_2$) – это коллекция текстов,

собранная в соответствии с явно сформулированными принципами и возможно размеченная (annotated) на некотором уровне лингвистического анализа. Это определение соответствует коллекциям текстов, собранным в Машинном фонде русского языка. Однако в современных исследованиях в области корпусной лингвистики… под корпусом (корпус$_3$) часто понимается *представительная* коллекция текстов в смысле корпус$_2$, т.е. корпус$_3$, имеющий конечный размер, который может адекватно служить представителем потенциально бесконечного множества текстов некоторого фиксированного типа в некотором диахроническом срезе. Употребляя слово *корпус* ниже, мы всегда имеем в виду корпус$_3$.

Представительность, в частности, предполагает, что коллекция текстов сбалансирована в отношении жанров и функциональных стилей и что она имеет достаточные размер и выборку по числу текстов и авторов, чтобы служить основной для статистически достоверных исследований лингвистических феноменов в текстах соответствующей тематики. <…>»

(*Шаров С.А. Представительный корпус русского языка в контексте мирового опыта // Научно-техническая информация. Сер. 2. 2003. № 6. С. 9*).

В.А. Плунгян

Зачем нужен Национальный корпус русского языка?
Неформальное введение

«<…>

Кому и зачем может быть нужен… корпус?

<…> Прежде всего, корпус нужен – даже не просто нужен, а необходим – профессиональным лингвистам, тем, кто так или иначе имеет дело с фактами языка, а значит, должен эти факты собирать и систематизировать. Для лингвистов корпус – как минимум неоценимый инструмент, сокращающий затраты времени на техническую работу. На самом деле, конечно, корпус – нечто большее, чем просто техническое подспорье. Это фактически справочно-информационная система по современному русскому языку, позволяющая получать ответы на самые неожиданные вопросы. Более того, позволяющая ставить новые проблемы, которых лингвистика прошлого почти не касалась.

Несколько частных примеров, взятых из недавней исследовательской практики – моей или моих коллег. Вот на какие вопросы лингвист может ответить с помощью Корпуса буквально за считанные минуты.

1) В русском языке есть глагол несовершенного вида *реагировать*. Его коррелятами совершенного вида могут быть несколько разных приставочных

глаголов: *прореагировать, отреагировать, среагировать* (явление нередкое, особенно среди заимствований). Какой из этих приставочных коррелятов употребляется чаще? К каким контекстам тяготеет каждый из этих приставочных коррелятов (например, какой из них охотнее сочетается с наречием *быстро*)? Наконец, в какой последовательности они появляются в современном языке – одновременно или по очереди? Различается ли частота их употребления в разные периоды?

2) В русском языке у части существительных мужского рода в парадигме единственного числа имеется особая дополнительная падежная форма – так называемый «второй родительный» падеж. Так, у слова *сахар* обычная форма родительного падежа выглядит как *сахара*, а форма второго родительного – как *сахару* (например, в контекстах типа *положите себе еще сахару*). Эта форма проникла в русское склонение в XVI – XVII веках, пережила «пик» употребительности в XVII – XVIII веках, а к концу XIX века стала медленно угасать. В современном языке второй родительный встречается только примерно у сотни слов – правда, очень употребительных – и обычно может быть заменен на простой родительный (так, можно сказать и *положите себе еще сахара*, разница почти неощутима говорящими). Новые заимствования уже много десятилетий не принимают формы второго родительного падежа. Можно посмотреть, с какой частотой употребляются у разных слов – и у разных авторов – формы второго родительного. Например, как сейчас предпочитают писать – *поднять с пола* или *поднять с полу*? А *встать – с пола* или *с полу*?

Совершенно ясно, что число таких примеров можно многократно увеличить, а задачи – усложнить. Но я нарочно привел примеры самых «обыденных» задач, встающих перед исследователями русского языка, чтобы показать, насколько Корпус технически сокращает и революционизирует работу с материалом даже и в этих случаях, позволяя простым нажатием кнопки получить данные, на сбор которых в иной ситуации потребовались бы месяцы (если не годы).

<…>

Но, может быть, корпус – это изобретение ценное, однако интересное только узким профессионалам? Может ли корпус быть интересен кому-то еще, кроме лингвистов?

Безусловно, может – так же, как далеко не только лингвисты пользуются словарями и грамматиками.

Но сначала скажу о тех, кому давно уже не приходится специально рассказывать о преимуществах корпуса. Это – программисты, работающие в области автоматической обработки текстов (в том числе и различного рода поисковых систем). Поскольку программы такого рода имеют дело с естественным языком, они должны в той или иной степени «понимать» структуру тек-

стов, написанных на этом языке. Причем – внимание! – понимать структуру именно тех текстов, которые встречаются в реальной жизни, а не идеализированную структуру языка в том виде, как она описана в академических и тем более школьных грамматиках. Из сказанного ясно, что программисты, может быть, как никакие другие профессионалы (не считая лингвистов, конечно) заинтересованы в том, чтобы корпуса, отражающие подлинное и максимально разнообразное языковое употребление, так сказать, неприглаженную языковую стихию, создавались и развивались. Не случайно проект создания Национального корпуса русского языка уже на самых ранних этапах был поддержан компанией «Яндекс» (крупнейший российский портал, разработавший одну из самых быстрых и эффективных поисковых программ по русскому сегменту Интернета), и в целом вне лингвистики наибольшее внимание к Корпусу проявляли и проявляют специалисты по информатике и программированию. Сотрудничество с программистами компании «Яндекс» оказалось очень плодотворным: при их непосредственной технической поддержке и был создан сайт, на котором размещен Национальный корпус русского языка в его нынешнем виде.

Разумеется, и программисты далеко не исчерпывают «целевую аудиторию» корпуса. Следующая по важности группа пользователей – это, наверное, те, кто так или иначе имеет дело с преподаванием современного русского языка, причем не только – и, может быть, даже не столько – в качестве родного, сколько в качестве иностранного.

Конечно, и в российской школе – в том числе и в высшей – Корпус может быть полезен для преподавателей и учащихся... Например, именно в Корпусе можно быстро и легко найти пример на редкое слово или грамматическую конструкцию, проверить написание или употребление интересующих единиц и т.п. (Следует, правда, при этом помнить, что Корпус – не нормативное пособие, язык там отражается не таким, каким он *должен быть* с точки зрения авторов описаний, а таким, каким он на самом деле *является*. С точки зрения школьной грамматики кое-что из того, что встречается в Корпусе, будет квалифицировано как «отступление» от нормы. Впрочем, Корпус организован так, что учитель и его ученики имеют все возможности составить собственный подкорпус из образцовых с точки зрения языка произведений и пользоваться именно им).

Но многократно возрастает значимость Корпуса при обращении к иностранной аудитории. Для людей, не владеющих русским языком в качестве родного (как преподавателей, так и обучаемых), Корпус оказывается поистине незаменимым инструментом. Действительно, мы, носители русского языка, ежесекундно погружены в его стихию. «Примеры употребления» русского языка не просто существуют у нас в сознании – они окружают нас буквально повсюду. Конечно, специально отобранные и обработанные в составе

Корпуса, эти примеры могут принести гораздо большую пользу, но если носителя русского языка лишить Корпуса, это не скажется фатальным образом на возможности его контактов со стихией русского языка – просто потому, что эта стихия существует по крайней мере и в его сознании тоже.

Иное дело иностранец. Его языковое сознание – не русское. И он в высшей степени нуждается в инструменте, открывающем ему максимально широкий (и максимально комфортный) доступ в мир русского языка. Ничего лучше Корпуса современная наука в этом случае предложить не может. Именно в Корпусе преподаватель и студент могут найти ответы на многие интересующие их вопросы – причем такие ответы, которые и носитель не сразу догадается предложить. Поэтому не случайна высокая популярность корпусов в иноязычной среде. И именно от зарубежных русистов (в особенности преподавателей русского языка) мы получали самые заинтересованные и самые эмоциональные отклики.

<…>

Еще одна группа людей, для которых Корпус может представлять бесспорный интерес, – люди пишущие и, шире, вообще как-то в своей повседневной деятельности связанные со словом. Например, редакторы газет и журналов. Редакторам в своей практической деятельности гораздо чаще, чем академическим исследователям, приходится решать вопросы узуса: допустимо ли такое слово или конструкция? Кто, где, когда употребил впервые такой оборот? Для каких типов текста он наиболее характерен? Трудно представить себе, где можно быстро найти ответы на такие вопросы, если не в Корпусе. (Вообще иногда кажется, что корпуса были придуманы специально для редакторов – впрочем, некоторые утверждают, что специально для программистов – или специально для преподавателей русского языка как иностранного.) Во всяком случае нам известно, что многие, как теперь принято говорить, «продвинутые» редакторы активно пользуются Корпусом для решения своих повседневных проблем – ну и, конечно, для более эффективного устрашения авторов, как же без этого. «Вот Вы тут пишете… а, между прочим, в Национальном корпусе русского языка…» Говорят, что такая синтаксическая конструкция действует безотказно. Опять-таки, Корпусом можно пользоваться и для проверки каких-то сведений, т.е. как справочником – но, еще раз повторю, в этом отношении необходимо соблюдать известную осторожность, помня, что не всё действительное может быть разумно (по крайней мере, если речь идет о тексте, предназначенном для публикации в газете или журнале).

(*Плунгян В.А. Зачем нужен Национальный корпус русского языка? Неформальное введение // Национальный корпус русского языка: 2003 – 2005. М.: Индрик, 2005. С. 12 – 17*).

Н.В. Перцов

О роли корпусов в лингвистических исследованиях

В приведённом ниже фрагменте представлены некоторые данные, собранные Н.В. Перцовым, демонстрирующие расхождения в лингвистических утверждениях, представленных в работах последних лет, с материалами, извлечёнными из Национального корпуса русского языка (www.ruscorpora.ru). Литера **К** отмечает начало корпусного материала, противоречащего приведённому утверждению.

«<…>

(L1) [Мельчук, Холодович 1970: 112; Mel'čuk 2004: 41; Плунгян, Рахилина 2005: 380]: при глаголе *промахнуться* может быть синтаксически выражен только агенс, а остальные его семантические актанты – объект-мишень, инструмент и средство – не могут. Если при глаголе *выстрелить* можно выразить все четыре семантических актанта – *Он выстрелил в утку из винтовки разрывной пулей*, то при *промахнуться* – только один: *Он промахнулся*.

К (1): объект-мишень выражен в 21 контексте употребления *промахнуться* (из 583): посредством группы с предлогом *мимо* (*Враг* <…> ***промахивается мимо*** *целей* [А. Проханов, 2001]), с предлогом *по* (*Первый бандит, так неудачно* ***промахнувшийся по*** *«мишени», был жив* <…> [А. Измайлов, 2001], с предлогом *в* (<…> *динамовский защитник умудрился* ***промахнуться в*** *пустые ворота с метра* [Е. Чежегов, 2001]; (2) имеются контексты, в которых выражены инструмент (причем совместно с мишенью) и средство: <…> *он молнией вырвал наган – и всадил две пули рябому в грудь и третью – в его товарища… но* ***третьею промахнулся****!* [С. Бабаян, 1995-1996]; *Портрет человека, который* <…> *по чистой случайности* ***промахнулся в меня из*** *снайперки с крыши «Титаника»* [В. Скворцов, 2001].

(L2) [Апресян 2004а: 27]: из двух лексем существительного *влияние* – акциональное *влияние*[1] (квазисинонимичное *воздействию*) и *влияние*[2] как название свойства (квазисинонимичное *авторитету*) – с глаголом *иметь* в современном языке сочетается только *влияние*[2]; «примеры типа *Эта книга всегда имела сильное на него влияние* (А.С. Пушкин), где *влияние*[1] сочетается с глаголом *иметь* в качестве OPER1, в современном языке явным образом устарели».

К <15 из 59 контекстов с существительным *влияние*>: *Когда человек,* ***имея влияние на*** *ход политических процессов, старается не привлекать к себе внимание и не занимать должностей с громкими названиями, к нему прикрепляется ярлык – «серый кардинал»* [«Итоги», 1996.09.20]; «*Далеко не все кредиторы этих организаций смогут* ***иметь влияние на*** *ОАО «РЖД», –*

сказал он «Известиям» [«Известия», 2003.01.11]; *Не только в Ираке, где Россия берется спасти Америке лицо, не только в Северной Корее,* ***на*** *которую только Россия* ***имеет влияние****, но и во множестве разных других ситуаций* [«Спецназ России», 2003.01.15].

<…>

[ЯКМСЛ: 54]: глаголы состояния неспособны употребляться в повелительном наклонении; «ср. невозможность <…> **Знай древние языки* <…>».

К <2>: *Мой совет всем водителям:* ***знайте*** *свои права, требуйте их соблюдения всеми, кто встречается на вашем пути!* [«Свободный курс», 1997.01.23]; *При посещении офиса* ***знайте*** *примерные размеры окон, для того чтобы вам посчитали стоимость не какого-то мифического окна, а именно вашего* [«Биржа плюс свой дом», 2002.03.11].

<…>

Приведённый материал показывает, что языковая интроспекция исследователя как носителя языка не является абсолютно надежным инструментом, и её необходимо верифицировать посредством обращения к корпусам и к опросу информантов. Здесь мы наблюдаем нечто парадоксальное: исследователь, нацеленный на языковое поведение той или иной языковой единицы, мысленным взором охватывающий её возможные употребления, нередко оказывается в плену собственного языкового чутья и за деревьями частных употреблений не видит всего леса. Иногда суждения разных информантов по поводу тех или иных фраз расходятся существенным образом. В таких случаях исследователю нужно по возможности отрешаться от собственных языковых представлений и обращаться к речевой деятельности, которую в изобилии предоставляет корпус. Поэтому представление о языковой интроспекции как о таком же надежном инструменте, как экспериментальные исследования, ошибочно. Опора только на интроспекцию аналогична опоре только на данные наших органов чувств при установлении числовых данных в случае измерения расстояния, силы звука и т.п. без привлечения аппаратуры, дающей точные данные.

Разумеется, я не хочу быть понят так, что нужно отказываться от интроспекции и языкового чутья. Нет, ни в коем случае. Как нельзя полностью доверять чутью, так нельзя и полностью доверять корпусам, тем самым их фетишизируя. В самом деле, в любых текстах могут быть языковые ошибки, с одной стороны, и языковая игра, художественные вольности и т.п., с другой. При изучении корпусных данных требуется внимательный контроль со стороны языковой интуиции исследователя, причем желательно с привлечением оценок других носителей языка.

<…>»

(*Перцов Н.В. О роли корпусов в лингвистических исследованиях // Труды Международной конференции «Корпусная лингвистика – 2006» (Санкт-Петербург, 10 – 14 октября 2006 г.). СПб., 2006. С. 320 – 321, 326, 328*).

Тема 2

КОРПУСНАЯ ЛИНГВИСТИКА И СМЕЖНЫЕ ДИСЦИПЛИНЫ

А.В. Венцов, Е.В. Грудева

О корпусе русского литературного языка (www.narusco.ru)

«Создание корпусов языков в настоящее время является актуальной проблемой и насущной задачей учёных разных стран. Объем статьи, как, впрочем, и её преимущественно практическая направленность, не позволяют нам обратиться к обсуждению проблем общего характера, связанных с ролью корпусов в построении теоретического описания языка – см., в частности, инспирированную Н. Хомским недавнюю дискуссию в рамках телеконференции Corpora-List, где сторонники Хомского утверждают иррелевантность для теории языка корпусных данных – равно как статистики и даже семантики. С нашей точки зрения, «ненаблюдаемость» языка, на которую ссылается Хомский, никак не говорит о том, что не существует какой бы то ни было логической связи между характеристиками языка и характеристиками порожденного языком текста – а именно к этому фактически приходят Хомский и его сторонники. Но если такая связь существует, что опровергнуть достаточно трудно, то это и приводит к естественной мысли о необходимости корпуса, который даёт нам организованную определенным образом совокупность текстов – вместо более или менее произвольного набора примеров, извлеченных из текстов или сочиненных исследователем. Мы уже не говорим о том, что статистические данные, которые извлекаются из корпуса, являются ценнейшим материалом для социолингвистических, литературоведческих и иных изысканий. <…>»

(*Венцов А.В., Грудева Е.В. О корпусе русского литературного языка (www.narusco.ru) // Russian Linguistics. 2009. № 2*).

С.А. Шаров

Представительный корпус русского языка в контексте мирового опыта

«1.3. Использование корпусов для лингвистических исследований

Любой корпус создаётся как средство отражения и эмпирического исследования явлений, встречающихся в языке (или подъязыке, в случае специали-

зированного корпуса). Наличие компьютерного корпуса не меняет радикально деятельность лингвиста. Корпуса текстов использовались для создания грамматик и словарей задолго до появления компьютеров. Словарь английского языка Сэмюэля Джонсона (середина XVIII в.) и грамматика Отто Есперсена (первая половина XX в.), а равно и академические грамматики и словари русского языка создавались на основе анализа реальных примеров словоупотребления, записанных на карточках. Однако компьютерный корпус служит инструментом, с помощью которого можно проводить исследования, методологически отличные от традиционных.

Создание представительных корпусов и их разметка на различных уровнях влечет за собой создание словарей и грамматик, построенных на основе корпусной методологии. Представительный британский корпус LOB, построенный по модели Брауновского корпуса, лёг в основу [Quirk R., Greenbaum S., Leech G., Dik J. A Comprehensive Grammar of the English. London: Longman, 1985]. Создание первого большого английского корпуса Bank of English (20 млн словоупотреблений в 1980-е гг.) привело к созданию серии грамматик и словарей серии COBUILD. Создание БНК (Британского национального корпуса. – *Е.Г.*) привело к появлению новой грамматики [Biber D., Johansson S., Leech G., Conrad S., Finegan E. The Longman Grammar of Spoken and Written English. London: Pearson Education, 1999]. Задача, встающая перед корпусно-ориентированной грамматикой, заключается в создании описания, которое дает адекватный анализ для *любого* словоупотребления, зафиксированного в корпусе, а наибольшее внимание обращается на наиболее частотные случаи.

Непосредственные наблюдения, которые можно провести над текстом корпуса, касаются лексических характеристик, таких, как частота встречаемости отдельных слов и словосочетаний. <…>

3. Вместо заключения

Подавляющее большинство исследований в области корпусной лингвистики начиналось на материале английского языка. Причиной этого является не только и не столько активное развитие компьютерной техники в США, а интеллектуальный климат в Британской лингвистике в 60 – 80-е гг. XX в. В США в это время властвовал хомскианский подход, основанный на лингвистической интуиции, которая не требует наличия корпусных данных (зачастую хаотичных и зависящих от более широких контекстов высказывания), поскольку объектом изучения является возможность построения правильных языковых конструкций (well-formedness), а различие между правильными и неправильными конструкциями может быть проведено любым носителем

изучаемого языка. В противоположность рационалистскому подходу, основанному на лингвистической интуиции, проводящей различие между правильными и неправильными конструкциями, эмпирический подход предполагает, что язык является ресурсом, обеспечивающим набор возможностей для коммуникации. Этот набор реализуется в дискурсе, поэтому объектом исследования в лингвистике является результат реализации этого ресурса, а именно, слова и конструкции, употреблённые в тексте.

В отличие от США в британской лингвистике были сильны эмпирические тенденции, которые предполагали использование реальных примеров для проверки лингвистических гипотез, отметим, в первую очередь, исследования Джона Фёрса и его учеников: Грегори, Синклера, Хэллидея и др. Это и привело к созданию многих корпусов и разработке корпусных исследований на материале английского языка. Эмпирический подход явно присутствовал и в нашей лингвистике, в которой лингвистический анализ практически всегда сопровождался примерами реального словоупотребления. <…>»

(*Шаров С.А. Представительный корпус русского языка в контексте мирового опыта // Научно-техническая информация. Сер. 2. 2003. № 6. С. 12; 16*).

У.Н. Фрэнсис

Проблемы формирования и машинного представления большого корпуса текстов

«<…>

В 1962 году, когда я только начинал собирать в университете Брауна «The Brown Standard Corpus of American English» (корпус B), я встретил на одной из лингвистических конференций профессора Роберта Лиза. Отвечая на его вопрос относительно моих тогдашних интересов, я сказал, что у меня есть заказ от Министерства образования США на формирование корпуса современного американского варианта английского языка в миллион словоупотреблений для машинного использования. Он посмотрел на меня с удивлением и спросил: «Для чего, собственно, вы это делаете?» Я сказал что-то о выяснении подлинных фактов английской грамматики. Никогда не забуду его ответ: «Это бессмысленная трата вашего времени и правительственных денег. Вы – носитель английского языка; в течение десяти минут вы способны представить больше примеров на любое явление английской грамматики, чем сможете найти во многих миллионах слов случайных текстов». Это замечание весьма существенно для нашей темы. Не думаю, что Хомский в ту пору

уже определил свои термины competence ‘компетенция, владение языком’ и performance ‘употребление языка’, но именно это противопоставление имел в виду Лиз (вспомните, что он является первым и весьма ортодоксальным учеником Хомского). Корпус – собрание текстов – неизбежно является фиксацией употребления, а лингвист должен – по крайней мере в соответствии с ранней версией трансформационной теории – заниматься только компетенцией. Самым же лучшим способом получения знаний о компетенции считалась работа не с текстами, а использование интуиции носителя языка. Вот почему правомерен вопрос, зачем нужно тратить время, силы и средства на сбор корпуса текстов. Ответ, конечно, состоит в том, что очень и очень многих людей, в том числе лингвистов, действительно интересует употребление языка, либо само по себе, либо как один из путей, ведущих к пониманию компетенции. <…>»

(*Фрэнсис У.Н. Проблемы формирования и машинного представления большого корпуса текстов // Новое в зарубежной лингвистике. Выпуск XIV. Проблемы и методы лексикографии. М.: Прогресс, 1983. С. 334 – 335*).

А.В. Венцов, В.Б. Касевич, Е.В. Ягунова

Корпус русского языка и восприятие речи

«В настоящее время лингвистика во многом избавилась от раннегенеративистских иллюзий, в частности, от уверенности, что лингвистические механизмы как таковые могут быть познаны с привлечением весьма ограниченного набора примеров (обычно сочиненных самим лингвистом). На смену этим достаточно наивным представлениям приходит понимание необходимости строить исследование даже самого «мелкого» фрагмента языковой системы с использованием репрезентативного множества текстов соответствующего языка. Оговоримся, что имеется в виду репрезентативность как в количественном, так и в качественном отношении – по представленности жанров, стилей и т.п. Такое множество текстов стало уже традиционным называть *корпусом*. Приступая к исследованию конкретной проблемы, лингвист может (а в реальной ситуации, как правило, должен) составлять свой собственный корпус.

В последние десятилетия усилия лингвистов многих стран направлены на создание национальных, или универсальных, интегральных корпусов. Хотя критерии репрезентативности такого корпуса пока не вполне ясны, ясна задача: корпус должен обладать количественными и качественными параметрами, необходимыми и достаточными для построения на его основе адекватных словаря и грамматики соответствующего языка.

Адекватность словаря определяется, с этой точки зрения, тем, насколько мала вероятность встретить в произвольном тексте – вне текстов корпуса – словарную единицу (слово, словоформу, фразеологизм), отсутствующую в словаре. «Произвольность» текста не следует понимать буквально: для любого корпуса, даже универсального, допустимы ограничения – например, невключение текстов диалектного характера.

Адекватность грамматики мы предпочли бы трактовать как характеристику действующей, динамической системы, обеспечивающей речевую деятельность. Иначе говоря, грамматика для нас – это механизм порождения и/или восприятия текста (речи). Адекватность такой грамматики – это ее способность порождать правильные (нормативные) тексты и только их (критерии нормативности задаются отдельно), а также анализировать с получением заданного результата (транскрипция, семантическая запись и т.п.) правильные тексты...

Уже использование логической связки «и/или» выше дает понять, что мы, не отрицая единства грамматического механизма на некотором уровне, признаем тем не менее возможность и даже необходимость выделять грамматику, отвечающую за порождение речи, и грамматику, «заведующую» восприятием речи. Более того, в этом различении, восходящем к Л.В. Щербе с его активной и пассивной грамматиками, мы идем дальше, разграничивая также *словари*: генеративный (обслуживающий порождение речи) <…> и перцептивный (обслуживающий восприятие речи). Именно последний, как компонент модели восприятия речи, будет интересовать нас в настоящей статье.

Прежде, однако, воспроизведем основные аргументы в пользу, как нам представляется, признания относительной самостоятельности перцептивного словаря...

Главной отличительной особенностью перцептивного словаря нам видится характер его единицы: в качестве таковой есть основания указать *словоформу*. Можно считать экспериментально доказанным, что важным ключом для идентификации слова при его восприятии (изолированно или в тексте) выступает *частотность* данного слова. Но частотность слова как лексемы – в известном смысле фикция. Реальной частотностью характеризуются именно отдельные словоформы слова, причем разные словоформы одного и того же слова могут существенно отличаться по частотности[2].

---

[2] Разумеется, частотность словоформы, которая отлична от частотности лексемы, – это особенность русского и аналогичных ему языков с развитой морфологией. Данная проблема может быть периферийной или даже несущественной для аналитических и тем более изолирующих языков (вероятно, именно поэтому аналогичные вопросы не рассматриваются в многочисленных работах на материале английского языка).

Точно так же можно считать доказанным, что еще один важный ключ, используемый для предварительной, грубой классификации слова при восприятии речи, – это его акцентный контур. Но и акцентный контур – даже более непосредственно, нежели частотность – есть признак словоформы, а не лексемы. Разные словоформы одной и той же лексемы могут обладать разными акцентными контурами, совокупность которых образует так называемую акцентную кривую, ср., например, *сад*, *са́ду*, *(в)саду́*, *(в)сада́х* и т.п. Акцентная кривая создается, главным образом, перемещением ударения с основы на окончание или наоборот.

Признание словоформы основной единицей перцептивного словаря, разумеется, приводит к значительному увеличению его объема. В то же время это возрастание объема значительно меньше, чем можно было бы предположить априори; связано это с тем, что отнюдь не каждая лексема обладает полным набором словоформ, отвечающим категориям, которые присущи ее классу/подклассу. Специальное статистическое изучение такого рода ограничений представило бы отдельный интерес.

Увеличивая словарь, опора на словоформу в то же время сильно упрощает процедуру идентификации единиц текста при их восприятии, во многом сводя эту процедуру к прямому сличению отрезка текста и единицы словаря – минуя процесс лемматизации, неизбежный, если мы имеем дело с традиционным словарем лексем, а не словоформ.

<…>

Моделирование процессов восприятия речи (во всяком случае, на материале русского языка) включает в себя такие подготовительные этапы, как

– формирование представительного корпуса текстов (на начальном этапе – в орфографической записи) с акцентуацией словоформ и разметкой согласно специально разработанной системе аннотирования;

– создание на базе корпуса текстов словаря для моделирования восприятия речи; единицей словаря выступает словоформа с индексом частотности.

На настоящий момент общий объем нашего корпуса – 1 031 920 словоупотреблений. На основании подкорпуса объемом 322 тыс. словоупотреблений организован частотный словарь словоформ, включающий 63 742 единицы и словарь фонетических слов объемом 84 174 единицы. Этот подкорпус имеется также в транскрибированном виде. <...>»

(*Венцов А.В., Касевич В.Б., Ягунова Е.В. Корпус русского языка и восприятие речи // Научно-техническая информация. Сер. 2. 2003. № 6. С. 25 – 27*).

Н.Н. Леонтьева

Корпусная лингвистика и системы автоматического понимания текста

«Корпусная лингвистика (КЛ) – это новая (по крайней мере, для нашей страны) и интенсивно развивающаяся дисциплина. В ней сконцентрировались многие полезные свойства гуманитарных и технических дисциплин, включая и статистику как вспомогательный прием при обработке массивов. КЛ называют новым информационным ресурсом. Но её статус среди прикладных наук пока не очень ясен. Каких свойств в ней больше – научной дисциплины или работающей системы?

В первом случае встаёт вопрос о **методе** КЛ как науки. Во втором случае (если мы видим в КЛ больше черт прикладной системы, своего рода системы управления базами данных, совмещающей приёмы ручной и автоматической обработки текстовых данных, в том числе их поиск) важны **сфера** использования и **результаты**, реальные или хотя бы планируемые. А может быть, КЛ вообще выполняет только служебную роль – обеспечивает текстовым материалом лингвистов: практиков (составителей словарей) и теоретиков? Тогда это вполне традиционная роль. К тому же соблюдающаяся при формировании самих текстовых корпусов культура внимательного отношения к атрибутам естественного текста (учёт жанра, стиля, автора, времени создания текста и других «регистров» метаразметки корпуса…) обязана филологии как традиционной гуманитарной дисциплине…

Однако масштабы, динамика и успехи КЛ объясняются использованием наработанных компьютерных технологий, это они превратили КЛ в мощный информационный ресурс, сблизивший её именно с системами. Очевидно, что КЛ вобрала в себя методы нескольких продвинутых типов прикладных систем, объединённых общим названием «системы автоматической обработки текста» (АОТ). В системах АОТ тоже имеются и свои теории, и свои результаты. Рассмотрим, какие разновидности компьютерных систем внесли свой вклад в развитие КЛ.

До сих пор прикладные системы анализа текста развивались по двум главным линиям, условно назовём их **лингвистической** и **информационной**. Первая реализовалась в основном в системах машинного перевода (СМП), а среда МП в свою очередь способствовала развитию лингвистических теорий и формализмов. Вторая – это анализ в составе разного вида информационно-поисковых систем (ИПС), нужных внешним пользователям-специалистам, заинтересованным в эффективном поиске полезной информации… Как же соотносятся друг с другом лингвистический анализ (ЛингвАн) и информационный анализ (ИнфАн) текста?

ИнфАн в информационных системах часто опирается на результаты начального ЛингвАн, однако эти два направления давно развиваются параллельно и, к сожалению, изолированно друг от друга. Это привело к тому, что ни то, ни другое направление не дали пока тех результатов, которые ожидает от них общество. Информационный анализ, не использующий достижений ЛингвАн, вырождается в технически простую задачу поиска на вхождение запрошенных цепочек лексем (в том числе терминов) в больших массивах текстов. А детальный лингвистический анализ, не пользующийся достижениями ИнфАн, никак не может выйти за пределы предложения, в целый текст.

Похоже, что КЛ, объединив методы того и другого, дала каждому из них новую перспективу. Из информатики взят и даже расширен масштаб анализа: обработке подлежит не просто целый текст как вожделенная цель ЛингвАн, а массивы, или корпуса, текстовых материалов. Термины *индексирование* и *аннотирование* также заимствованы КЛ из информатики, но они приобрели в ней другое значение: как синонимы собственных терминов КЛ – *тэгирование* и *разметка*. <…>

Из лингвистики кроме приёмов быстрого создания словарей, тезаурусов и конкордансов КЛ наследует детальность разбора и различение уровней анализа (морфологический, синтаксический, семантический). Пока в реальном масштабе реализована только морфология; приписывается какая-то информация и каждой текстовой единице, не имеющей морфологии (в системах АПТ этот уровень назван графематическим анализом). <…> Но, начиная с проблем синтаксической разметки, обостряются вопросы, связанные со статусом и использованием КЛ…

Дело в том, что КЛ остаётся аморфной дисциплиной, не заявившей о своей цели (ср. прикладные дисциплины, имеющие цели: достижение точности понимания или перевода отдельных предложений при ЛингвАн или в системах МП, получение новой информации в информационно-поисковых системах, построение базы данных в разных системах искусственного интеллекта и др.). КЛ давно служит для создания разного рода словарей – переводных, авторских, терминологических, специальных, контекстных, статистических. Но помимо выполнения этой очень важной, но всё же служебной роли станет ли КЛ центром в круге систем АОТ? Можно ли надеяться, что КЛ обеспечит такую исчерпывающую и достоверную экспертизу текста, на которую смогут опираться все другие системы, решающие разные задачи с естественным текстом? Например, сможет ли КЛ дать лингвистическую основу для дальнейшего разбора художественных произведений? Облегчит ли КЛ построение базы для включения в неё описаний объектов и ситуаций, данных в тексте? Ответы на эти и многие другие вопросы содержательного характера зависят от успехов прикладной лингвистики и её теории.

Если уточнить термин АОТ, заменив слово *обработка* на слово *понимание* – **автоматическое понимание текстов** (АПТ) – правильнее было бы связать КЛ как прикладную дисциплину с системами типа АПТ. Понимание отличается от обработки тем, что предполагает наличие воспринимающего субъекта, который ставит разумную цель и формулирует свои требования к результату. Хотя механизм АПТ пока еще не заработал на массивах, создаваемых КЛ, представляется, что воспринимающий субъект и его цели (а это требование к результату) обязательно должны войти в теоретическую модель и стать компонентами КЛ как системы: ведь все информационные ресурсы так или иначе предназначены для реальных пользователей.

<…>

Теоретических и методологических вопросов относительно характера и «языка» семантического уровня, способного удовлетворять «внешние» запросы, остаётся очень много. Однако сочетание методов ЛингвАн и ИнфАн позволит создателям прикладных систем решать многие проблемы, которые по отдельности трудно или совсем не решаются, как, например, установление разного рода референтных связей по всему тексту.

В сложных задачах СемАн на помощь приходит контекст целого, который можно учитывать в интерпретации каждой встреченной и локально не снимаемой неоднозначности. Кроме того, фактором, облегчающим анализ целого текста, является ослабление требований к результатам предшествующего этапа, возможность неполного анализа тех предложений, для которых нет лексического словарного обеспечения или которые оказались слишком сложными для синтаксического анализа. Ведь известно, что существующая в любом тексте смысловая избыточность может восполнить локальное «недопонимание».

Пока же в роли пользователей КЛ выступают лишь сами лингвисты. Эту роль никак нельзя недооценивать. Тот простор, который открывает КЛ, просто вынуждает лингвистов при создании и обкатке грамматик выйти за пределы только синтаксического анализа изолированных предложений.

<…>

Замечу, что автоматический синтаксический анализ этих и других – даже средней трудности – фраз даст большой информационный шум (ошибки и/или много вариантов), и валентная структура мало чем поможет, если учитывать при анализе только синтаксические способы её выражения.

В связи с этим встаёт вопрос: нужно ли – после работы синтаксического парсинга и предшествующих ему автоматических процессоров – проводить очень сложную и трудоёмкую (часто вручную) процедуру снятия омонимии, тем более что она часто сопровождается теоретически спорными решениями? Размеченные и откорректированные тексты нужны людям, изучающим дан-

ный язык, или такой категории пользователей, как преподаватели. Но и они в таком выправленном корпусе не смогут найти информацию о том, как нельзя сказать, тем более, почему так нельзя сказать…

А зачем самому лингвисту вычищенный, стерилизованный массив? Нужно ли ему корректировать автоматические результаты или вообще проводить разметку вручную? Ведь лингвисту, особенно прикладному лингвисту, важно видеть истинную картину всех неоднозначностей и других проблем естественного текста, чтобы создавать правила автоматического или автоматизированного их разрешения. Вычищенный сегодня массив синтаксических структур может завтра не пригодиться, если будет применен более мощный СинАн. Та же проблема с семантической разметкой: уточнение семантической классификации и увеличение словаря обеспечит улучшенный результат СемАн на том же исходном тексте/массиве. Что же – ещё раз чистить? Ответ пока не ясен.

Внешнему пользователю нужен хорошо отлаженный и быстро работающий механизм поиска, причём с разными уточняющими запрос параметрами. Возможны разные стратегии поиска: для некоторых запросов синтаксис не нужен, для других достаточен упрощённый СинАн, третьи требуют полного или выборочного семантического разбора. Но ориентация на реальные запросы реальных пользователей с приемлемыми параметрами скорости вынуждает КЛ как систему функционировать только в полностью автоматическом режиме, без привлечения интер- или постредактора. Для этого нужно разрабатывать словари и грамматики, могущие работать на непрепарированных, реальных массивах. Поэтому основные усилия прикладных лингвистов надо направить на разработку анализа, а не на коррекцию его результатов.

Рабочее место лингвиста должно быть снабжено разными процессорами, с разной семантической силой. Внутренняя дескрипция текста (лингвистические структуры) и внешняя дескрипция (данные о целом тексте: жанр, тема и др.) будут взаимно полезны для разных целей анализа корпусных материалов. При вычислении ответов на вопросы об основном содержании какого-либо текста или о различиях в содержании двух произвольных текстов корпуса потребуется провести полный или близкий к нему СемАн целого текста, чтобы дать полноценный ответ пользователю. Одна из задач СемАн – быстро устанавливать связи со всеми другими источниками информации, позволяющими уточнять построенные структуры. Это позволит, например, при сигнале о неоднозначности или сбое синтаксического разбора фразы из корпуса провести СемАн и вернуть его результаты в СинАн. И в этой задаче слово за лингвистами, за их способностью прийти к соглашению относительно способа представления семантической структуры текста в корпусах. Пока же такой способ не найден.

Сделаем некоторые выводы.

1. Понимание – ментальный процесс, его единицами являются **не** слова, а понятия, или концепты. Как определить, что такое концепт, в системах АПТ и КЛ, не залезая в мозги пользователя (ведь материалом КЛ являются – пока – слова)? Как их задать в вербальном виде? Да ещё так, чтобы каждый пользователь извлекал свою информацию, своё понимание из одного исходного текстового материала? Сам пользователь не знает словаря и грамматики системы АПТ и не может на них воздействовать. Значит, система АПТ должна работать методом «встречного текста», уметь адаптировать свои структуры к любому из запросов и вопросов, поступивших от внешней интеллектуальной системы.

2. Перечисленные проблемы относятся большей частью к **теории** прикладной лингвистики и АПТ-систем. При переносе центра внимания на запросы внешней системы к корпусу насущной становится задача включения пользователя, или компонента «воспринимающее устройство», в модель/теорию АПТ. Самой неразработанной частью этой теории остаётся семантический компонент, в его важнейшей функции – установлении связей со всеми теми источниками информации, которые могут участвовать в поиске ответа на запросы воспринимающего устройства. <…>

3. Назову некоторые позитивные шаги, которые может сделать сейчас лингвистика и конкретно КЛ навстречу такому социальному заказу:

– укрупнение единиц анализа в локальных структурах – построение синтаксических, затем семантических групп; как первый шаг потребуется задать полные списки устойчивых словосочетаний (в основном это сложные предлоги, союзы и наречия), а также терминов, претендующих на статус общеязыковых «понятий» (именные группы);

– выход за пределы предложения в СемАн: доказательство связности текста по основным объектам и установление отношений референции по всему тексту; для этого (а также для необходимого сжатия текста) нужно разработать методы использования смысловой неполноты и избыточности;

– задание правил и механизмов сравнения содержания текста с тем, что содержится в базе данных, то есть с уже упакованными знаниями; это потребует разработки метаязыка, позволяющего сравнивать разные тексты между собой и тексты с другими источниками информации (заданными тезаурусами, номенклатурами и разными списками).

<…>

Решение названных проблем открывает новую перспективу перед прикладной и теоретической лингвистикой, а именно, намечает мостик, связывающий разные источники знаний. Моделировать взаимодействие разнородных систем можно на самом горячем сейчас участке – на механизмах взаи-

модействия синтаксического и семантического представлений текста. Добротное решение этой задачи поможет снять или свести к минимуму очень трудоёмкую и практически невыполнимую для больших текстовых корпусов процедуру ручной коррекции построенных синтаксических и семантических представлений…

Может показаться, что мы слишком многого ждём от КЛ. Но создано ведь уже достаточно наработок, и при серьёзном обсуждении и согласованной работе лингвистического сообщества есть шанс, основываясь на КЛ как новом информационном ресурсе, продвинуть развитие разных систем АПТ и тем дать второе дыхание самой корпусной лингвистике».

(*Леонтьева Н.Н. Корпусная лингвистика и системы автоматического понимания текста // Московский лингвистический журнал. 2004. Т. 9. № 1. С. 5 – 9, 11 – 14*).

Приложение 3

Тема 3

КОРПУС И WEB: СХОДСТВА И РАЗЛИЧИЯ

В.И. Беликов, М.В. Ахметова

Статистическая оценка функциональных свойств лексики по материалам Интернета

«<…>

Охарактеризуем материал, **текстовые массивы Интернета**. Хорошим подспорьем для разного рода лингвистических разысканий стал Национальный корпус русского языка, но для детального исследования лексики его объема часто не хватает. Выручают некоторые сегменты Интернета, которые корпусами можно называть лишь метафорически. Корпуса формируются не стихийно, а создаются намеренно; их параметры задаются и контролируются, технические затруднения при поиске носят случайный характер и поисковые возможности при развитии корпуса могут меняться лишь в лучшую сторону. Не то с текстовыми массивами. Здесь мы знаем лишь самые общие характеристики содержащихся в них текстов, однако и их часто вполне достаточно. Важнейшими текстовыми массивами для работы с лексикой оказываются Библиотека Максима Мошкова (БМ) – большое собрание литературных и

стилистически близких к ним текстов, и стихийно формирующаяся русскоязычная блогосфера.

Важным достоинством БМ является ее разделение на несколько подмассивов, стилистика которых существенно различна. В первую очередь значимо противопоставление разделов «Собрание классики» (az.lib.ru), «Современная русская проза» (lib.ru/PROZA) и «Самиздат» (zhurnal.lib.ru). «Современность» в соответствующем разделе БМ трактуется достаточно широко и охватывает значительную часть советского периода. Собранием действительно современного профессионального литературного творчества является другой сегмент Интернета – «Журнальный зал» (magazines.russ.ru), где сосредоточены журнальные публикации с 1990-х гг.

«Самиздат» представляет собой очень большое по объему собрание современных самодеятельных произведений разного жанра, обычно невысоких художественных достоинств; многие авторы имеют достаточно смутные представления о литературной норме, доля разговорной и просторечной лексики в авторском тексте этого массива заметно выше, чем в только что упомянутых, поэтому в целом лексикон «Самиздата» близок к современному разговорному узусу.

Язык блогов во многом является отражением повседневного молодежного словоупотребления. Теоретически Яндекс допускает поиск в блогах с заданием отдельных параметров и их комбинаций: региона, пола и возраста блоггеров, а также с выделением конкретного фрагмента блогосферы (livejournal.com, diary.ru и т. п.). <…>

<…>

Не так уж редко кодифицированные **грамматические характеристики** отдельных единиц противоречат повседневному узусу.

Во всех толковых словарях фигурирует слово *корректив* (м. р.). Анализ текстовых массивов Интернета показывает, что если в 1930-е гг. и ранее *вносился корректив*, то к середине XX в. вноситься стали *коррективы*, в дальнейшем нейтрализация по числу способствовала смене рода на женский. К настоящему времени использование этого слова в единственном числе мужского рода стало безусловной архаикой, сейчас в словаре стоило бы писать: «**корректива**, *ж.* (*реже* **корректив**, *м.*), обычно *мн.* …» [см. подробнее: Беликов, в печати$_2$].

<…>

Обращение к интернет-массивам позволяет довольно точно определить время и темпы конкретных словарных изменений. Изменения эти могут иметь разный характер: лексическая единица может «просто» устареть и выйти из употребления, может, наоборот, проявить территориальную или социальную экспансию, а может замениться другой, внешне сходной. Словарями эти процессы фиксируются далеко не всегда адекватно.

В словаре под редакцией Д.Н. Ушакова имелись слова *бестоварье* ‘недостаток, отсутствие товаров’ с пометой *газет.*, *ведьмак* ‘знахарь, колдун, оборотень’ с пометой *обл.* и *решебник* ‘учебное пособие, содержащее подробные решения задач, помещенных в каком-н. задачнике; ключ к задачнику’ с пометой *школьн. арго*. Последнее слово позднее в толковые словари не включалось, то ли как устаревшее, то ли как имеющее слишком узкогрупповое распространение. *Ведьмак* в достаточно объемном (130 тыс. слов) БТС отсутствует, но в новом БАСе представлен, по-прежнему с пометой *обл.* А *бестоварье* в двух названных академических словарях получило помету *разг.* Между тем *бестоварье* в БМ встречается лишь в 8 текстах, датированных 1917 – 1928 годами (три художественных: «Разгром» Фадеева, «Третья столица» Пильняка, «Возвращение Мюнхгаузена» С. Кржижановского), а также в двух современных, но в обоих случаях цитируются документы той же эпохи. В блогосфере это «разговорное слово» появилось лишь четырежды, причем только в цитатах 1920-х гг. Что касается *ведьмака*, то обнаружившаяся в последние десятилетия всенародная любовь ко всему мистическому и потустороннему, сделала это слово чрезвычайно частотным: если в разделе «Классика» БМ оно встретилось лишь в 4 произведениях, то в современной литературной периодике («Журнальный зал» по 2008 г. вкл.) – в 19 текстах; в повседневном узусе ведьмаки упоминаются чаще многих общеизвестных политиков: в блогах за первую неделю декабря 2008 г. *ведьмаки* встретились 203 раза. Разумеется, никакого «областного» налета у этого слова уже нет. *Решебник* же достаточно давно стал упоминаться вне связи со школой, ср. у Аркадия Штейнберга о рыбаке: *Он перелистывает, как решебник, / Волну, волну... Ответа нет как нет* («Взморье», 1932); позднее это слово метафорически использовалось в стихах Борисом Слуцким и Сашей Соколовым. Что касается основного значения, то оно ежедневно по нескольку раз фигурирует в блогосфере, причем и в связи с вузовским обучением.

<…>

Интернет-блоги во многих случаях являются наиболее эффективным инструментом выявления ареалов распространения регионально маркированных единиц: *чойс* ‘любая лапша быстрого приготовления’ и *оптарь* ‘оптовый рынок’ находятся только в омских блогах; *садоогород* ‘садово-огородное товарищество или участок в нем’ используется и в официальных контекстах – почти исключительно в Удмуртии, *ссобойка* (также *собойка*) ‘набор продуктов на работу, в дорогу; школьный завтрак, взятый из дома’ – практически только в Белоруссии.

<…>

Приведенные выше примеры можно легко умножить. Интернет позволяет подтверждать или опровергать имеющиеся в толковых словарях сведения о

функциональных свойствах лексики, выявлять новые, трудноуловимые традиционными методами особенности употребления слов и фразеологизмов.

Огрехи словарей прошлого вполне объяснимы, но в XXI веке лексикограф не имеет права работать по старинке и манкировать легкодоступными текстовыми массивами».

(*Беликов В.И., Ахметова М.В. Статистическая оценка функциональных свойств лексики по материалам Интернета // Компьютерная лингвистика и интеллектуальные технологии: По материалам ежегодной Международной конференции «Диалог-2009» (Бекасово, 27 – 31 мая 2009 г.). Вып. 8 (15). М.: РГГУ, 2009. С. 25 – 30*).

Приложение 4

Тема 6

НАЦИОНАЛЬНЫЙ КОРПУС И ТРЕБОВАНИЯ К ЕГО СОЗДАНИЮ

В.А. Плунгян

Зачем нужен Национальный корпус русского языка? Неформальное введение

«<…> Что же такое Национальный корпус?

В данном случае слово «национальный» — своего рода термин, отражающий скорее семантику английского слова «national», чем русского слова «нация». Впервые это определение появилось в названии Британского национального корпуса (British National Corpus, BNC), созданного в 1990-е годы в Великобритании специалистами-лексикографами; это не самый первый электронный корпус, созданный в мире, но один из лучших, крупнейших и наиболее известных. Для британцев слово «национальный» означало в первую очередь «характеризующий британский национальный вариант английского языка» (в отличие от американского, австралийского и т.п.), но поскольку этот корпус очень быстро стал практически эталоном корпуса вообще, то значение слова «национальный» незаметно изменилось. Национальным корпусом стали называть просто самый большой и представительный корпус, характеризующий язык данной страны в целом. Таким, например, оказался Чешский национальный корпус (Český národní korpus), содержащий практически исчерпывающую коллекцию текстов на чешском литературном языке разных периодов.

Понятно, что Национальный корпус должен быть прежде всего большим: его объем измеряется сотнями миллионов словоупотреблений (для сравнения можно сказать, что, например, полное собрание сочинений Ф.М. Достоевского насчитывает «всего» около двух миллионов слов). Но, кроме того, он – и это даже важнее – должен быть представительным. Иначе говоря, он должен содержать все типы текстов, представленные в данном языке в данный исторический период, и при этом содержать их в правильной пропорции.

Именно поэтому Национальный корпус русского языка не ограничивается, например, только произведениями художественной литературы XIX и XX века, сколь бы важны они ни были для изучения русского языка. Он содержит и газетные, и журнальные статьи разной тематики (от общественно-политических до, например, спортивных), и специальные тексты (научные, научно-популярные и учебные по разным отраслям знания), и рекламу, и частную переписку, и дневники. Словом, в Корпус попадают образцы практически любого существующего в русском языке письменного дискурса – от статьи современного музыкального критика до инструкции по уходу за кактусами, от рассказов Пелевина до справочника по физике. Более того, составители Корпуса хорошо понимали, что для полного и адекватного представления о том, что происходит в современном русском языке (или, если угодно, *с* современным русским языком) необходимо еще в большей степени расширить рамки Корпуса и включить в него, наряду с письменными текстами, также и записи устной речи. В настоящее время эта работа делается.

Почему образцы устной речи так важно иметь в Корпусе? Люди пишут не так, как говорят; в особенности это различие ощутимо для языков с давней письменной традицией, за время существования которой нормы письменной и устной речи успевают разойтись достаточно сильно. Письменная речь всегда более консервативна; к тому же, например, в русском языке письменная традиция формировалась под сильным иноязычным влиянием (первоначально старославянским, впоследствии немецким и французским), которое гораздо меньше затронуло устную речь. В этом отношении русский язык не исключение: сходным образом дело обстоит во многих европейских письменных языках, от чешского до французского, а также во многих письменных языках Азии с древней литературной традицией.

Таким образом, если мы хотим выявить наиболее динамичные структуры живого русского языка и если мы хотим хотя бы отчасти заглянуть в будущее русского языка, мы должны обратиться к стихии устной речи, не скованной традицией и нормой. Многое в устной речи поражает – но, с другой стороны, многие конструкции, существующие в современной устной стихии, неожиданно всплывают в документах времен Алексея Михайловича и даже в новгородских берестяных грамотах XII – XIV веков.

Источником устных текстов для нас являются, например, записи радиопередач, интервью, круглых столов и т.п., а также тексты, полученные в более неформальной обстановке, – например, беседы социологов или маркетологов с целевыми группами респондентов на определенную тему (качества какого-либо товара, социальные проблемы, личные обстоятельства участников беседы и т.п.): в таких ситуациях люди, как правило, говорят достаточно свободно и естественно. Но, не ограничиваясь этим, мы ведем также записи бытовых разговоров (диалогов и монологов) на улице, в учреждениях, в домашней обстановке. В таких записях участвуют группы добровольцев из разных регионов России, так как в Корпусе, конечно, должны быть образцы речи не только жителей крупных столичных городов. Сразу следует добавить, что отдельной проблемой является включение в Корпус образцов не общерусского языка (пусть и в его разговорном варианте), а настоящей диалектной речи. Такие образцы мы тоже надеемся со временем в Корпус включить.

<…>

Если посмотреть на пропорции разных типов текстов в Корпусе, то окажется, что доля собственно художественных текстов (проза и драматургия) не так уж велика: она составляет около 40 %, т.е. меньше половины. При этом в число художественных текстов включается и мемуарная проза, которая очень интересна и показательна с точки зрения языка, но многими исследователями справедливо квалифицируется как жанр промежуточный между художественной литературой и чистым «non-fiction». Это во многом противоречит установкам традиционной отечественной филологии (вообще явно или неявно ставившей знак равенства между изучением русского языка и изучением русского *литературного* языка, т.е. языка художественной литературы). Сам термин «литературный» язык (обозначающий на самом деле скорее не литературный в прямом смысле, а просто общенациональный нормативный, т.е. *стандартный* язык) отчасти предполагает, что наиболее престижная и «правильная» часть текстов, создаваемых на данном языке, – это тексты художественной прозы. Между тем такая точка зрения как минимум не очевидна и требует доказательств. Верно ли, что язык писателей (в том числе выдающихся писателей) и общенациональный язык – это одно и то же? В общем случае это, конечно же, не так – и тем более это утверждение не соответствует действительности во второй половине XX века и начале нынешнего века, когда социальное значение художественной литературы (и, как следствие, идейно-стилистические установки современных постмодернистов) радикально изменилось в сравнении с концом XIX – началом XX века. Поэтому в Национальном корпусе русского языка художественные тексты представлены в большом количестве, но они не доминируют. Интересно, что в корпусах европейских языков эта доля еще более низкая и, как правило, не

превышает 20 %, так что Национальный корпус русского языка всё равно остаётся одним из самых «литературоцентричных». <…>

И вот собранное вместе всё это богатство, отражающее, как можно надеяться, современный русский язык после 1955 года во всех его аспектах, стилях, жанрах и формах существования (планируется разместить тексты общим объемом до 100 миллионов словоупотреблений <…>), позволяет любому человеку искать любые слова или сочетания слов в определенной грамматической форме или просто определенные грамматические формы. Говоря более техническим языком, возможен поиск по морфологическим параметрам. Кроме того, поиск возможен не только по всему корпусу, но и по определенному подмножеству текстов, выбранному пользователем: например, тексты определенного автора, определенного периода, определенного жанра и т.п. (естественно, в любых комбинациях).

<…>»

(*Плунгян В.А. Зачем нужен Национальный корпус русского языка? Неформальное введение // Национальный корпус русского языка: 2003 – 2005. М.: Индрик, 2005. С. 7 – 9, 11 – 12*).

Приложение 5

Тема 8

ВИДЫ ЛИНГВИСТИЧЕСКОГО АННОТИРОВАНИЯ

М.В. Копотев, Л. Янда

Национальный корпус русского языка (www.ruscorpora.ru)

«<…>

III. Проблемы и решения

III. 1. Теоретическая эклектичность

Один из «постулатов аннотирования», сформулированных Дж. Личем, определяет теоретические основания аннотирования так: «Annotation schemes should preferably be based as far as possible on ‘consensual’, theory-neutral analyses of the data[3]» [Leech 1993: 275]. Несмотря на это, существуют языковые ба-

[3] Схема аннотации должна быть основана на как можно более «обобщенном», теоретически нейтральном анализе данных.

зы данных, которые связаны с определёнными теоретическими установками [например, проект FrameNet (www.icsi.berkeley.edu/~framenet), основанный на жёстких принципах семантического описания]. В этих случаях разметка единиц более или менее точно соответствует исходным теоретическим положениям разработчиков.

Однако очевидно, что проект общедоступного многоярусного корпуса должен следовать постулату Дж. Лича. И в этой сфере разработчики русскоязычного корпуса сталкиваются с первой серьёзной проблемой.

В НКРЯ… представлена морфологическая, лексико-семантическая информация, а также частично словообразовательная и синтаксическая. Однако ясно, что степень полноты и общепризнанность классификаций языковых уровней существенно различается. Так, например, в научной литературе по морфологии могут дискутироваться вопросы о количестве русских падежей, но, как кажется, не вызывает сомнения сам факт существования категории падежа. В области синтаксиса, как известно, такого единства нет. Широко распространённая в практике преподавания классификация, опирающаяся на представление о главных и второстепенных членах предложения, не может считаться общепризнанной; современные синтаксические теории, описывающие синтаксические отношения в виде дерева зависимостей, не имеют прямой корреляции с теорией главных/второстепенных членов предложения, метаязык «грамматики конструкций» Ч. Филлмора не может быть согласован с положениями «Русской грамматики» 1980 года и т.д. (Грамматика-80).

Трудно представить корпус, который смог бы объединить все теории, поэтому многоярусный корпус неизбежно (во всяком случае, в обозримом будущем) оказывается или эклектичным, или узконаправленным. К этому добавляется и техническая проблема: если большинство программ автоматического морфологического аннотирования русского языка базируется на «Грамматическом словаре» А.А. Зализняка, то в основе алгоритмов синтаксических парсеров часто лежат разные синтаксические теории, среди которых синтаксис в духе Грамматики-80 не является самым популярным. Ещё больше сложностей возникает при описании семантического компонента языковых единиц.

Осознавая проблему теоретической эклектичности, создатели НКРЯ выбирают разные подходы для разных языковых уровней. Если морфология в НКРЯ представлена в достаточно традиционном виде… и не апеллирует к специальным сведениям, выходящим за базовые знания выпускника филологического факультета, то семантическая разметка представляет собой воплощение на широком языковом материале оригинальной системы семантических дескрипторов, которая требует предварительного знакомства со справкой на сайте или – в идеале – с соответствующими работами авторов… Ко-

нечно, такую систему семантической разметки ни в коем случае нельзя назвать недостатком, поскольку она оказывается гораздо более полной и строгой, чем существующие «традиционные» классификации лексики. С другой стороны, синтаксическая разметка… будет гораздо менее подробной и ограничится лишь «малым» синтаксисом (на уровне словосочетания).

Таким образом, эклектичность и неравномерная представленность разных языковых уровней в НКРЯ выявляет две существенные проблемы современной лингвистики: отсутствие полных теоретически обоснованных и общепринятых классификаций, с одной стороны, и сложность (граничащая с невозможностью) автоматического аннотирования на основе этих классификаций – с другой. Всякий языковой корпус в силу необходимости тотального описания материала кристаллизует проблемные области в описании того или иного языка. И в этом смысле НКРЯ является не только инструментом для быстрого поиска примеров, но и бесконечным источником совершенствования теоретических и чисто дескриптивных подходов к русскому языку.

<…>»

(*Копотев М.В., Янда Л. Национальный корпус русского языка (www.ruscorpora.ru) (рец.) // Вопросы языкознания. 2006. № 5. С. 151*).

Д.О. Добровольский, А.А. Кретов, С.А. Шаров

Корпус параллельных текстов: архитектура и возможности использования

«**1**. Корпус параллельных текстов (**КоПарТ**), входящий в качестве самостоятельного модуля в Национальный корпус русского языка, состоит из множества художественных произведений с их переводами. Корпус включает в себя, с одной стороны, оригинальные русские тексты с их переводом на английский язык, а с другой – английские тексты с их переводом на русский. <…>

Корпус параллельных текстов постоянно пополняется. Предполагается, что в дальнейшем он будет расширяться как за счёт произведений других авторов и жанров, так и за счёт других (помимо английского) языков перевода. Имеющийся на сегодня корпус может рассматриваться как пилотный. Выбор включённых в него текстов был мотивирован в первую очередь их высоким литературным качеством, а также наличием переводов на другие языки. Выбор языков пилотного корпуса мотивирован следующими соображениями. Понятно, что на первом этапе было бы нецелесообразно использовать в качестве параллельных русскому сразу несколько языков, так как каждый из них

обладает своими особенностями, которые, возможно, могли бы повлиять на процесс выравнивания. То, что в качестве «пилотного» языка был выбран именно английский, объясняется несколькими – прежде всего техническими – причинами. Графика английского языка не содержит диакритических знаков, что делает обработку английских текстов на машинных носителях более лёгкой. Кроме того, английские тексты оказались наиболее доступными. Поиск электронных версий переводов русской литературы на другие языки часто сопряжён со значительными техническими трудностями.

<…>

2. В настоящее время разрабатываются программные средства выравнивания параллельных текстов; кроме того, создаётся система управления корпусом, призванная удовлетворить запросы пользователей. КоПарТ обеспечен программой **ПарТекс** <…>, имеющей на входе два параллельных текста (оригинал и перевод). Выравнивание осуществляется на уровне предложений. Программа выдаёт на выходе синтезированный текст, в котором последовательно за каждым предложением оригинала следует соответствующее предложение перевода. В таком синтезированном тексте поиск интересующих пользователя слов может осуществляться штатными средствами обычных текстовых редакторов, например, таких, как «Майкрософт Ворд». В программе ПарТекс для поиска может быть «подстрока в строке» и на выход подаётся текстовый файл, в который входят все пары предложений оригинала и перевода, содержащие заданную последовательность символов. Возможен поиск как английских, так и русских слов или словосочетаний.

Одна из наиболее существенных трудностей выравнивания заключается в том, что авторское членение текста на предложения и абзацы не всегда выдерживается в тексте перевода… Кроме того, в разных языках (а иногда и разных изданиях) приняты различные способы графического оформления, что иногда затрудняет определение границ предложения в автоматическом режиме. Ср., например, различные способы оформления переходов от прямой речи персонажей к авторским ремаркам. В таких случаях результаты автоматического выравнивания нуждаются в коррекции, осуществляемой вручную. Программа позволяет обнаружить в параллельных текстах асимметрию такого рода.

Алгоритм обнаружения асимметрии прост: количество глав оригинала сравнивается с количеством глав перевода, и в случае неравенства выдаётся сообщение об асимметрии. В случае равенства числа глав осуществляется переход на следующий уровень членения текста. В каждой из глав, начиная с первой, сравнивается количество абзацев. В случае неравенства выдаётся сообщение об асимметрии, в случае равенства осуществляется переход к анализу следующей главы. После выравнивания по абзацам осуществляется пере-

ход к выравниванию по предложениям. Сравнивается количество предложений в первом абзаце оригинала с количеством предложений в первом абзаце перевода, при несовпадении выдаётся сообщение об асимметрии, при совпадении количества предложений в первом абзаце оригинала и перевода осуществляется переход к анализу второго абзаца.

Для решения собственно лингвистических задач (в первую очередь в области сопоставительной лексикологии и двуязычной лексикографии) важны отношения типа *слово – слово*, *слово – словосочетание* и *словосочетание – слово*. Такие пары могут быть названы *функционально эквивалентными фрагментами* (ФЭФ). Типовая поисковая задача пользователя может быть сформулирована так: *Извлечь все случаи употребления слова L (в оригинале) и его ФЭФ (в переводе)*. При решении этой задачи могут быть использованы как минимум две стратегии, назовем их *тотальной* и *импликативной*.

Тотальная стратегия нахождения ФЭФ состоит в следующем. Исходный текст – последовательная цепочка символов, адрес каждого из которых равен числу натурального ряда. Адрес каждого слова в исходном тексте задаётся интервалом между адресом первого и адресом последнего символа включительно. Если длина исходного текста = D^1, а длина переводного текста = D^2, то можно составить пропорцию и с её помощью получить адрес предполагаемого ФЭФ. Например, $D^1 : D^2 = AdrL : AdrX$, где AdrL - длина текста от начала до первого символа искомого слова, а AdrX – длина параллельного текста от начала до первого символа предполагаемого ФЭФ.

<…>

…Понятно, что по мере удаления от начала текста размер ошибки в абсолютных единицах будет увеличиваться. Именно поэтому практическая польза от тотальной стратегии будет убывать по мере роста величины AdrL, т.е. пропорционально расстоянию от начала текста до интересующего нас фрагмента текста.

Импликативная стратегия поиска ФЭФ ориентирована на границы, задаваемые архитектоникой текста. Адрес искомого слова *L* задаётся последовательным сужением зоны поиска, т.е. пошагово: номер тома, главы в томе, абзаца в главе, предложения в абзаце, слова в предложении. Аналогичным образом ищется предложение, содержащее предполагаемый ФЭФ переводного текста. При этом оптимальный результат достигается в том случае, когда количество единиц на каждом из уровней членения текста совпадает.

Практика показывает, что у каждого из методов есть как свои достоинства, так и свои недостатки. Тотальная стратегия универсальна, но неточна. Ошибка в определении адреса ФЭФ пропорциональна размеру текста. Импликативная стратегия точна, но не универсальна, поскольку предполагает изоморфное членение параллельных текстов. Прежде чем пользоваться им-

пликативной стратегией, следует убедиться, что у параллельных текстов одинаковое количество абзацев, а в каждом из абзацев – одинаковое количество предложений. Если количество абзацев и предложений не одинаковое, следует либо отказаться от импликативной стратегии, либо восстановить параллелизм текстов в данном отношении. Второе решение предпочтительнее, прежде всего из-за неточности тотальной стратегии.

Таким образом, необходимо создать программу, которая сравнивала бы тексты в их естественных границах, обнаруживала асимметрию в количестве абзацев и предложений и выдавала информацию о местах этой асимметрии пользователю. Имея эту информацию, пользователь может восстановить формальную (по количеству абзацев и предложений) симметрию параллельных текстов и тем самым обеспечить успешную реализацию импликативной стратегии поиска ФЭФ. После такого предредактирования параллельных текстов становится возможным автоматический поиск ФЭФ для любого содержащегося в тексте оригинала слова. Функциональные роли «исходный текст» и «параллельный текст» задаются самим пользователем, что обеспечивает гибкость программы и возможность анализа как от оригинала к переводу, так и наоборот.

Принципиально возможны и другие способы выравнивания параллельных корпусов. Ср. способ выравнивания Австрийской академии наук в Вене – Austrian Academy Corpus… Подлежащие выравниванию тексты предварительно разбивались на предложения по определённым принципам, единым для оригинала и переводов. Такое членение текста предполагает тщательное постредактирование результатов автоматической разбивки, позволяющее ориентироваться на определённые синтаксические структуры, а не на употребление знаков препинания: точки, вопросительного и восклицательного знаков. Подобная предварительная обработка текстов, подлежащих выравниванию, существенно повышает качество конечных результатов, получаемых с помощью специальных программ выравнивания в полуавтоматическом режиме.

После выравнивания параллельных текстов КоПарТа по предложениям было проведено морфологическое аннотирование и лемматизация полученного корпуса с использованием тех же средств, что и в Национальном корпусе русского языка в целом <…>

<…> Механизм поиска в параллельном корпусе позволяет искать по лемме, точной словоформе, морфологическим признакам или их комбинации. Также возможно использование в запросе стандартных регулярных выражений, например, **.*[а-я]** и т.п.

Поиск по лемме является наиболее простым способом поиска, который позволяет найти все формы одного слова: запрос **стакан** находит все формы

(*стакан, стакана, стаканом*). Задание нескольких лемм (в их словарной форме) соответствует поиску фразы, например, запрос **один слово** находит фразы *одним словом, ни одного слова* и т.п. Для поиска точной формы каждую словоформу надо заключать в кавычки, например, запрос **«ни» «одного» «слова»** найдёт ровно эти примеры. <…>

В результате создатели двуязычных словарей, переводчики, все лингвисты, работающие с параллельными текстами, получают весьма простой и эффективный инструмент сбора материала. Ценность этого инструмента определяется тем, что в лингвистике этап сбора материала является наиболее трудоёмким и наименее творческим, а подобные корпусы параллельных текстов позволят сэкономить время и силы для собственно исследовательской работы».

(*Добровольский Д.О., Кретов А.А., Шаров С.А. Корпус параллельных текстов: архитектура и возможности использования // Национальный корпус русского языка: 2003 – 2005. М.: Индрик, 2005. С. 263 – 271*).

Приложение 6

Тема 9

РАЗЛИЧНЫЕ ТЕХНОЛОГИИ РАЗМЕТКИ

О.Н. Ляшевская, В.А. Плунгян, Д.В. Сичинава

О морфологическом стандарте Национального корпуса русского языка

«0. Введение

Существующий опыт теоретического обсуждения и практического создания морфологически размеченных корпусов показывает, что можно выделить две крайности в подходах к аннотированию языковых единиц. Первый подход, который можно назвать «формально-морфологическим», предполагает, что каждой встреченной в тексте словоформе, отличающейся по внешнему виду от других словоформ, присваивается некоторый ярлык, вне зависимости от реально стоящей за ней грамматико-семантической или синтактико-семантической информации. Например, русской словоформе *брата* всегда приписывается ярлык «родительный падеж», даже если в некотором контексте эта словоформа с точки зрения «школьной» грамматики интерпретируется как винительный падеж: *Я привел своего брата*. То же касается информа-

ции о лексемной принадлежности словоформы: у омонимичных словоформ типа *были* (от глагола *быть*) и *были* (от существительного *быль*) исходной формой всегда будет считаться инфинитив глагола *быть*.

Второй подход, который можно назвать «углублённым семантическим», нацелен на извлечение как можно более полной семантической информации, связанной с данной словоформой. Примером ярлыков в корпусе, размеченном согласно такой идеологии, могли бы служить пометы «настоящее историческое время» (для словоформ *приходит* и *смотрит* во фразе *А он вчера приходит и смотрит как-то странно*) или «будущее в значении вежливого побуждения» (для словоформы *передадите* во фразе *Не передадите ли вы мне соли?*).

Формально-морфологический подход часто применяется в прикладной лингвистике – в особенности в системах, где используется сплошное автоматическое аннотирование текстов. Он выгоден тем, что позволяет разметить огромные массивы текстов без участия человека (программа-парсер приписывает информацию, руководствуясь электронными морфологическими словарями-указателями словоформ). Кроме того, он прост (для установления морфологических характеристик программе не требуется анализировать контекст), удобен для статистических исследований, а отсутствие морфологической омонимии в разметке (т.е. ситуации, когда одной словоформе приписывается несколько конкурирующих морфологических разборов) позволяет избежать «комбинаторного взрыва» при автоматическом построении различных синтаксических и семантических гипотез.

Главный недостаток чисто морфологического подхода становится очевиден, если размеченный таким способом корпус предлагается пользователю-человеку (будь то лингвист, школьник, иностранец, изучающий русский язык и т.п.). Неподготовленный пользователь будет, по-видимому, весьма озадачен, получив по запросу «винительный падеж» только формы единственного числа женского рода на *–у/-ю* или узнав, что в русском языке именительный падеж употребляется после предлога *за* (ср. *Что* ***за прелесть*** *эта Наташа*). Таким образом, формально-морфологический подход предлагает совершенно иной взгляд на грамматику русского языка, идущий вразрез со сложившейся грамматической традицией, и это противоречие делает такой корпус малопригодным, в частности, для использования в качестве экспертной системы по русскому языку.

С другой стороны, разметка текста в соответствии с углубленным семантическим подходом предполагает кропотливую работу лингвиста-эксперта, который анализирует особенности контекста, интонационные характеристики высказывания и т.п. К сожалению, пока не существует компьютерных программ, которые были бы способны заменить человека на этом направле-

нии и обеспечить должный уровень адекватности, а значит, нереально обработать таким образом значительные объемы текстов. Вместе с тем стремление к максимальной детализации грамматического значения таит иную опасность. Разметка субъективна, поскольку зависит от интуиции эксперта, и следовательно, повышается вероятность, что другой носитель русского языка (или другой специалист) окажется не согласен с предлагаемой трактовкой грамматического значения словоформы.

Таким образом, каждая из представленных крайних точек зрения имеет свои достоинства и недостатки. В связи с этим идеальным балансом между ними кажется такой подход к морфологической разметке текста, при котором словоформы размечаются на уровне традиционных грамматических ярлыков, таких, как «родительный падеж» или «настоящее время», а омонимичным словоформам приписывается только одна и «правильная» (т.е. общепринятая в русской грамматической традиции) характеристика. Именно такой взгляд на устройство морфологической разметки сформировался в лингвистическом коллективе, разрабатывающем Национальный корпус русского языка… Предполагается, что глубина семантической информации о грамматических формах достаточна для большинства пользователей корпуса[4], а задача выбора нужного значения в принципе алгоритмизуема; тем самым морфологическая разметка больших по размеру корпусов может быть осуществлена, по крайней мере в значительной части, при помощи компьютерной программы.

Однако информация о потенциальной грамматической многозначности словоформы, т.е. о морфологической омонимии, также не бессмысленна. Два вида размеченных текстов – один со снятой омонимией и другой, в котором омонимичным словоформам приписаны все возможные морфологические разборы, – могут быть полезны не только для тренировки «обучаемых» прикладных программ, но и для лингвистов, задавшихся вопросом: почему человек «не замечает» морфологической омонимии в тексте, например, почему он не понимает форму *мыла* во фразе *Мама мыла раму* как форму родительного падежа существительного *мыло*?

Корпус современного русского языка (вторая половина XX – начало XXI в.) состоит из двух подкорпусов – со снятой и с неснятой грамматической омонимией. Разметка корпуса с неснятой омонимией осуществляется автоматически, тогда как разметка корпуса со снятой омонимией в настоящее

[4] Исследователь семантики грамматических категорий сможет сам провести необходимую детализацию значения, выбрав из предоставленного материала, например, по употреблениям форм настоящего времени, примеры на «обычное» настоящее и настоящее историческое. Скорее всего, разные исследователи сделают это по-разному.

время происходит в полуавтоматическом режиме… и требует участия человека. <…> В связи с этим корпус с неснятой грамматической омонимией существенно превышает по размеру корпус со снятой грамматической омонимией. В поисковой системе, расположенной на сайте *ruscorpora.ru*, пользователь может задать ограничение на поиск по корпусу только со снятой или только с неснятой омонимией. Поиск по корпусу с неснятой омонимией дает гораздо больше языкового материала, но поскольку омонимичные формы в нем получают весь возможный набор морфологических характеристик, поисковая выдача по этим текстам содержит значительное количество «шума». Однако необходимо понимать, что разборы в корпусе с неснятой омонимией не являются ошибочными – они имеют другой статус: статус гипотетических разборов».

(*Ляшевская О.Н., Плунгян В.А., Сичинава Д.В. О морфологическом стандарте Национального корпуса русского языка // Национальный корпус русского языка: 2003 – 2005. Результаты и перспективы. М., 2005. С. 111 – 114*).

В.Б. Касевич, А.В. Венцов, Е.В. Грудева, Н.А. Слепокурова, Е.А. Сведенцова и др.

О морфологии в Национальном корпусе русского языка[5]

«<…>

Каждое словоупотребление должно получить морфологическую характеристику, т.е. ему должны быть приписаны морфологические дескрипторы. Стоит подчеркнуть, что лишь работа над корпусом может – в идеале – решить вопросы морфологии и, шире, грамматики в достаточно полном объеме. Дело именно в том, что при осуществлении морфологической разметки мы просто вынуждены тем или иным способом характеризовать **все** грамматические явления, встречающиеся в текстах. У нас нет выбора, мы не вправе что бы то ни было опустить, заменить один пример другим, укрыться за словосочетания *и т.д.*, *и в некоторых других случаях* и т.п. Фактически грамматика, претендующая на полноту, может быть создана только на базе репрезентативного корпуса.

Каковы основные принципы – и основные технологические приемы – морфологической разметки? Теоретически здесь возможны два подхода.

[5] В данной статье речь идёт о Корпусе, который позднее был переименован: в настоящий момент он носит название «Корпус русского литературного языка» (сокращённо – КРЛЯ) и размещён на сайте www.narusco.ru (сноска моя. – *Е.Г.*).

Первый, более распространенный, заключается в том, что морфологическая разметка осуществляется непосредственно в тексте с использованием специально разработанных программ-taggers. Эти программы опираются обычно на предварительную синтаксическую разметку, формальные признаки словоформ, сведения о частотности и т.п. Как правило, такого рода информации оказывается недостаточно, в результате размеченные тексты содержат в морфологических дескрипторах неприемлемое число ошибок и требуют очень существенного ручного постредактирования.

То же самое можно сказать о методах акцентуирования текстов, где ситуация принципиально не отличается от описанной для морфологической разметки. В принципе, опираясь на морфонологические закономерности русской акцентуации, можно проставить ударения непосредственно в текстах. Но это (предполагая, естественно, разработку не вполне тривиальной программы) дает адекватный результат (часто вероятностный) на материале части словоформ и производных слов, на материале же простых исходных словоформ правила не работают (что и демонстрируется известными речевыми ошибками вроде *нАчать* вместо *начАть*). Объединяя эти две проблемы, следует констатировать, что вариант «**сначала** морфологическая разметка, а затем – акцентуация» в лучшем случае неудачен, в худшем – невозможен. Дело в том, что морфологическая разметка неакцентуированного текста затруднена наличием большого числа (более 4 тыс.) омографов, поэтому, не зная места ударения, мы не можем часто определить, с какой словоформой имеем дело (напр., *любИм* или *лЮбим*). Кроме того, имеющиеся на сегодня программы практически не способны акцентуировать уже размеченный (морфологически) текст.

Соответственно становится более привлекательным второй из возможных подходов. Он заключается в том, что как акцентуация (и введение буквы **ё**), так и морфологическая разметка осуществляются сначала *в словаре*. На начальной стадии работы словарь может быть сравнительно небольшого объема. Это позволяет нам снабдить – вручную, разумеется – каждую словоформу словаря максимально подробным и выверенным набором морфологических дескрипторов. Затем тексты «прогоняются» через программу, которая ставит каждую словоформу текста в соответствие словоформе словаря, т.е. производит их идентификацию, и переносит на единицы текста характеристики единиц словаря. Если в тексте встречается единица, отсутствующая в словаре, программа предлагает ее описать в принятой системе терминов-дескрипторов (задавая при этом как набор дескрипторов, так и порядок их введения); по завершении этой работы «новая» единица заносится в словарь вместе со своим описанием. Тем самым словарь постоянно пополняется – и это происходит до тех пор, пока не будет принято решение о достаточной ре-

презентативности словаря (ее критерии – отдельная проблема; одновременно можно заметить, что решение о прекращении пополнения словаря не может быть абсолютным – ведь словарь носителей языка постоянно пополняется, что находит свое отражение в текстах. Т.е. фактически *возможность* прекращения пополнения словаря выступает лишь временной и условной, в то время как *необходимость* пополнения – постоянна и безусловна).

Существенной чертой морфологического описания единиц словаря и текста является то, что для каждого класса единиц набор дескрипторов и порядок их введения при морфологической разметке есть *характеристика постоянная*. В этом легко видеть прямую связь с принципами грамматики порядков, только здесь эти принципы переносятся на метаязыковой уровень. С принципами грамматики порядков наш подход сближает и логическое следствие из принятого требования к постоянству набора дескрипторов: если некоторая характеристика, предусмотренная системой дескрипторов для единиц данного класса, оказывается отсутствующей (невозможной, неприменимой), ее отсутствие фиксируется символьно определенным пробелом в цепочке дескрипторов или введением нуля. Например, в сослагательном наклонении или в императиве глаголы не различаются по временам, но эта характеристика считается неотъемлемым признаком глагола, а потому ее отсутствие в описании отмечается. (Здесь тоже очевидны параллели с проблемами, рассматриваемыми в разных разделах лингвистики при описании языковых единиц. Напр., в фонологии есть точка зрения, согласно которой при существовании в системе некоторого ДП все фонемы, как-то согласующиеся с наличием данного ДП, помечаются этим признаком. При таком подходе русские сонанты – звонкие фонемы. Более адекватна другая точка зрения, согласно которой признак «звонкость/глухость» иррелевантен для сонантов.) Наш подход строится на компромиссе. Не претендуя на окончательное *лингвистическое* решение проблемы, мы учитываем потребности компьютерной обработки текста: поисковой системе значительно легче осуществлять поиск в словаре и тексте, если каждая характеристика обладает позиционной закрепленностью – но эта закрепленность нарушается, если какие-то из характеристик изымаются из описания, не оставляя при этом «следов». (В данном случае уместно вспомнить о теории следов в генеративной лингвистике.)

<…>»

(*Венцов А.В., Грудева Е.В., Касевич В.Б., Сведенцова Е.А., Слепокурова Н.А. О морфологии в Национальном корпусе русского языка // Материалы XXXIII Международной филологической конференции (15 – 20 марта 2004 г., Санкт-Петербург). Вып. 24. Секция общего языкознания. Ч. 2. СПб.: ОНУТ Филол. ф-та СПбГУ, 2004. С. 3 – 8).*

М.В. Копотев, Л. Янда

Национальный корпус русского языка (www.ruscorpora.ru)

«<…>

III. 2. «Машинная грамматика» русского языка и её отношение к «большой» лингвистике

Вторая проблема, встающая перед создателем аннотированного корпуса, связана с дилеммой объём материала vs. точность обработки. Одним из промежуточных итогов компьютерной лингвистики стало признание факта невозможности точного автоматического анализа текста. Для русского языка, богатого флективным словоизменением и омонимичностью грамматических показателей, создание анализатора, безошибочно производящего дизамбигуацию (снятие неоднозначности), практически невозможно. На сегодняшний день качественное аннотирование русского текста всегда связано с существенной ручной «постобработкой», проводимой квалифицированными специалистами. В этом смысле при относительной ограниченности организационных возможностей перед создателями любого корпуса всегда стоит выбор: сравнительно небольшой, но выверенный корпус или объёмный, но аннотированный автоматически.

Разрешая эту дилемму, создатели языковых корпусов вынуждены идти на более или менее серьёзные упрощения лингвистических классификаций, выбирая между скоростью обработки материала и точностью интерпретаций. Фактически речь идёт о том, что разработчики принимают те или иные решения, которые противоречат языковой реальности или лингвистическим представлениям; принятие этих решений часто связано не с теоретическими установками создателей, а с задачей облегчения автоматической обработки. Создатели НКРЯ тоже должны были идти на подобные компромиссы, вызванные и пробелами в описании системы русского языка, и требованиями автоматической обработки. Не обсуждая мотивировок, заставивших разработчиков прийти к тому или иному решению, приведём список таких допущений.

а. Не разводятся лексические омонимы. Пользователя НКРЯ не должно вводить в заблуждение то, что авторы корпуса предлагают поиск в подкорпусе со снятой омонимией. Речь идёт только об устранении грамматической неоднозначности (например, существительное и глагол ПЕЧЬ). Лексические омонимы в корпусе считаются одной леммой, в силу этого поиск только одного члена полной омонимичной пары невозможен. Так, например, запрос «ЛУК: существительное: ‘оружие’» выдаёт и контексты такого рода: *Золотистые связки лука над крыльцом* [Сергей Довлатов. Заповедник (1983)].

b. Не учитываются (или недостаточно учитываются) следующие многокомпонентные единицы.

• Формы сослагательного наклонения глагола: *прочитал бы, сходил бы* и более сложные случаи, как в предложении *Я хочу, чтобы студенты прочитали эту книгу*, в котором слившиеся частица и союз не отменяют аналитизма сослагательной формы *прочитали* [*бы*].

• Формы сложного будущего времени: *буду читать*.

• Аналитические формы прилагательных и наречий: *более быстрый, более быстро* (оставляем в стороне вопрос о спорности их выделения в «большой» лингвистике).

• Аналитические формы местоимений: *ни от кого*.

• Составные и дробные числительные: *сто сорок восемь, две третьих*. Записи «двадцать три» и «23» считаются разными единицами и состоят из разного количества лемм («лексем»). Добавим, что традиционные разряды числительных заменены основанными на морфологических критериях выделенными и интуитивно понятными «числительными» и «числительными прилагательными».

• Служебные фраземы (так называемые «эквиваленты слова»): *потому что, в течение* и т.д.). Список из 180 служебных фразем («сложных лексических единиц», по терминологии авторов) далёк от полноты. Оставляя в стороне полнозначные фразеологизмы типа *сесть в калошу*, которые тоже должны выделяться как отдельные единицы… отметим, что, по данным словарей, …список «сложных лексических единиц» должен быть увеличен примерно в 10 раз (например, отсутствуют такие очевидные кандидаты, как *в числе, в ногу, на износ, на зависть* и др.).

c. Не учитываются однословные морфологические признаки, сложные для автоматического анализа.

• Не выделены отдельно, а включены в категорию множественного числа формы Pluralia tantum.

• Текстоформы типы *красивее* (КРАСИВО, КРАСИВЫЙ) считаются одной формой. Так, запрос «прилагательное в форме компаратива» возвращает среди результатов предложение *Моторы ревели теперь ровнее, и ящики успокоились* [И. Грекова. На испытаниях (1967)].

• Отсутствуют собственные/нарицательные существительные. Параметра «антропонимы» в семантической разметке, очевидно, недостаточно, поскольку в русском языке есть, например, топонимы, омонимичные именам нарицательным.

• В списке частей речи без достаточного теоретического обоснования указана такая часть речи, как «вводное слово». Надо отметить, что эту кате-

горию-«призрак» можно найти во многих словарях русского языка, в том числе и в «Грамматическом словаре» А.А. Зализняка. Однако нам неизвестны классификации, в которых бы фигурировала такая часть речи.

• Без достаточных объяснений местоимения разделены на морфологически мотивированные местоимения-существительные, местоимения-прилагательные, местоимения-предикативы, местоименные наречия (традиционные разряды местоимений отнесены к семантическим признакам). И хотя эта классификация выглядит обоснованной, поиски некоторых местоимений оказываются непростой задачей (а поиск реципрока *друг друга* по морфологическим показателям вообще невозможен).

Подводя итог этой части рецензии, необходимо признать, что в настоящее время (как, кажется, и в обозримом будущем) могут существовать два разнонаправленных принципа создания русскоязычных корпусов, в силу того, что объём материала и точность аннотирования представляются на практике взаимоисключающими критериями. В то же время оба подхода имеют своё право на существование, и оба вполне оправданы при подготовке современных корпусов. Так, относительно небольшой корпус ХАНКО позволяет искать формы сослагательного наклонения, аналитического будущего, существительные Pluralia tantum и другие единицы, о которых речь шла выше, однако следствием ограниченного объёма является, например, то, что в нём нет ни одной звательной формы».

(*Копотев М.В., Янда Л. Национальный корпус русского языка (www.ruscorpora.ru) (рец.) // Вопросы языкознания. 2006. № 5. С. 151 – 153*).

Приложение 7

Тема 10

МНОГОКОМПОНЕНТНЫЕ ЕДИНИЦЫ В АННОТИРОВАННОМ КОРПУСЕ: КОРПУСНЫЙ И ПСИХОЛИНГВИСТИЧЕСКИЙ ПОДХОДЫ

А.В. Венцов, В.Б. Касевич, Е.В. Ягунова

Об идиомах в Национальном корпусе русского языка

«1. Неоднократно отмечалось, что существующие словари, толковые, частотные и иные, практически игнорируют гетерогенность единиц, реально

входящих в словарь. Сам термин «словарь» в известном смысле вводит в заблуждение: он предполагает, что единица (элемент) соответствующего множества – это всегда и неизменно *слово*: слова входят в словарь, а сочетания слов – нет; словосочетания порождаются в речевой деятельности из слов по правилам грамматики. При этом фактически не учитывается то важнейшее обстоятельство, что невключение словосочетаний (как и словоформ) в словарь объясняется именно возможностью их порождения *по правилам*: то, что поддаётся описанию через указание на набор элементов (слов) и соответствующие правила, излишне включать в словарь. Но существует очень много сложных, составных единиц, слагающихся из элементов, по формальным признакам являющихся словами (а слово – это прежде всего формально-грамматическая единица), но *не* образующихся по правилам. Соответственно они должны входить в словарь – хотя словами и не являются. Иначе говоря, в действительности словарь – это не множество *слов*, а *множество единиц, которые не образуются по правилам*… Единицы оказываются гетерогенными: среди них, конечно, абсолютно преобладают «традиционные» слова, но также достаточно обильно представлены словосочетания (и «иррегулярные формы слов»…).

2. При организации большого корпуса текстов – в нашем случае Национального корпуса русского языка, который предполагает морфологическую разметку, необходимым условием разметки выступает сегментация текстов на слова – опять-таки точнее будет сказать: на единицы, которые должны войти в словарь. Соответственно возникает проблема *критериев*, по которым выделяются такие единицы. Критерии не должны сводиться к правилам выделения *слов*: как уже было сказано, слово есть формально-грамматическое (формально-морфологическое) образование безотносительно к тому, функционирует оно самостоятельно или в составе сложного целого. Поскольку на базе корпуса строится семейство словарей, состав словаря непосредственно зависит от того, как сегментируется текст.

3. Нетрудно видеть, что сочетания слов, которые не образуются по правилам, это – в широком смысле – *идиомы*. Необходимо, как сказано, сформулировать правила выделения идиом; идиомы – это «по умолчанию» ***неоднословные*** *целостности* (НЦ), поэтому определению идиом должно предшествовать определение слов; этот этап описания мы пропускаем… Критерии же (правила) выделения (определения) идиом можно представить себе следующим образом. Идиоматичность фиксируется там, где (а) по крайней мере одно из слов не употребляется вне НЦ (в частности, вне именно данной идиомы), напр., *без умолку*; (б) в рамках НЦ нарушаются правила управления или согласования, напр., *в течение*; (в) ни одна из словоформ в составе НЦ не может быть опущена с сохранением семантики и функций НЦ – возможно, за

вычетом семантики опущенного слова (напр., *она всё равно не узнает* ⇒ **она всё не узнает* ⇒ **она равно не узнает*); иначе говоря, *всё равно* является идиомой, в отличие от, напр., *поодаль от*, ср. *она села поодаль от Петра* ⇒ *она села поодаль*, т.е. *поодаль от* не является идиомой.

4. Идиомы обладают частеречной принадлежностью. Напр., *бить баклуши* – это глагол (непереходный, наподобие *спать*), или, точнее, глагольная идиома, *невзирая на* – предлог (предложная идиома). Многие идиомы принадлежат к **вводным словам**. Эта категория представлена словами и словосочетаниями, которые **всегда** не включаются в синтаксическую структуру высказывания (они также обладают обычно специфическим просодическим оформлением). Напр., *как правило, по всей вероятности*. Вводные слова входят в словарь на правах особой части речи.

5. Категория «идиома» занимает в системе то же место, что категория «лексема». Однако из грамматической информации идиоме приписывается лишь частеречная принадлежность. Т.е. наличие маркера (дескриптора) IDI (или аналогичного), указывающего на идиоматичность соответствующего сочетания, по умолчанию снимает всю прочую грамматическую информацию, кроме частеречной.

6. Идиомы можно раскрывать, идентифицируя (маркируя) все входящие в них словоформы, как если бы они входили в неидиоматическое сочетание. В этом случае (решение принимается как конвенциональное) в словаре появляется некоторое количество фиктивных лексем (*баклуша* из *бить баклуши*, *обнимка* из *в обнимку* и т.п.). Такой результат объясняется особым свойством идиом: на них не распространяется принцип безостаточной членимости (на слова). Другое следствие операции по развёртыванию идиом – это перераспределение частотностей в частотном словаре. Ясно, что фиктивные лексемы наподобие *баклуша* будут иметь нулевую частотность применительно к своим словарным формам. Но, скажем, частотность слова *друг* из идиомы *друг друга*, ср. *они ненавидят друг друга*, в результате раскрытия идиомы «вольётся» в показатель частотности лексемы *друг*, что, скорее всего, будет искажением реальных отношений в лексической системе русского языка. Впрочем, эта проблема требует отдельного изучения. Дело в том, что из признания режима «поверхностного» восприятия речи, когда носитель языка идентифицирует (часто вероятностно) словоформы текста и синтаксические связи между ними при минимальном учёте семантики… может следовать возможность пословного восприятия словоформ в составе идиом – т.е. фактически с разрушением последних. Например, материально идентичные цепочки слов будут восприниматься одинаково в отвлечении от семантики, ср. *Друг друга они увидели ещё издалека* и *Друг друга всегда выручит*.

7. Отдельно следует рассматривать проблему сочетаний, не являющихся идиомами, но также неоднословных и – в некоторых случаях – потенциально неоднозначных. Мы имеем в виду сочетания знаменательного и служебного слова, в которых ударение переносится со знаменательного слова на предлог или иную клитику, напр., *на+ пол*, *из+ лесу* (знак «+» указывает на ударность слога слева от знака). Похоже, что только предлоги *на, за, по, под* и частицы *не, ни* (в ограниченном числе сочетаний) способны притягивать к себе ударение. Если перенос ударения ведёт к семантическому и функциональному сдвигу (здесь можно предложить и более формальные критерии), сочетание трактуется как *однословное* – иная часть речи, обычно наречие. Напр., *на+ухо, на+людях*. В прочих случаях сочетание трактуется как двусловное (***но*** одно фонетическое слово), неидиоматичное. Напр., *на+ пол*, *за+ спину*.

8. В связи с трактовкой рассматриваемых единиц возникает необходимость решения проблем, относящихся к составу словаря, а также к процедурам восприятия речи. В словарь, как можно предложить, включаются сочетания типа *на+ночь*, которые выше были признаны однословными. Предлоги и другие клитики входят в словарь с «собственным» ударением. Одновременно вводится правило, согласно которому в тексте сочетание «предлог (клитика) + существительное (знаменательное слово)» всегда имеет **одно** ударение; соответственно одно из ударений должно быть устранено. В результате для сочетания, напр., *на+ пол* открываются две возможности, ср. *он упал на+ пол* и *он упал на по+л*. Если речь идёт об автоматических процедурах, моделирующих соответствующие процессы аппаратно-программными следствиями, в указанного типа случаях выбор принадлежит оператору. Таким же образом сочетание *на+ де+нь* трансформируется в *на+день* (наречие, возможно, также прилагательное) или в *на де+нь* – сочетание предлога с существительным.

9. При моделировании восприятия речи словосочетание типа *на+ пол*, естественно, трактуется как (возможное) слово *на+пол*, реально отсутствующее в словаре. (Здесь возникает проблема, заключающаяся в том, что программа не должна давать «полный отказ», когда она встречает в тексте слово, отсутствующее в словаре. Но эту проблему всё равно надо решать.) Вместе с тем программа проверяет, существует ли в словаре предлог *на+*. Получив утвердительный ответ, программа ищет в словаре **ударное** слово *по+л*. Разумеется, здесь возможны ошибочные интерпретации, когда, например, слово *на+лом* (ср. *чёрным налом*) будет интерпретировано как словосочетание *на лом*. Но это лишь один из неизбежных случаев вероятностных решений.

<…>

11. На сегодняшний день, по-видимому, ни один из существующих словарей не включает всю совокупность идиоматических и функционально близких им сочетаний какого бы то ни было языка – тем более нет достаточ-

но разработанных процедур обработки этих сочетаний в речевой деятельности. Однако идиомы (в широком понимании термина) достаточно богато представлены в любом языке, и их изучение вполне могло бы стать особым «подразделом» лингвистики и психолингвистики».

(*Венцов А.В., Касевич В.Б., Ягунова Е.В. Об идиомах в Национальном корпусе русского языка // Научные чтения-2003 (Санкт-Петербург, 15 – 17 декабря 2003 г.): Материалы конференции. Приложение к журналу «Язык и речевая деятельность». Т. 5. СПб., 2004. С. 8 – 11*).

О.Н. Ляшевская, В.А. Плунгян, Д.В. Сичинава

О морфологическом стандарте Национального корпуса русского языка

«<…>

2. Трактовка аналитических форм

В Корпусе в настоящее время используется в основном пословный принцип морфологической разметки; кроме того, в процессе разработки находится «второй слой» разметки на уровне неоднословных устойчивых оборотов (*в течение, во что бы то ни стало* и т.п.). Предусмотрен поиск лексических единиц как в составе оборотов, так и вне их. Например, пользователь, ищущий сочетания предлога *в* с существительным в винительном падеже, выбрав опцию «искать вне оборота», будет избавлен от многочисленных примеров употребления этого предлога в составе сложных предлогов (типа *в течение*) и других оборотов. Как особый вид оборотов в будущем предполагается также разбирать аналитические грамматические формы: будущее время несовершенного вида (*будет оценивать*), условное наклонение (*оценили бы*), прошедшее время совершенного вида пассивного залога (*был оценен*), аналитические формы сравнительной степени прилагательных и наречий (*более экзотически*) и др.

На уровне пословной разметки аналитические формы получают «морфологическую» трактовку. Формы сложного будущего времени кодируются как

быть: буд. время + <глагол>: инфинитив, несов. вид (*буду петь*),

формы условного наклонения – как

<глагол>: прош. время/инфинитив + *бы/б/чтобы*,

аналитические формы сравнительной и превосходной степени прилагательных и наречий – с помощью формул

более/менее + <прил.>: полож. форма / <наречие>

или

самый/наиболее/наименее + <прил.>: положит. форма / <наречие>.

«Морфологический» принцип хорош своей относительной простотой и последовательностью: его легко провести программными средствами (для идентификации грамматической формы не требуется обращаться к её контексту), а предложения, содержащие аналитические формы, вообще говоря, можно найти с помощью стандартных поисковых запросов. Кроме того, это решение уравнивает конструкции типа *будет плакать* с другой близкой инфинитивной конструкцией со значением будущего времени: *станет плакать*, а признанные аналитические формы суперлатива – с похожими, но менее стандартными конструкциями типа *в наибольшей степени заинтересованный* или *менее всех заметный*.

Как слабую сторону данного решения мы можем отметить наличие «шума» при поиске и расхождение с традицией грамматического описания русского языка. Неудобство при поиске возникает, во-первых, если пользователь, например, ищет формы инфинитива (или прошедшего времени глагола), но не имеет возможности автоматически отсеять аналитические формы. Во-вторых, при поиске самих аналитических форм пользователь должен задавать произвольное расстояние между составляющими из-за свободного порядка элементов конструкции, и отсюда велика вероятность получить в выдаче примеры, где искомые формы встречаются случайным образом (ср. *Самым ценным качеством* ***будет*** *именно умение* ***предвидеть****…*).

Безусловно, больше всего мы отходим от грамматической традиции в случае форм будущего времени и условного наклонения. Как уже было замечено, выход мы видим в том, чтобы разбирать аналитические грамматические формы как особый вид оборотов. От стандартных оборотов они будут отличаться большей свободой лексического наполнения и нежёстким порядком входящих в них элементов.

Техническую сложность, кроме того, представляет разметка употреблений сложного будущего времени с однородными формами типа *буду читать, писать*, так называемые сериальные глагольные конструкции типа ***буду сидеть смотреть****, как ты занимаешься*, а также аннотации оборотов типа *должен буду думать*, допускающих две интерпретации:

должен + *думать*: буд. время

и

должен: буд. время + *думать*

На двух уровнях, пословном и на уровне оборотов, предполагается разбирать также разрывные формы отрицательных и неопределённых местоимений типа *ни у кого, кое с кем*, взаимные местоимения типа *друг с другом*, составные числительные типа *триста двадцать пять* и аналитические формы императива типа *давайте споём*».

(*Ляшевская О.Н., Плунгян В.А., Сичинава Д.В. О морфологическом стандарте Национального корпуса русского языка // Национальный корпус русского языка: 2003 – 2005. Результаты и перспективы. М., 2005. С. 120 – 122*).

А.В. Венцов, Е.В. Грудева

Аналитические формы в Национальном корпусе русского литературного языка

«Как известно, цели создания большого (национального) аннотированного корпуса текстов предполагают не только разработку надёжного лингвистического инструментария[6], но и создание на основе построенного корпуса новых грамматики и словаря (словарей) данного языка.

<…>

Необходимость аннотировать большие массивы текстов поставила перед лингвистами много вопросов как теоретического, так и практического характера. К последней группе вопросов относится, в частности, следующий: как оптимально соотносить такие показатели, как скорость разметки и её качество?

Опыт работы над созданием собственного корпуса русского языка, а также опыт обращения к результатам работы и технологиям, используемым в этой области другими коллективами, показывает, что теоретически более быстрый и в силу этого экономически более выгодный путь использования алгоритмических процедур лингвистического аннотирования не приводит к нужным результатам: доля ошибок в классификации языковых явлений оказывается недопустимо высокой и для достижения нужного результата приходится обращаться к ручной доразметке текстов. Как представляется, к продукции такого рода, как национальный корпус языка, должны применяться такие же требования, как к словарям, энциклопедиям, учебникам и пр., т.е. наличие фактических ошибок здесь недопустимо в принципе. Более трудоёмким, но и более эффективным с точки зрения требуемого результата является технология полуавтоматической разметки текстов, которая предполагает наличие оператора, разрешающего вопросы, связанные с омонимией в самом широком смысле слова.

---

[6] Ср.: «Корпусную лингвистику можно считать усовершенствованной методикой сбора и обработки материала – традиционного «расписывания» текстов с последующим использованием как-то организованной картотеки для извлечения из «примеров» грамматической, лексикографической и иной информации, для проверки выдвинутых лингвистических гипотез и т.п.» [Венцов, Грудева, Касевич, Ягунова 2005: 35].

Национальный корпус русского литературного языка (далее – НКРЛЯ) создаётся в Лаборатории моделирования речевой деятельности Санкт-Петербургского государственного университета (научный руководитель лаборатории – В.Б. Касевич).

К числу важнейших особенностей НКРЛЯ относятся обязательная акцентуированность всех словоформ в текстах (включая случаи так называемого вторичного ударения типа *лесо^пито+мник*[7], *двадцатичетырё^хэта+жный*), систематическое восстановление в правах буквы «ё» и последовательное выделение так называемых составных слов. Под последними понимаются единицы, которые иногда в литературе называют «сочетаниями, эквивалентными слову» (типа *в_обни+мку, в_голова+х, а_то+* и пр.). Следует заметить, что составной характер таких сочетаний, как *в_обни+мку*, носит орфографический и этимологический характер, с грамматической же точки зрения это слова-наречия. В пределах категории «составные слова» выделяются разрывные и неразрывные (составные) слова (например, *дру⁺г__о_-_дру⁺ге* – с одной стороны, и *в_обни+мку, на_дыбы+, изо_дня+_в_де+нь* – с другой) <…>.

Последовательная реализация указанных принципов позволяет снимать омонимию на разных языковых уровнях, что в конечном счете даёт возможность получить более адекватную картину, связанную, с одной стороны, с частотностью единиц, с другой – с конкретными морфологическими характеристиками единиц... Ср., например:

(1) *заступи+тесь*{заступи+тьcя=VV0,prfc,intr=,0,impr,0,pl,2p,0} (форма императива) и

засту+питесь{заступи+тьcя=VV0,prfc,intr=,0,indc,futr,pl,2p,0} (форма индикатива, будущего времени) или

(2) *на_попа+*{на_попа+=CW1=AV0} («составное слово», неразрывное, наречие) и

на{на=PRP} *попа+*{по+п=NN0,m,anim=,sg,ac} (сочетание предлога *на* и существительного *поп* в аккузативе).

При выборе технологии морфологической разметки текстов мы исходили из того, что данный корпус, подобно словарям или энциклопедиям, не должен иметь ошибок. Поэтому нами принята система разметки с использованием постоянно пополняемого словаря аннотированных словоформ. В этом случае самый первый текст полностью размечается вручную и по нему создается базовый словарь. Вслед за этим полученный словарь дополняется все-

[7] Здесь и далее символ «+» – знак основного ударения, символ ^ – знак вторичного (нефонологического) ударения.

ми возможными омонимами и используется при разметке последующих текстов с пополнением после каждого следующего текста. При наличии словаря процесс разметки происходит полуавтоматически с помощью специальной программы. Если конкретная словоформа текста представлена в словаре единственным вариантом, ее морфологическое описание переносится в размеченный текст без ведома оператора. При наличии в словаре нескольких омонимов все они предлагаются оператору для выбора. Наконец, отсутствующую в словаре словоформу оператор описывает вручную. Подобный процесс повторяется итеративно для каждого следующего текста, и по мере увеличения объема размеченного корпуса доля чисто ручной разметки постепенно сокращается.

В отличие от существующей практики (ср., например, корпус ХАНКО) включать в состав так называемых многокомпонентных единиц, кроме «сочетаний, эквивалентных слову», составные числительные и аналитические формы, составители НКРЛЯ ограничиваются «составными словами», что позволяет последовательно иметь дело с такой лингвистической единицей, как (лексико-грамматическое) слово.

Что же касается аналитических (морфологических) форм в НКРЛЯ, то традиционная аналитическая форма признаётся состоящей из *двух слов*… Поскольку морфологическому описанию в корпусе подлежит каждое лексико-грамматическое слово, то в составе аналитической формы маркируются оба её компонента. Например, в составе аналитической формы *буду читать* «буду» описывается как вспомогательный глагол с соответствующими значениями лица, числа и пр., а «читать» – как инфинитив. То же с аналитическими формами компаратива (*более сильный*), суперлатива (*самый большой*), сослагательного наклонения (*взял бы*), пассива (*был сделан*): словам *более*, *самый* приписываются дескрипторы служебного слова, слово *бы* по традиции относится к разряду частиц, слово *был* описывается как вспомогательный глагол, а слова *сильный*, *большой*, *взял*, *сделан* описываются как обычные прилагательные, глагол в сослагательном наклонении и краткое страдательное причастие соответственно. Ср.:

(3) *бу+ду чита+ть*
бу+ду{бы+ть=VAX,impf,intr=,0,indc,futr,sg,1p,0}
чита+ть{чита+ть=VV0,impf,tran=VVI,0}

(4) *бо+лее си+льный*
бо+лее{бо+лее=AUX=,0,0,0}

си+льный{си+льный=AJ0=,pln,sg,m,nm}

(5) *са+мый большо+й*
са+мый{са+мый=AUX=,sg,m,nm}
большо+й{большо+й=AJ0=,pln,sg,m,nm}

(6) *взя+л бы*
взя+л{взя+ть=VV0,prfc,tran=,act,sbjn,0,sg,0,m}
бы{бы=PRT}

(7) *бы+л сде+лан*
бы+л{бы+ть=VAX,impf,intr=,0,indc,past,sg,0,m}
сде+лан{сде+лать=VV0,prfc,tran=VVP,psv,sht,0,m,sg,0}.

В результате получается, например, что все глаголы сослагательного наклонения признаются омонимами по отношению к глаголам прошедшего времени. В действительности, конечно, показатель сослагательности – это **одновременно** частица *бы* и форма глагола, **совпадающая** с формой прошедшего времени (т.е. омонимичная ей). Но служебное слово *бы*, как известно, может присоединяться почти к любой словоформе в составе высказывания (составляя с ней единое фонетическое слово). Даже преодолев трудности его автоматического обнаружения, мы должны будем искать в тексте форму на *-л(а/о/и)*, т.е. всё равно эта форма, совпадающая с формой прош. времени, будет «интересовать» нас как форма сослагательного наклонения.

Таким образом, введя в класс значений соответствующего морфологического дескриптора, содержащего указание на часть речи, такие категории, как служебное слово и вспомогательный глагол, мы получаем возможность извлекать по этим описателям, кроме всего прочего, информацию об аналитических формах.

Немаловажным представляется и тот факт, что при таком подходе к маркированию аналитических (морфологических) форм наблюдается соответствие между теоретическим построением и технологическим решением».

(*Венцов А.В., Грудева Е.В. Аналитические формы в Национальном корпусе русского литературного языка // Труды Международной конференции «Корпусная лингвистика – 2006» (10 – 14 октября 2006 г., Санкт-Петербург). СПб., 2006. С. 75 – 80*).

Тема 11

МОРФОЛОГИЧЕСКОЕ АННОТИРОВАНИЕ: ПРОБЛЕМЫ И РЕШЕНИЯ

О.Н. Ляшевская, В.А. Плунгян, Д.В. Сичинава

О морфологическом стандарте Национального корпуса русского языка

«<…>

1. Морфологическая разметка в Корпусе современного русского языка

Морфологическая разметка текста состоит в выделении словоформ и в приписывании каждой словоформе информации о лексемной принадлежности (исходной форме слова) и о совокупности её грамматических признаков.

<…>

Морфологическая разметка содержит информацию о словоизменительных, но не о словообразовательных признаках лексемы. Деривационные признаки включены в состав семантической разметки, представляющей собой расширение морфологической аннотации. Совокупность морфологических признаков, приписываемых словоформе в некотором значении, называется её морфологическим разбором. Если какая-либо словоформа отождествляется с несколькими грамматическими значениями (наборами грамматических признаков), то ей изначально приписываются все возможные разборы.

Используемые в морфологической разметке словоизменительные признаки мы будем называть также грамматическими признаками, а морфологические разборы – грамматическими разборами.

Морфологическая информация, приписываемая произвольному слову в тексте, состоит из четырех «полей», или групп помет:

1. Лексема, которой принадлежит словоформа (указывается «словарная запись» данной лексемы);

2. Множество грамматических признаков данной лексемы, или словоклассифицирующие характеристики (указывается принадлежность лексемы к той или иной части речи, а также, например, род для существительного, переходность для глагола и т.п.) <…>;

3. Множество грамматических признаков данной словоформы, или словоизменительные характеристики (например, падеж для существительного, число для глагола);

4. Информация о нестандартности грамматической формы, орфографических искажениях, сокращенном написании типа *млн*, *г-н* и т.п.

Морфологическую разметку дополняет так называемая акцентуационная разметка, в которой представлена информация о некоторых особенностях плана выражения словоформы, таких, как место ударения и произношение *е* как «ё»[8].

В основу метаязыка грамматических помет, ввиду предполагаемой широкой международной аудитории пользователей Корпуса, положена система сокращенных помет («тегов») на основе латинского алфавита. В то же время предусмотрена возможность использования при поиске традиционных названий категорий на русском языке (в форме «грамматические признаки»). Полный список граммем и их сокращённую латинскую нотацию см. в разделе «Морфология» на сайте ruscorpora.ru.

<…>

Разработчики стандарта морфологической разметки исходили из ряда принципов (выделение моё. – *Е.Г.*). Во-первых… грамматические признаки, приписываемые словоформе, должны быть понятны как можно большему широкому кругу пользователей и согласовываться с традицией описаний грамматики русского языка. В тех случаях, когда языковое явление допускает несколько трактовок в русле русской грамматической традиции (так называемые «спорные вопросы» русистики: сколько родительных падежей в русском языке, один или два; входит ли форма превосходной степени в парадигму прилагательного; является ли предикатив особой частью речи и т.д.), морфологический стандарт обеспечивает единообразное решение этой проблемы во всём Корпусе, причём по возможности такое, которые было бы приемлемо с точки зрения сторонников любой из существующих трактовок.

Во-вторых, всем словоформам Корпуса, признанным формами русского языка (а не включёнными в русский текст словоформами иностранных языков), должна быть обязательно приписана некоторая грамматическая характеристика. С этим связана большая исследовательская работа разработчиков Корпуса по выявлению словоформ, не описываемых нормами русской грамматики, и определению их места в составе или вне состава парадигмы слова.

В-третьих, Корпус стремится максимально облегчить для пользователя задачи поиска морфологической и лексической информации. Именно этим подходом продиктовано решение, согласно которому вид и залог глагола считаются двойственными категориями: словоклассифицирующими и слово-

---

[8] Акцентуационная разметка не применяется в корпусе с неснятой омонимией, т.к. у омонимичных словоформ может быть несколько вариантов представления, ср. *большáя* и *бóльшая*, *лет* и *лёт*.

изменительными. Так, например, словоформа *открылся* входит, с одной стороны, в парадигму лексемы *открыться*, а с другой – в расширенные парадигмы глаголов *открыть* – как форма среднего (медиального) залога и *открывать(ся)* – как форма совершенного вида. Лингвист, изучающий семантику глагола, получит при поиске по заглавному слову *открыться* также и формы от *открыть* и *открывать(ся)*; исследователь же глагольного вида или залога, выбрав соответствующий параметр, может ограничить свой поиск нужным элементом видовой или залоговой пары.

Четвёртый принцип звучит следующим образом: «не важно, как названо некоторое грамматическое явление, важно, чтобы оно могло быть сформулировано в виде запроса к Корпусу». Так, иногда в грамматической традиции существует несколько обозначений для одного и того же грамматического признака, например, будущее время (совершенного вида) = непрошедшее время (совершенного вида). В Корпусе в данном случае ярлыком грамматического признака было выбрано «будущее время», как более традиционное. В то же время разработчики понимали, что исследователь русского языка, использующий термин «непрошедшее время», сможет найти все интересующие его употребления, задав запрос:

наст. время, несов. вид + буд. время, сов. вид.

С этих же позиций при выработке решений, касающихся других спорных вопросов грамматики, выбор делался в пользу более дробного представления грамматической категории. Например, в состав парадигмы существительного был включён второй родительный падеж (ср. *спору нет*), с учётом того, что исследователь, считающий это употребление формой дательного падежа, сможет задать запрос:

дат. падеж + второй род. падеж.

<…>

Пятый принцип можно было бы назвать «не решай за исследователя». Если контекст не позволяет во фразе *Я буду звать тебя Квазимодо* однозначно определить падеж существительного (именительный vs. творительный), то в Корпусе сохраняются два альтернативных разбора – в противном случае разметчик корпуса выступил бы в роли, которую надлежало взять на себя лингвисту-исследователю.

<…>»

(*Ляшевская О.Н., Плунгян В.А., Сичинава Д.В. О морфологическом стандарте Национального корпуса русского языка // Национальный корпус русского языка: 2003 – 2005. Результаты и перспективы. М., 2005. С. 114 – 120*).

Тема 12

СЕМАНТИЧЕСКАЯ РАЗМЕТКА

Г.И. Кустова, О.Н. Ляшевская, Е.В. Падучева, Е.В. Рахилина

Семантическая разметка лексики в Национальном корпусе русского языка: принципы, проблемы, перспективы

«1. Введение

Естественным расширением и продолжением разметки Корпуса по морфологическим признакам является таксономическая классификация словника Корпуса (семантическая разметка). В принципе, даже наличие одной только морфологической разметки значительно расширяет возможности лингвистов при использовании Корпуса, поскольку позволяет искать примеры употреблений не вообще слов, а слов в определённых формах (например, глаголов в императиве, существительных в том или другом падеже и т.д.). Уже морфологическая разметка содержит какую-то, пусть и довольно скудную, семантическую информацию (например, признак «одушевлённость» у существительных). Внедрение же семантической разметки открывает целый спектр новых возможностей.

Семантическая разметка создаётся в Отделе лингвистических исследований ВИНИТИ и предназначена для того, чтобы усилить возможности поиска по лингвистическим параметрам – в частности, в тех случаях, когда поиск в текстах ведётся не по изолированным словам, а по их сочетаниям, т.е. по конструкциям. В принципе, предполагается, что весь Корпус современного русского языка (т.е. запланированные 100 млн словоупотреблений) будет размечен таким образом, однако в настоящее время семантическая разметка применена только к той части корпуса, где снята морфологическая омонимия.

<…>

4. Семантическая разметка: признаки и классы

Как уже было сказано, семантическая разметка является естественным расширением и продолжением уже прочно интегрированной в Корпус морфологической разметки. Она включает 3 группы признаков:

(а) признаки, выражаемые словообразовательными показателями: словообразовательные корреляты соответствующих исходных слов получают пометы «диминутив», «аугментатив», «аттенуатив», «nomen agentis», «nomen femininum», «отыменное прилагательное», «отглагольное прилагательное»,

«отглагольное существительное», «семельфактив», «префиксальный глагол» и т.п.;

(б) признаки, соответствующие так называемым лексико-грамматическим разрядам: качественные, относительные и притяжательные прилагательные, предметные и непредметные существительные, имена собственные и т.п.;

(в) собственно семантические признаки: тематический (таксономический) класс; «оценка»; «каузативность» (у глаголов и отглагольных имен) и др.[9]

…в Корпусе выделяется своя система признаков для каждой части речи: свой набор имеют глаголы, прилагательные, числительные, наречия, местоимения, и отдельно предметные и непредметные имена.

В качестве примеров выделяемых семантических классов можно привести следующие:

– для глаголов: движение, физическое воздействие, создание, уничтожение, обладание, эмоция, речь, поведение человека;

– для прилагательных: размер, форма, цвет, вкус, запах, температура, место, время, свойство человека;

– у непредметных существительных, поскольку значительная часть их образована от глаголов и прилагательных, классы пересекаются с глагольными и адъективными, ср.: движение, физическое воздействие, создание, уничтожение, обладание, эмоция, речь и т.п. (для отглагольных) и цвет, вкус, температура, место, время, свойство человека (для отадъективных); кроме того, у них есть и «собственные» классы, такие как мероприятие, болезнь, спорт, игра, единица измерения;

– для предметных имен: лица, животные, растения, вещества и материалы, здания и сооружения, инструменты, транспортные средства и т.п.

…разработчики старались соблюдать принцип традиционности, т.е. избегать явных расхождений с традиционно принятой грамматической и таксономической номенклатурой. С другой стороны, были добавлены и некоторые из тех классификационных рубрик, разработанных в рамках системы «Лексикограф», которые отсутствуют в других классификациях. Например, для предметных имён это информация о мереологии (включающая прежде всего указания на отношения «часть – целое» и «элемент – множество», в которых участвует данный объект) и о топологии объекта (включающая такие классы, как «вместилища», «поверхности» и т.п.). Мереология и топология – это независимые параметры классификации, существующие параллельно таксономии, поэтому одно и то же существительное может характеризоваться по всем трём параметрам. Например, *ковш* (*экскаватора*) будет относиться к

[9] Каждому значению слова соответствует свой набор признаков; кроме того, в семантическую разметку входит информация о статусе значения (первое/непервое значение).

приспособлениям по таксономической классификации, к вместилищам по топологической характеристике и будет частью с точки зрения мереологии.

Заметим, однако, что и внутри таксономической классификации для Корпуса наиболее удобным был признан не древесный, а фасетный принцип классификации – и, следовательно, одно и то же слово может попадать сразу в несколько классов, если это необходимо. Действительно, в языке, как известно, есть множество случаев, когда одна лексема совмещает свойства нескольких классов. В такой ситуации разработчик, по нашему мнению, должен не навязывать своё однозначное решение (как того требовала бы древесная классификация), а ориентироваться на весь спектр классификационных возможностей. Скажем, глагол *убедить* относится и к глаголам речи, и к глаголам воздействия на ментальное состояние; *вытребовать* – к глаголам речи и к поссесивным глаголам; *наполнить* – к глаголам помещения и изменения признака; *забить* <гвоздь> – к глаголам помещения и воздействия и т.д.

Представляется, что фасетная классификация отражает интересы пользователя наиболее полно: именно поэтому фасетная система принята в такой области, как библиотечное дело… ведь подобно Корпусу, библиотечный поиск ориентирован на самый широкий круг людей».

(*Кустова Г.И., Ляшевская О.Н., Падучева Е.В., Рахилина Е.В. Семантическая разметка лексики в Национальном корпусе русского языка: принципы, проблемы, перспективы // Национальный корпус русского языка: 2003 – 2005. Результаты и перспективы. М., 2005. С. 155, 158 – 160*).

Приложение 10

Тема 13

СИНТАКСИЧЕСКАЯ РАЗМЕТКА

М.В. Копотев, Г.Б. Гурин

Принципы синтаксической разметки Хельсинкского аннотированного корпуса русских текстов ХАНКО

«I. Введение

Проект по созданию Хельсинкского аннотированного корпуса русских текстов ХАНКО рассчитан на несколько лет и в своем законченном виде предоставит пользователю информацию о трех языковых уровнях: морфологическом, синтаксическом и функциональном. <…> В настоящем докладе выносятся на обсуждение принципы синтаксической разметки ХАНКО.

II. Типы синтаксического аннотирования в корпусе

Соблюдение принципов аннотирования, сформулированных в [Leech 1993], максимально расширяет круг потенциальных пользователей корпуса и существенно облегчает взаимодействие с информационным ресурсом, хотя может вызвать упреки в «ненаучности». Однако, как кажется, подход к созданию корпуса, не принуждающий авторов нести всю ответственность за логичность и последовательность разметки, а опирающийся на существующие классификации, позволяет выявлять лакуны в описаниях языка, обнаруживать дефекты и противоречия в разных подходах к языку. Последний постулат Дж. Лича предупреждает критику как раз с этой стороны.

There can be no claim that the annotation scheme represents ‘God’s truth’. Rather, the annotated corpus is made available to a research community on a caveat emptor principle. It is offered as a matter of convenience only, on the assumption that many users will find it useful to use a corpus with annotations already built in, rather than to devise and apply their own annotation schemes from scratch (a task which could take them years to accomplish) [Leech 1993: 275].

Таким образом, корпус − это несовершенный, но часто удобный инструмент исследования, пригодный для использования в самых разных областях лингвистики, доступный любому знакомому с базовой лингвистической терминологией пользователю: студенту, учителю, преподавателю, исследователю – и сам по себе не содержащий ответы на вопросы, но позволяющий их получать.

Говоря о синтаксической разметке, авторы полагают, что на сегодняшний день существует три теории, в рамках которых можно осуществить достаточно полное описание русского материала:

– грамматика зависимостей (И.А. Мельчук, И.М. Богуславский, Л.Л. Иомдин и др.);

– грамматика структурных схем (Н.Ю. Шведова, В.А. Белошапкова и др.);

– традиционные синтаксические учения (А.А. Шахматов, В.В. Виноградов, Н.С. Валгина и др.).

При частных совпадениях в описании все три теории претендуют на полное и независимое от других подходов описание языкового материала[10]. При

[10] Тремя вышеперечисленными подходами список синтаксических теорий, конечно, не ограничивается. Укажем еще описания русского языка с точки зрения функциональной грамматики (А.В. Бондарко, М.В. Всеволодова, А. Мустайоки и др.), семантического синтаксиса (Н.Д. Арутюнова, Е.В. Падучева, И.Б. Шатуновский и др.), «когнитивного» синтаксиса (Г.А. Волохина, З.Д. Попова) и др. Будучи в отдельных частях глубокими и точными, они, однако, в настоящее время не могут служить основой для полного описания языкового материала.

этом степень подробности описания в рамках разных теорий различна. Так, грамматика зависимостей уделяет большее внимание типам синтаксических отношений (напр., в системе ЭТАП-3 и созданном на его основе корпусе количество поименованных отношений (ветвей) доходит до 80), с другой стороны, традиционное учение о членах предложения предлагает исследователю подробную классификацию синтаксических «узлов» (типы сказуемых, разряды обстоятельств и др.). В этом смысле синтаксис Русской грамматики 1980 года выглядит, как кажется, самым неинформативным.

Наконец, следует отметить, что не все подходы одинаково приняты русистами. Самым «теоретически нейтральным», очевидно, следует признать традиционный синтаксис, опирающийся на классификацию членов предложения: именно на его основе сформулированы пунктуационные правила русского языка, этой терминологической системой владеет и школьный учитель, и профессиональный лингвист. С другой стороны, распространение учебника под редакцией В.А. Белошапковой, долгое время считавшегося базовым во многих вузах России, привело к тому, что многие преподаватели опираются в основном на синтаксис структурных схем. В то же время грамматика зависимостей известна лингвистам сравнительно меньше и наиболее активно используется для решения прикладных задач. Таким образом, оказывается, что выбор синтаксической теории, которая бы и удовлетворяла «постулату теоретической нейтральности», и обладала бы достаточной полнотой, представляется нелегкой задачей.

После обсуждения всех возможных подходов создатели ХАНКО приняли решение использовать для синтаксической разметки две альтернативные синтаксические схемы разметки: грамматику зависимостей и традиционный синтаксис членов предложения. При очевидной эклектичности такого подхода, совмещение двух схем позволит решить следующие задачи:

– подробно описать и узлы, и связи синтаксических структур;

– удовлетворить нужды и преподавателей русского языка, и профессиональных лингвистов;

– в зависимости от желания пользователя представлять результаты альтернативных разметок как независимо, так и совместно.

Работа над созданием такого типа аннотирования логично разбивается на две части. В настоящее время идет работа по аннотированию в терминах членов предложения, именно эта схема обсуждается в докладе[11].

---

[11] Полный список параметров доступен по адресу www.helsinki.fi/hum/slav/hanco/syntax.rtf. Автоматический поверхностно-синтаксический анализ в терминах деревьев зависимости давно применяется для аннотирования русского материала, гораздо проще автоматизируется и достаточно подробно описан…

III. Традиционный синтаксис в ХАНКО

Как известно, основы традиционного подхода в общем и целом сложились в работах русских лингвистов еще в XIX веке. По-видимому, наиболее полным описанием русского синтаксиса с этой точки зрения можно считать Академическую грамматику 1960 года. Современная общеизвестная классификация отражена с небольшими вариациями в вузовских учебниках по современному русскому языку (см., напр., Валгина 2000; Кустова et al. 2005].

Плюсы этого подхода в следующем:

– общеизвестность и простота;

– возможность косвенным образом искать материал для исследований, даже опирающихся на другие синтаксические подходы (прежде всего, структурные схемы).

К минусам традиционного похода можно отнести следующее:

– очевидное несоответствие современным представлениям о природе синтаксических структур;

– описание синтаксических узлов и игнорирование синтаксических связей;

– непоследовательность в описании и неустранимые противоречия (отсутствие предложных групп, невозможность четко разграничить разные типы второстепенных членов и т.д.);

– сложность автоматической обработки.

Однако указанные достоинства и недостатки принятого подхода в целом не служат оправданием результатов работы; они, скорее, корректируют ожидания потенциального пользователя.

Создатели ХАНКО сознательно шли на серьезные компромиссы, отказываясь от тех вариантов разбора, которые им представлялись корректными, ради сохранения понятного простому пользователю уровня метаязыка. Ниже приводятся аргументы в пользу ряда частных и не связанных друг с другом решений, принятых в ХАНКО.

1. При решении тех или иных конкретных задач создатели ХАНКО всегда задавались вопросом, насколько ценной является та или иная синтаксическая информация и насколько трудно автоматизировать обработку данных. Прогнозируемый объем ручной работы и ценность результатов часто оказывались в противоречии: например, выделение в качестве единицы детерминанта привело бы к существенному увеличению ручной работы (автоматизировать поиск детерминантов невозможно), однако сколько-нибудь последовательно выполнить эту работу было бы трудно, так как объем понятия «детерминант» по-разному определяется в разных лингвистических работах, а многие синтаксисты обходятся вообще без этого понятия.

2. Необходимо было учитывать и удобство интерфейса. Синтаксическая информация приписывалась разным единицам, в том числе и текстоформам, которые уже содержат морфологическую информацию, в случае двойной разметки представленную в виде знака «+» в действующем корпусе. Естественно, синтаксическая разметка также нередко оказывается двойной (например, текстоформа одновременно может быть и дополнением, и обстоятельством, входить в состав обособленного оборота, выступать в роли союзного слова). Такая же проблема множественности описаний возникает при анализе клауз. На экране компьютера эта множественность будет представлена в виде серии специальных значков: однако чем их больше, тем труднее пользователю найти нужный. Поэтому в разметку не включаются те синтаксические единицы, поиск которых может быть легко осуществлен с помощью косвенных признаков: например, в корпусе не размечаются восклицательные и невосклицательные предложения, найти которые в корпусе можно по пунктуационному знаку.

3. Принципиальным решением разработчиков является выделение внутри осложняющих оборотов обычных второстепенных членов, то есть распространенное обособленное обстоятельство будет описано как целый комплекс под этой рубрикой, но его составные элементы как нормальные второстепенные члены. Это находящееся в противоречии с традиционной грамматикой решение необходимо для получения точной информации, например, на запрос «все прямые дополнения». Было бы странно, если бы система выдавала дополнения в «*Иван читает* ***книгу***», но игнорировала бы субстантивы в винительном падеже в «*Прочитав* ***книгу*** *до половины, Иван принялся за журнал*».

4. Было принято решение отказаться от внутренней дифференциации типов сложноподчиненных, сложносочиненных и бессоюзных предложений. Причин несколько:

– отсутствие четких границ между типами бессоюзных предложений, традиционные классификации которых строятся на типологии сложносочиненных и сложноподчиненных предложений; конкретные решения при массовой обработке материала были бы открыты для семантической критики [Тестелец 2001: 264]. В то же время выделение непересекающихся типов союзных предложений часто просто невозможно;

– традиционная классификация союзных сложных предложений в значительной степени соотносится с классификацией союзов (союзных слов – относительных местоимений). Таким образом, поиск, скажем, определительных связей может опираться на леммы «КОТОРЫЙ», «ЧТО» и др. Определенный процент «шума» при этом неизбежен, но такой поиск окажется достаточно эффективным;

– типы нерасчлененных сложноподчиненных предложений с коррелятивно-союзной и коррелятивно-местоименной структурой можно будет осуществлять с помощью разных типов скреп.

5. Конструкции с прямой речью особо не выделяются, поскольку она считается явлением текстового уровня: в частности, прямая речь может включать несколько пунктуационно оформленных автономных предложений.

6. Наконец, не используется классификация клауз по цели высказывания (повествовательные, вопросительные, побудительные). Автоматизировать разметку этих типов предложений трудно: формы выражения побуждения многообразны и несводимы к использованию морфологического императива, косвенные вопросы нельзя обнаружить при поиске по вопросительному знаку. К тому же, предлагаемая классификация позволяет обнаруживать некоторые типы, например, побудительных предложений (запрос «самостоятельная инфинитивная клауза + бы» будет выдавать побудительные предложения типа «*Почему бы тебе не помолчать?*»).

<…>

V. Выводы

Опыт последовательного применения разметки по членам предложения показывает, что эта теория имеет существенные недостатки, главными из которых можно назвать вложенность однопорядковых компонентов (напр., определение в обстоятельстве) и пересекаемость классификационных признаков (количество случаев теоретической неоднозначности доходит до 30 %). Возможным решением этих проблем могла бы стать частичная разметка корпуса, то есть выделение только хорошо определяемых, «чистых» случаев, однако это привело бы к отсутствию разметки для значительной части синтаксических единиц. С другой стороны, часть описанных проблем неотъемлема от диффузной природы языка и будет, следовательно, возникать и при применении альтернативных синтаксических теорий.

Кардинальным (и неосуществимым) решением было бы устранение этой устаревшей теории из практики преподавания (что, по-видимому, означает и перевод пунктуационных правил на другие теоретические основания). Однако в обозримом будущем общеизвестность схемы заставляет использовать ее при разметке корпуса, рассчитанного на самую широкую аудиторию».

(*Копотев М.В., Гурин Г.Б. Принципы синтаксической разметки Хельсинкского аннотированного корпуса русских текстов ХАНКО // Компьютерная лингвистика и интеллектуальные технологии. Труды Международной конференции «Диалог-2006»*. М.: РГГУ, 2006. С. 280 – 282, 284).

Тема 14

СЛОВАРИ, СОЗДАННЫЕ НА БАЗЕ КОРПУСА

А.В. Венцов, Е.В. Грудева

Акцентно размеченный Корпус русского литературного языка как источник новых словарей («Словарь омографов русского языка» и «Частотный словарь словоформ русского языка»)

«<…>

Как отмечают создатели русскоязычных корпусов, организация Национального корпуса русского языка – абсолютно необходимая предпосылка для создания новой академической грамматики и академического словаря русского языка, которые послужили бы базой для разработки семейства грамматик и словарей разной ориентации, в том числе школьных, а также самых разных пособий и справочников <…>.

Мы остановимся на некоторых особенностях Корпуса русского литературного языка (www.narusco.ru), создаваемого в лаборатории моделирования речевой деятельности Санкт-Петербургского государственного университета (научный руководитель лаборатории – доктор филологических наук, профессор В.Б. Касевич), и в связи с этим на двух словарях, которые изданы благодаря имеющемуся в нашем распоряжении корпусу.

Корпус русского литературного языка (далее – КРЛЯ) объемом 1 млн словоупотреблений создан силами сотрудников лаборатории в период с 2002-го по 2007 год. КРЛЯ представляет собой совокупность четырёх относительно самостоятельных подкорпусов: художественной литературы (30 % от общего объёма корпуса), публицистики (30 %), научно-популярной литературы (20 %), а также драмы как некоторого приближения к зафиксированной на письме разговорной речи (20 %). Все тексты относятся к периоду с 50-х гг. XX в. до нашего времени.

Особенностью корпуса является то, что все тексты в нём акцентуированы (каждой словоформе приписан символ ударения), последовательно восстановлена буква «ё», а также специальной разметке подверглись так называемые «составные слова» (единицы типа *в обнимку*, *в головах*, которые по всем лексико-грамматическим признакам являются словами, но пишутся – в силу традиции – раздельно).

Поскольку в типологическом отношении русский язык относится не

только к языкам с развитой морфологией (флективным), но ещё и к акцентным языкам, причём, как известно, ударение в русском языке разноместно и подвижно, то тем самым каждая единица текста (словоформа) должна быть акцентно охарактеризована. Долгое время исследователи русского языка недооценивали роль омографии в русских текстах, в учебных пособиях обычно приводится 2 – 3 примера (типа *крУжки – кружкИ, зАмок – замОк, мУка – мукА*), и в результате складывалось впечатление, что явление омографии в русском языке носит периферийный характер.

В ходе акцентной разметки всех текстов, вошедших в корпус, обнаружилось, что омографы в современном русском языке исчисляются *тысячами*. При этом «сравнительно мало лексем, которые различаются только ударением в своих словарных формах – именно это и объясняет тот факт, что данное явление до сих пор мало привлекало внимание исследователей. Ударение, как своего рода подсобное средство, «работает» в основном «внутри» парадигмы, а также в сфере различения форм, принадлежащих разным парадигмам» [Венцов, Касевич, Сведенцова 2004: 187]. Речь в данном случае идет о том, что в классификации полученных омографических пар (и реже троек) наиболее наполненными оказались два класса: первый связан с различением за счет ударения двух форм одного и того же глагола – 2-е л. мн. ч. наст. или буд. времени в противоположность 2-му л. мн. ч. императива (типа *лЮбите – любИте, ввАлитесь – ввалИтесь*), а второй представляет собой различение за счет ударения двух словоформ разных слов (типа *бЕлкам – белкАм*), тогда как класс омографов, различающихся ударением в своих словарных формах, по наполняемости занимает одно из последних мест в классификации.

На основании полученного материала и был составлен «Словарь омографов русского языка» [Венцов, Грудева, Касевич, Корешкова и др. 2004]. Словарь содержит более четырех тысяч омографических пар, т.е. слов и форм, которые пишутся одинаково, но читаются (произносятся) по-разному. Материал в словаре упорядочен двояко: в первой части все омографические пары представлены в алфавитном порядке, во второй части те же омографы разбиты по грамматическим классам. В обзорной статье, помещенной в словарь, дается анализ связи между типом омографии и семантикой омографов.

Другой словарь, который также явился результатом работы с акцентуированным корпусом, – «Частотный словарь словоформ русского языка» [Венцов, Грудева 2008]. С одной стороны, выборка текстов в 1 млн словоупотреблений в настоящее время считается слишком маленькой для создания частотного словаря. Считается также, что гораздо интереснее и ценнее получить частотный словарь на материале, скажем, 100-миллионного корпуса. С другой стороны, оказывается, что создать 100-миллионный корпус лингвистически аннотированных текстов вручную – трудновыполнимая задача. При соз-

дании же большого корпуса *автоматически* аннотированных текстов появляется, с нашей точки зрения, недопустимое число ошибок, искажающих представления о языке. Разбор ошибок при составлении частотных словарей на многомиллионных автоматически размеченных корпусах русского языка представлен в следующей публикации [Венцов, Грудева 2007].

В то же время для решения целого ряда задач вполне достаточным оказывается корпус и меньшего объема. Ср. замечание редактора упсальского частотного словаря Л. Лённгрена: «<…> В наш корпус входит 1 миллион словоупотреблений. На вопрос, достаточно ли этого, однозначного ответа нет: всё зависит от того, для каких исследований будет употребляться материал корпуса. Например, для изучения относительно высокочастотных явлений в языке достаточно и меньшего объёма выборки. С другой стороны, даже корпус, во много раз превышающий 1 миллион словоупотреблений, не может гарантировать „правильное“ ранжирование низкочастотных лексем, составляющих бóльшую часть словарной сокровищницы» [Лённгрен 1993: 13 – 14].

Как известно, частотный словарь языка с развитой морфологией может создаваться как минимум двумя путями, в зависимости от выбора основной единицы словаря: либо как словарь словоформ, либо как словарь лексем. Практически все известные частотные словари русского языка – это словари лексем, а не словоформ. Для решения многих задач (например, для отбора лексического минимума при обучении иностранному языку), действительно, гораздо важнее иметь представление о частотных рангах именно лексем. Однако для решения многих других проблем, напр., для моделирования процессов восприятия речи, крайне необходим частотный словарь именно словоформ.

Как известно, в русском языке словоформа не всегда равна графическому слову (ср. уже упоминавшуюся выше проблему «составных слов»). Наконец, хорошо известно, что реальной частотностью в языке (особенно в таком морфологически богатом языке, как русский) обладают словоформы, а не лексемы. Это было хорошо показано уже в одном из первых частотных словарей русского языка – словаре Э.А. Штейнфельдт [Штейнфельдт 1963].

Интересно также отметить, что составители частотных словарей отмечают *привычность* основной словарной единицы – лексемы, а также тот факт, что при сведéнии словоформ в лексемы лингвисты могут использовать разные принципы, что приводит к более высокой доле субъективности в количественных показателях по лексемам по сравнению с количественными данными по словоформам. Ср. замечание Л. Лённгрена: «<…> Лемма (исходная форма) для каждой словоформы должна указываться вручную. Это означает, что, прежде чем приступить к лемматизации, нужно установить принципы, по которым она будет проводиться. Эти последние могут отличаться от при-

менявшихся в других работах принципов и дать результаты, которые невозможно будет полностью сравнить с уже существующими. С этой точки зрения *количественные языковые факты, опирающиеся только на уровень словоформ, являются более объективными и надёжными*» [Лённгрен 1993: 28 – 29; курсив наш. – *А.В., Е.Г.*].

Таким образом, в качестве единицы описания словаря выступает акцентно размеченная словоформа (всего в словарь вошло 133 267 словоформ, включая имена собственные и «составные слова»). Следует отметить, что по многим показателям данный словарь создан впервые, поскольку аналогов акцентно размеченного КРЛЯ, в котором последовательно восстановлена буква Ё и маркированы «составные слова», в настоящее время, насколько нам известно, не существует.

<…>

Как видим, корпус даже небольшого объема, но содержащий важную для русского языка информацию об ударении, может послужить источником создания новых словарей русского языка. <…>»

(*Венцов А.В., Грудева Е.В. Акцентно размеченный Корпус русского литературного языка как источник новых словарей («Словарь омографов русского языка» и «Частотный словарь словоформ русского языка») // Проблемы истории, филологии, культуры. 2009. Т. 24. № 2. С. 631 – 635*).

А.В. Венцов, Е.В. Грудева

Частотный словарь словоформ русского языка

«Введение

<…>

Существующие печатные частотные словари русского языка представляют собой, как правило, словари лексем (подробный обзор частотных словарей русского языка см., например, в книге: (Козырев, Черняк 2004: 264 – 271)). Среди частотных словарей русского языка представлены словари разного типа: общеязыковые словари, словари языка писателей, словари публицистики и пр. Из общеязыковых частотных словарей наиболее известны три: «Частотный словарь современного русского литературного языка» Э.А. Штейнфельдт, составленный на основе выборки текстов объемом 400 тысяч словоупотреблений, в результате чего были получены данные о частоте встречаемости 2500 лексем (Штейнфельдт 1963); «Частотный словарь рус-

ского языка» Л.Н. Засориной, составленный на основе текстовой выборки объемом 1 млн словоупотреблений, что дало около 40 тысяч лексем (Засорина 1977), и «Частотный словарь современного русского языка» Л. Лённгрена, составленный также на выборке текстов объемом 1 млн словоупотреблений, но отличающийся от предыдущих словарей более современным языковым материалом (Лённгрен 1993).

Качество составления частотных словарей и их объём в немалой степени зависят от технических возможностей. Так, частотный словарь Штейнфельдт был составлен вручную силами большого числа исполнителей; словари Засориной и Лённгрена создавались уже с использованием вычислительной техники. Поскольку современные компьютеры обладают большими возможностями в обработке информации, возникает естественное желание получить частотные словари бóльшего объема. См., например, замечание А.Н. Баранова в учебнике по прикладной лингвистике (во фрагменте, посвящённом частотным словарям): «<…> Наиболее объёмный (около 40 тыс. слов) словарь Засориной составлен на основе обработки примерно одного миллиона словоупотреблений, что *сейчас уже трудно считать представительной выборкой для такого языка, как русский*» (Баранов 1993: 67; курсив наш. – *А.В., Е.Г.*).

В настоящее время предпринята попытка создать частотный словарь русского языка на основе Национального корпуса русского языка (www.ruscorpora.ru) объемом 100 млн словоупотреблений. Тексты, положенные в основу этого словаря, написаны в период с 1950-го по 2005 г. Автором проекта и основным исполнителем является С.А. Шаров (http://dict.ruslang.ru/freq.php). По понятным причинам словарь такого объема проще хранить в электронном виде, нежели в печатном. Любопытно, что составители самого большого на сегодняшний день частотного словаря русского языка отмечают: «При интерпретации списков частотного словаря надо помнить, что любой корпус, каким бы большим он ни был, является конечным подмножеством потенциально бесконечного множества текстов на данном языке. Любая другая выборка этого подмножества породит несколько другой список, который будет отличаться в своих менее частотных элементах» (Ляшевская, Шаров 2008: 346). Иными словами, сколь бы велика ни была выборка текстов, все равно могут найтись тексты, в которых встретятся слова, не вошедшие в словарь, составленный на основе этой выборки.

Таким образом, по объёму выборки представляемый нами частотный словарь словоформ сопоставим со словарём Л.Н. Засориной и со словарём Л. Лённгрена.

<…>

…в качестве единицы описания данного словаря выступает акцентно

размеченная словоформа. Следует отметить, что по многим показателям данный словарь создан впервые, поскольку аналогов акцентно размеченного Корпуса русского литературного языка, в котором последовательно восстановлена буква Ё и маркированы «составные слова», в настоящее время, насколько нам известно, не существует.

Структура словаря

В данной версии словаря представлены следующие разделы:

1. *Алфавитно-частотный список словоформ.*
2. *Частотный список словоформ.*
3. *Алфавитно-частотный список «составных слов».*
4. *Частотный список «составных слов».*
5. *Алфавитно-частотный словарь омонимов (имя собственное - имя нарицательное).*
6. *Алфавитно-частотный словарь омографов.*
7. *Некоторые статистические сведения.*

Алфавитно-частотный список словоформ

Алфавитно-частотный список словоформ включает словоформы первых 473 рангов, что составило всего 2654 единицы. Структура словарной статьи выглядит следующим образом:

Словоформа	Частота по жанрам					Количество текстов по жанрам				
	1	2	3	4	Общая	I	II	III	IV	Общее
А										
Алекса+ндр	6	103	54	7	170	3	6	21	2	32
Алекса+ндра	17	8	30	6	61	2	5	16	2	25
Алекса+ндрович	21	14	8	0	43	2	4	7	0	13
Алексе+й	2	87	6	6	101	1	7	5	3	16
Андре+й	35	14	11	5	65	6	5	9	3	23
Аро+н	0	52	0	0	52	0	1	0	0	1
а	3160	3561	1976	1098	9795	47	69	212	84	412
а_то^	102	88	23	22	235	31	31	17	19	98
а+	200	43	166	114	523	38	22	55	35	150
а+вгуста	2	7	35	9	53	1	5	17	7	30

Словоформы расположены в алфавитном порядке, причём сначала в алфавитном порядке идут словоформы имён собственных, а затем уже все остальные. Знак «+» означает основное ударение, знак «^» – вторичное ударение.

Информация о частоте встречаемости словоформы в корпусе представлена следующим образом: сначала идёт информация о частоте в каждом подкорпусе (графа 1 – драма, 2 – беллетристика, 3 – публицистика, 4 – наука), а затем информация об общей частоте по всему корпусу.

Информация о числе текстов, в которых встретилась та или иная словоформа, организована по такому же принципу: сначала указывается число текстов в пределах каждого подкорпуса (I – драма, II – беллетристика, III – публицистика, IV – наука), а затем общее число текстов.

Следует иметь в виду, что подкорпус «драма» представлен только теми словоформами, которые входят в реплики персонажей; словоформы, входящие в авторские ремарки, пополнили подкорпус «беллетристика».

Частотный список словоформ

Частотный список словоформ организован по принципу убывания общей частоты встречаемости тех же 2654 словоформ, что вошли в состав алфавитно-частотного списка. Дополнительной графой в этом разделе является графа «частотный ранг». Структура словарной статьи выглядит следующим образом:

	Словоформа	Частота по жанрам					Количество текстов по жанрам				
Ранг		1	2	3	4	Общая	I	II	III	IV	Общее
1	и	4556	13795	10703	6868	35922	47	69	225	85	426
2	в	3332	9102	9679	6319	28432	47	69	226	85	427
3	не	6076	7100	4854	2077	20107	47	69	224	85	425
4	на	2188	6450	4462	2967	16067	47	69	224	85	425
5	с	1590	4214	2910	2067	10781	47	69	226	85	427
6	я+	5845	2410	1398	238	9891	47	59	125	30	261
7	а	3160	3561	1976	1098	9795	47	69	212	84	412
8	что^	1231	2143	2199	1182	6755	47	68	214	84	413
9	о+н	1305	3666	1128	465	6564	47	69	162	72	350

Как видим, верхушку частотного свода занимают, как обычно, разного рода служебные слова (предлоги *и*, *в*, *на*, *с*, союзы *а*, *что^*, частица *не*, местоимения *я+*, *о+н*). Первое существительное (*вре+мя* с частотой 1390) получает в словаре 56-й ранг; следующее существительное (*челове+к* с частотой 936) имеет 97-й ранг.

Алфавитно-частотный список «составных слов»

Алфавитно-частотный список «составных слов» организован по такому же принципу, что и алфавитно-частотный список словоформ. В число «составных слов» попали не только единицы, представляющие собой целостные лексико-грамматические образования, которые в силу традиции пишутся раздельно (типа *а_и+менно, а_ля+, а_не_то^, а_ну+, бе+з_вести, бе+з_толку, без_запи+нки*), но и заимствованные обороты и названия, а также некоторые иностранные имена собственные (типа *а^й_эм_со+ри, астрофи+тум_асте+риас, ал_Манби+джа*).

Частотный список «составных слов»

В частотном списке «составных слов» сохраняется та же информация (общая частота встречаемости в Корпусе и частота по каждому подкорпусу; число текстов, в которых встречается данное «составное слово»), только словоформы организованы по частоте.

Алфавитно-частотный словарь омонимов (имя собственное – имя нарицательное)

Алфавитно-частотный словарь омонимов включает 273 пары словоформ, различающихся по принципу «имя собственное – имя нарицательное», что отражается на письме прописной/строчной буквой (типа *а+да – А+да, була+т – Була+т*). Каждая словоформа снабжена информацией о частоте встречаемости как в каждом подкорпусе, так и в Корпусе в целом.

Алфавитно-частотный словарь омографов

Алфавитно-частотный словарь омографов включает более 700 пар словоформ, различающихся либо местом ударения (тип *А+дам – Ада+м, ба+зу – базу+*), либо его качеством (типа *а_то^ - а_то+, что^ - что+*), либо меной букв Е-Ё (типа *бельё+ – белье+*), либо различными комбинациями этих признаков (типа *брё+вна – бревна+*). Каждая словоформа в пределах пары снабжена информацией о частоте встречаемости как в каждом подкорпусе, так и в Корпусе в целом.

<…>»

(*Венцов А.В., Грудева Е.В. Частотный словарь словоформ русского языка (проект). Череповец: Изд-во ЧГУ, 2008*).

Г.И. Кустова

Словарь русской идиоматики: сочетания слов со значением высокой степени (http://dict.ruslang.ru/magn.php)

«Электронный ресурс «Словарь русской идиоматики» представляет собой электронный банк данных и содержит сведения о словах со значением высокой степени и их сочетаемости.

Идиоматикой в широком смысле называют такие сочетания и языковые выражения, которые носитель языка не конструирует по правилам семантической и грамматической сочетаемости, а запоминает и использует в готовом виде. В этом смысле к идиоматике относятся пословицы и поговорки, крылатые выражения, речевые штампы официального языка и языка СМИ (*выразить озабоченность*, *достигнута договорённость*), общераспространённые цитаты из фильмов, литературных произведений, анекдотов, песен и т.д. («*За державу обидно*», «*Все украдено до нас*»). В более узком смысле к идиоматике относят сочетания, в которых переосмысляется один или более элементов (*тёртый калач* – о человеке).

Типичным примером идиоматической сочетаемости является выражение значения высокой степени при разных словах. Наряду с обычными показателями высокой степени – *большой* для существительных (*большая радость*) и *очень* для глаголов, прилагательных и наречий (*очень огорчился*, *очень горячий*, *очень далеко*) – существует множество более «специализированных» показателей высокой степени (*жгучий*, *горячий*, *грубый*, *острый*, *исключительно*, *серьёзно*), которые имеют более узкую и избирательную сочетаемость с другими словами. Идиоматичным сочетаниям свойственна неполная семантическая мотивированность. Идиоматическую сочетаемость нельзя предсказать (т.к. она не выводится целиком из семантики соединяемых слов); её нужно постепенно запоминать и осваивать. Поэтому она составляет трудность не только для иностранцев, но и для носителей языка.

Например, носители языка (а также изучающие язык) должны запоминать, что *нарушение* может быть *грубым* и *злостным*, но не ?*жестоким*, а *ошибка* – *грубой* и *жестокой*, но не ?*злостной*. Нужно запомнить, что по-русски можно сказать *смертельно надоел*, но не говорят ?*смертельно нарушил*; что *боль*, *жалость*, *интерес* могут быть и *жгучими*, и *острыми*, однако *брюнет* бывает только *жгучим*, но не *острым*, а *нехватка* – *острой*, но не *жгучей*. При этом определённая семантическая мотивированность в идиоматических сочетаниях есть, т.е. вполне объяснимо, что для выражения значения высокой степени используются прилагательные *острый*, *резкий*, *жгучий*, *горячий*, *страшный*, *ужасный*, *невыносимый* и под.

Носители языка, не обладающие развитыми навыками и достаточной культурой речи (например, школьники), часто не знают, «как правильно сказать», и допускают многочисленные «идиоматические ошибки» в устной речи и письменных текстах, например: ?*безоговорочное решение* (ср. правильное: *безоговорочное согласие, бесповоротное решение*); ?*оголтелая ложь* (ср.: *беспардонная ложь, оголтелая травля*), ?*беспардонное пьянство* (ср. *беспробудное пьянство, беспардонная ложь*). Идиоматичные сочетания представляют для школьников особые трудности ещё и потому, что многие из них имеют книжный характер (*неоценимый вклад, непререкаемый авторитет, кровная заинтересованность*), а книжная, официальная речь вообще труднее усваивается детьми.

Существует множество градаций между более идиоматичными и более мотивированными сочетаниями.

Вопрос о границах между семантически мотивированной и идиоматической сочетаемостью является в науке о языке дискуссионным, а конкретные случаи идиоматической сочетаемости часто не получают однозначной квалификации, что отражается, в частности, в словарях. Например, во многих фразеологических словарях сочетание *круглый дурак* считается фразеологизмом; в Малом академическом словаре русского языка (МАС) у слова *круглый* выделяется значение «полный, совершенный», которое реализуется в сочетании *круглый дурак*, но при этом выражения *круглый отличник* и *круглый сирота* считаются фразеологизмами, хотя значение слова *круглый* в таких сочетаниях вполне подводимо под формулировку «полный, совершенный».

Другая теоретическая и терминологическая проблема состоит в том, что в отечественной традиции принято различать собственно фразеологизмы (идиомы), в которых исходное значение целиком переосмысляется (*медведь на ухо наступил; ломиться в открытую дверь*), и коллокации, в которых одно слово выступает в своём обычном значении, а второе – во фразеологически связанном (*плакать* ***навзрыд; в стельку*** *пьяный*).

Чтобы не обременять пользователя (особенно не обладающего специальной лингвистической подготовкой) сложной научной проблемой поиска и обоснования границ между свободной и идиоматической сочетаемостью, было принято решение включить в словарь наряду с настоящими идиомами (фразеологизмами, ср. *круглый сирота*) и коллокациями (ср. *плакать навзрыд; диаметрально противоположный*) менее идиоматичные (ср. *глубоко огорчён*), а также свободные (семантически мотивированные, ср. *чрезвычайно огорчён*) сочетания со значением высокой степени.

Благодаря этому данный электронный ресурс сможет служить полноценным справочником, содержащим корпус русских слов со значением высокой степени и сведения об их сочетаемости. Для тех пользователей, которых ин-

тересует, «как говорят» и «как не говорят», словарь будет служить просто собранием сочетаний со значением высокой степени, которые встречаются в текстах на русском языке и подтверждены данными Национального корпуса русского языка. Для тех пользователей, которые планируют заниматься научными исследованиями в области мотивированной и идиоматической сочетаемости, словарь предоставит исходный материал для наблюдений, обобщений, формулирования и проверки гипотез и т.д.

ЧТО ВКЛЮЧАЕТ СЛОВАРЬ И КАК ИМ ПОЛЬЗОВАТЬСЯ

Слова со значением высокой степени (*необычайно*, *на редкость*, *неимоверный* и т.п.) будем также называть **степенными словами**, **степенными показателями** или **показателями степени**. Слова, к которым они относятся, будем называть **характеризуемыми словами**, или **контекстами** (*на редкость* ***удачный***; *неимоверная* ***жара***).

Словарь содержит около 750 степенных слов и выражений и более 10 тысяч сочетаний со значением высокой степени.

Исходный список степенных слов формировался на базе Национального корпуса русского языка (в него вошли слова, имеющие в словаре корпуса помету «высокая степень»)…

В словарь включены степенные слова двух видов: наречия и прилагательные. При этом наречные показатели степени могут выступать в виде отдельных слов (весьма, чрезвычайно, крайне) и в виде наречных выражений, которые приравниваются к наречиям (до зарезу, из всех сил).

Контексты степенных слов были получены из текстов Национального корпуса русского языка…

ТИПЫ ЗАПРОСОВ

Пользователь может получить информацию, касающуюся отдельных слов и списков слов.

На сайте имеются:

- Алфавитный список всех сочетаний;
- Алфавитный общий список степенных слов;
- Алфавитный список наречий и наречных выражений со значением высокой степени;
- Алфавитный список прилагательных со значением высокой степени.

Для получения списка нужно активизировать соответствующую строчку.

<…>

Пользователь может получить информацию о сочетаемости отдельных слов, включённых в словарь.

Интерфейс содержит два поисковых окна:

(1) Степенное слово – которое выражает значение высокой степени (степенной показатель).

(2) Характеризуемое слово – при котором выражается значение высокой степени (контекст).

<…>

ПРИМЕРЫ ИЗ КОРПУСА И СТАТИСТИКА

Каждое полученное на запрос сочетание слов имеет значок Национального корпуса русского языка. При активации этого значка выдаются примеры употреблений данного сочетания в корпусе. В получаемом из корпуса файле указана статистика – количество употреблений данного сочетания в корпусе».

Приложение 12

Тема 15

ВОЗМОЖНЫЕ ЗАДАЧИ И СПОСОБЫ ИХ РЕШЕНИЯ ПУТЕМ ОБРАЩЕНИЯ К ИМЕЮЩИМСЯ ЭЛЕКТРОННЫМ ЯЗЫКОВЫМ РЕСУРСАМ (КОРПУСАМ)

М.А. Кронгауз

Методы семантики

«8.1. Источник и оценка языкового материала

Лингвистика вообще и лингвистическая семантика в частности являются эмпирическими науками, основанными на исследовании языкового материала. В ходе семантического исследования языковой материал подвергается различного рода оценкам. Оцениваться может правильность текста, семантическая тождественность двух языковых выражений, наличие тех или иных семантических отношений (например, причинно-следственной связи) и многое другое. Именно поэтому для методов семантики наиболее общими оказываются проблемы источника языкового материала и критериев его оценки.

Основным способом пополнения языкового материала и одновременно его оценки с различных точек зрения является **интроспекция**, т.е. самонаблюдение. Интроспекция означает обращение к собственной языковой интуиции. Исследователь сам порождает языковой материал и сам его оценивает. Метод интроспекции хорош тем, что исследователь, зная выдвинутую им самим гипотезу, может целенаправленно порождать материал, её верифицирующий или же фальсифицирующий. Важно отметить, что при этом с помощью интроспекции можно порождать как правильные, так и неправильные языковые выражения. **Отрицательный языковой материал** (т.е. такой языковой материал, который оценивается как неправильный), как отмечал Л.В. Щерба, также может оказаться очень полезен при проверке лингвистической гипотезы, а его порождение и использование в исследовании является **лингвистическим экспериментом**, т.е. также лингвистическим методом, хотя и более частным. Так, эксперимент, по Щербе, может заключаться в погружении слова в различные контексты, в результате чего получаются правильные и неправильные фразы. Отрицательный языковой материал помогает выделить типы контекстов, которые плохо совместимы с данным словом, и соответственно те компоненты значения слова, которые мешают погружению слова в соответствующий контекст, вступают с ним в противоречие.

<…>

Возвращаясь к интроспекции, можно сказать, что этот метод следует признать кратчайшим путём к проверке той или иной гипотезы. Но у него есть и определённые недостатки. Хотя в принципе нельзя говорить о совершенно объективной оценке языкового материала, интроспективная оценка считается в наибольшей степени субъективной. Исследователь, опирающийся только на собственную языковую интуицию, рискует получить неверные с точки зрения других носителей языка результаты. Это может обусловливаться, по крайней мере, тремя причинами. Во-первых, его идиолект (индивидуальный вариант языка) несколько отличается от других идиолектов именно в интересующем его аспекте. Во-вторых, языковая интуиция вообще плохо работает in vitro, т.е. в искусственно сконструированных условиях вне реального общения. Наконец, в-третьих, интуиция лингвиста могла претерпеть в процессе исследования изменения.

<…>

Наконец, последнее принципиальное и естественное ограничение использования интроспекции связано с отсутствием языковой интуиции или нечёткой языковой интуицией. Это означает, что интроспекцией не может пользоваться лингвист, изучающий семантику неродного языка. Особенно это касается так называемых полевых исследований, когда лингвист изучает язык непосредственно в среде носителей языка…

Вообще же интроспекции как самонаблюдению, обращению к собственной интуиции противопоставлены различные методы обращения к чужой ин-

туиции. Среди них в первую очередь следует выделить **наблюдение**, т.е. исследование письменных и устных текстов в условиях реальной коммуникации, и такие **экспериментальные методы**, как **анкетирование**, **интервьюирование** и пр.

Обращение к существующим, «отмеченным» текстам многие исследователи и лингвистические школы осознают как важнейший метод лингвистики. В качестве примера можно назвать такие разные направления и подходы, как дескриптивизм, исследование разговорной речи (Е.А. Земская в России, К. Бланш-Бенвенист во Франции и другие), японскую школу языкового существования (М. Нисио, Т. Сибата и другие, в центре внимания представителей этого направления находится речевая деятельность, конкретная обстановка, в которой происходит коммуникация, её социальные условия и т.д.), корпусная лингвистика и др. Для подобных «эмпирических» подходов, основанных на наблюдении функционирования языка, характерно стремление к максимально полному сбору речевого, или текстового, материала и использование особых методов сбора и обработки материала. В частности, среди методов обработки материала следует упомянуть **статистические**.

Корпусную лингвистику, достаточно активно развивающееся в последнее время направление, и метод исследования стоит рассмотреть подробнее. На первый взгляд кажется, что интроспекции как самому субъективному методу противопоставлен самый объективный метод – **корпусный анализ**, или, точнее, корпусная лингвистика. Корпусная лингвистика как таковая появилась сравнительно недавно – в конце 70-начале 80-х годов, заведомо после того как началось формирование корпусов текстов на различных языках. Её возникновение и расцвет в конце XX в. обусловлены развитием компьютеров и возможностью полной компьютеризации как самих текстов, так и работы с ними, прежде всего процедуры поиска. Во многом она является продолжением и развитием дескриптивных методов, характерных для американского направления структурной лингвистики. Основной принцип современной корпусной лингвистики существовал задолго до появления компьютерных корпусов и вообще корпусов текстов. Этот принцип заключается в том, что объектом исследования является отмеченный в реальной коммуникации языковой материал – написанные тексты, произнесённые фразы и т.д. Абсолютизация этого принципа означает по сути, что только такой материал и должен служить объектом лингвистического исследования. Однако при небольшом количестве языкового материала он служит скорее иллюстрацией научной гипотезы или аргументов в её поддержку, чем её основой или реальным объектом исследования.

Таким образом, именно сейчас, учитывая объём введённого в компьютер корпуса текстов, можно говорить о семантических исследованиях, основанных на корпусном анализе. Чтобы изучить семантику слова, следует найти все контексты, в которых оно зафиксировано. Так реализовывается идея

Л. Витгенштейна о том, что значение языковой единицы – это её употребление. При достаточно большом корпусе текстов невстречаемость слова в определённом контексте также значима. Она свидетельствует хотя и не об абсолютном запрете, но об определённых ограничениях, по крайней мере статистических. Вообще при корпусном анализе статистические закономерности приобретают особую значимость и могут играть роль своего рода эмпирической реальности, интерпретируемой с семантической точки зрения.

Корпусный анализ кажется максимально объективным – ведь языковой материал отчуждён от исследователя и не зависит от него. При корпусном анализе исходные позиции лингвиста, изучающего семантику родного языка, и лингвиста, изучающего семантику чужого языка, уравниваются. Значение языковой интуиции и связанные с ней искажения сводятся на нет. Кроме того, речь идёт об изучении языка in vivo, а не in vitro, т.е. в условиях реальной коммуникации (хотя большей частью речь идёт о письменных текстах). Интроспективная оценка правильности фактически заменяется фиксацией отмеченности языкового выражения в корпусе текстов. Иначе говоря, если некое явление отмечено, то оно и правильно. Но именно этот тезис и является одновременно и самым сильным, и самым слабым местом в корпусном анализе. Такой подход упрощает обработку языкового материала и вместе с тем огрубляет её.

Совершенно очевидно, что не всё сказанное и не всё написанное является правильным с точки зрения языковой интуиции, или, если выражаться более корректно, не весь отмеченный языковой материал имеет равный вес для построения лингвистической теории. Некоторые фразы, даже будучи приемлемыми, вызывают дополнительный семантический или прагматический эффект, никак не отмеченный в корпусе текстов.

Всё вышесказанное означает, что эффективность корпусной лингвистики безусловно увеличивается в сочетании с другими методами, например экспериментальными, в том числе уже упомянутым конструированием отрицательного материала.

Надо сказать, что объективность семантической оценки может повышаться, если дополнить интроспективную оценку обращением к чужой интуиции. Опрос информантов позволяет учесть различные идиолекты и различные языковые интуиции, а также избежать опасности искажения интуиции под влиянием выдвинутой теории. По этой причине лучшими языковыми информантами являются носители языка, не имеющие лингвистического образования и не строящие собственной теории, а непосредственно отвечающие на вопросы лингвистической анкеты.

Итак, по критерию происхождения лингвистического материала противопоставляются методы **внутренний** (интроспекция) и **внешний** (наблюдение, анкетирование, интервьюирование). Можно также говорить о противопоставлении методов **in vitro** и **in vivo**. Первый – метод эксперимента, когда ис-

следователь, обращаясь к собственной или чужой интуиции, строит или стимулирует носителей языка строить различные языковые фрагменты и подвергает их лабораторной оценке (интроспекция, анкетирование, интервьюирование). Второй – метод наблюдения, когда лингвист наблюдает естественную коммуникацию или её результаты. Следует отметить, что интроспекция, по-видимому, всегда экспериментальна. Едва ли можно объективно наблюдать и анализировать собственную речь. Противопоставление названных методов можно выразить в табл. 2.

Таблица 2

Методы семантики

Источник	Внутренний	Внешний
Эксперимент	Интроспекция	Анкетирование, интервьюирование
Наблюдение		Корпусный анализ, дескриптивные методы и др.

Для семантической оценки языкового материала лингвист также может использовать метод интроспекции, т.е. собственную интуицию (табл. 3). Ей в этом случае противопоставлены метод опроса, опирающийся на чужую или усреднённую интуицию, а также снова метод фиксации речевого факта, используемый, в частности, в корпусном анализе, несколько более грубый, различающий только отмеченное (читай правильное) и неотмеченное (при очень большом корпусе текстов, т.е. корпусе, стремящемся к бесконечности, – с большой вероятностью неправильное).

Таблица 3

Семантическая оценка языкового материала

Оценка	Внутренняя	Внешний
Опрос	Интроспекция: собственная оценка	Анкетирование, интервьюирование: чужая оценка
Наблюдение		Фиксация речевого факта: отмеченность/неотмеченность

(*Кронгауз М.А. Методы семантики // Кронгауз М.А. Семантика. М., 2001. С. 92 – 97*).

М.В. Копотев, А. Мустайоки

Современная корпусная русистика

«<…>

Корпусная лингвистика: сферы применения

Исследования русского языка, основанные на современных корпусных данных, уже имеют определённые традиции. В разных странах мира публикуются материалы, посвящённые как созданию русскоязычных корпусов, так и исследованиям с помощью корпуса (конференции «Корпусная лингвистика» в Санкт-Петербурге, «Мегалинг» на Украине, «Диалог» в Москве, а также сборники (Плунгян 2005; Никипорец-Такигава 2006). Всё это позволяет говорить о становлении нового направления – корпусной русистики. В то же время необходимо сказать, что корпусная лингвистика как дисциплина, имеющая свою методологию и… активно формирующуюся теорию, нередко подменяется простым поиском иллюстративного материала в собрании электронных текстов. Безусловно, это важный и необходимый элемент использования любого корпуса, однако было бы неверным сводить все многообразие корпусных методов к простой задаче быстрого поиска подходящего примера. <…> …ниже ряд конкретных примеров демонстрирует широту сфер применения корпусных подходов в современной лингвистике.

1. Использование корпусов в **грамматических и лексикологических исследованиях** стало уже обычным в современной исследовательской практике. Приведём лишь один показательный пример. В «докорпусных» исследованиях, описывающих конструкции типа *Лодку унесло ветром*, было сделано много ценных и точных наблюдений. Однако исследователи оперировали буквально двумя десятками примеров, не представляющих, как выяснилось, всего спектра употреблений. Использование корпуса (в данном случае Интегрума) позволило расширить список примеров до более чем двух тысяч и точнее описать эту конструкцию…

2. **Частотные списки и списки ключевых слов** активно создавались и использовались задолго до создания современных электронных корпусов. Эти исследования в большинстве случаев представляли частотные характеристики лексем (точнее, лемм). Корпусные методы позволяют сделать такие исследования более аккуратными и тонкими. Так, например, в исследовании (Коваль 2006) анализируются частотные характеристики омонимичных форм исходя из их реального употребления в современном русском языке. По данным исследователя, причастные формы большинства частотных русских глаголов практически не употребляются… и это означает, что омонимия существует лишь потенциально.

<…>

3. **Исследование коллокаций** (то есть сочетаний лексем) является в настоящее время одной из самых популярных тем корпусных исследований. Однако кроме этого решение более сложных задач осуществляется с опорой на исследование *коллигаций* (англ. colligation; сочетание лексем и/или грамматических признаков…). Так, в работе (Guo 2005) исследуется сочетаемость модальных глаголов и среди прочего демонстрируется, что служебная идиома *as well* часто сочетается с формами сослагательного наклонения *might* и условной клаузой, вводимой союзом *if*. Таким образом, можно говорить о лексико-грамматическом комплексе (коллигации) *if… might as well*.

4. **Исследование нормы/узуса**. Хотя исследование нормы обычно не входит в задачу корпусных лингвистов, множество острых, востребованных обществом языковых вопросов может быть решено на основе не субъективных оценок, а с привлечением статистически более представительного материала. Так, например, анализ сочетаний употребления второго родительного падежа типа *много народу* позволил выявить, что указания нормативных грамматик не соответствуют действительному употреблению этих форм…

5. Корпусные методы с самого возникновения активно использовались в **социолингвистических исследованиях**. В качестве иллюстрации современных исследований приведём данные английских исследователей (McEnery & Xiao 2004). По их данным, в Британском национальном корпусе (BNC) употребление английского глагола *fuck* различается по возрастным группам (табл.).

Возраст	<15	16 – 25	26 – 35	36 – 45	46 – 60
fuck	6,07	16,5	8,86	0,7	3,48

6. Ошибочно считать, что корпусная лингвистика работает только с письменными текстами. Отдельной и активно разрабатываемой областью корпусной лингвистики стало **создание и изучение корпусов устной речи**. Так, в крупнейшие национальные корпуса (BNC, НКРЯ и др.) включены транскрипты записей устной речи. Самой значительной коллекцией устных текстов (включая аудио- и видеозаписи) является, безусловно, проект CHILDES, объединяющий около 130 корпусов детской речи для более чем 20 языков, в том числе и для русского. В качестве примера исследований в рамках «детской» корпусной лингвистики укажем на статью (Protassova & Voeikova 2007), в которой с опорой на корпусные данные (частично доступные в CHILDES) демонстрируется употребление русских диминутивов в детской речи.

7. Корпусная лингвистика с самого своего возникновения была тесно связана с **преподаванием языка** в иностранной аудитории. Известно, что 50

самых частотных английских лексем покрывают 60 % английской разговорной речи (Nation 1990). И этот факт, безусловно, должен учитываться в подборе лексики для изучающих язык. Корпусные исследования такого рода давно проводятся и стали основой множества учебных словарей и грамматик (Oxford Learner's English Dictionary, Collins Cobuild Student's Dictionary, Collins Cobuild English Grammar и др.). К сожалению, такого рода пособия по русскому языку ещё не созданы, а существующие работы (напр., Морковкин 2003) опираются на устаревшие частотные словари и не учитывают современные корпусные данные.

8. Относительно новой областью является создание **корпусов ученических текстов**, которые позволяют классифицировать типы ошибок и учитывать их в процессе преподавания. Сведения такого рода учитываются в некоторых из указанных выше англоязычных учебных словарей. <…>

9. Тесно связанной с различными педагогическими задачами, однако имеющей и собственно лингвистическое значение, является **создание многоязычных параллельных корпусов**. Эта область корпусной лингвистики активно развивается, и в настоящее время созданы или создаются русско-английский, -немецкий, -японский, -финский, -словацкий корпуса. <…>

10. Наличие электронных текстов, принадлежащих одному автору, даёт возможность расширить круг задач, традиционно решаемых **стилистикой и авторской стилеметрией**. Так, анализ употребления частотных существительных в текстах Ф.М. Достоевского не позволяет определить специфику авторского употребления (*человек, дело, время* и др.). Однако внимательный анализ коллокаций этих десемантизированных единиц в текстах разных периодов творчества позволяет сделать определённые выводы о развитии взглядов писателя в сторону конкретики частного дела и человеческой индивидуальности.

11. Ещё одна задача, которая успешно решается с помощью корпусных методов, это **установление плагиата и скрытого цитирования**. Надо сказать, что эта задача шире, чем поиск скрытых цитат в студенческих и диссертационных работах. <…> … при всей критике подхода группы Г. Хьетсо по установлению авторства «Тихого Дона» эта работа стала одной из первых попыток решения подобных задач на корпусном материале.

12. Наконец, корпусные методы применяются для решения задач **судебно-лингвистической экспертизы**. Очевидно, самым известным случаем такого рода является дело Дерека Бентли, осужденного в 1953 году за участие в убийстве полицейского и помилованного (посмертно) 45 лет спустя. В ходе повторного судебного разбирательства целый ряд аргументов защиты был связан с интерпретацией языковых фактов. Одним из существенных доказательств невиновности стали данные корпусного исследования, проведённого Р.Ултардом. Исследователю удалось доказать, что продиктованное обви-

няемым признание было существенно переработано человеком, привыкшим писать полицейские протоколы.

В целом, для корпусных методов характерно:

– смещение исследовательской стратегии с изучения нормы («как правильно») на изучение узуса («как говорят/пишут»);

– автоматическое извлечение информации с помощью поисковых запросов, что может приводить к получению объёмного и не всегда релевантного материала;

– распространённость «формально-морфологического» подхода, при котором поиск примеров основывается на морфологической (или просто на буквенной) форме;

– использование квантитативных методов, позволяющих учитывать частотные характеристики исследуемых единиц, и замена интроспективных оценок материала точными количественными данными об употреблении;

– опора на автоматическое аннотирование, не лишённое, с точки зрения традиционной лингвистики, определённых неточностей и упрощений;

– внимание к контексту в широком смысле (исследование коллокаций, ключевых слов, конструкций, что предполагает учёт окружения исследуемой единицы).

Приведённые примеры исследований не преследуют цели очертить круг всех возможных сфер применения корпусных методов. Они лишь показывают широту применения и перспективность корпусной лингвистики – раздела языкознания, сугубо прикладного в момент возникновения, но развившегося в самостоятельную дисциплину, предлагающую в настоящее время как новые теоретические решения, так и конкретные исследовательские и педагогические инструменты для работы с языком».

(Копотев М.В., Мустайоки А. Современная корпусная русистика // Slavica Helsingiensia 34. Инструментарий русистики: корпусные подходы / Под ред. А. Мустайоки, М.В. Копотева, Л.А. Бирюлина, Е.Ю. Протасовой. Хельсинки, 2008. С. 16 – 20).

Д.О. Добровольский, А.А. Кретов, С.А. Шаров

Корпус параллельных текстов: архитектура и возможности использования

«**3**. Создание корпуса параллельных текстов в качестве одного из модулей Национального корпуса русского языка представляется целесообразным как с практической точки зрения, так и с точки зрения развития корпусной лин-

гвистики – одного из наиболее перспективных лингвистических направлений. С помощью параллельных корпусов могут быть также получены интересные результаты в области теоретического языкознания, так как опора на принципиально сопоставимые аутентичные тексты разных языков позволяет выявить часто неожиданные (как квазиуниверсальные, так и специфические) особенности функционирования языковой системы. Корпус параллельных текстов может быть эффективно использован в различных лингвистических исследованиях (в первую очередь, в области контрастивной лексикологии и двуязычной лексикографии), а также в исследованиях по теории перевода, сравнительного литературоведения, культурологии, автоматической обработки текста и др.

Приведём эскизный перечень основных вопросов, при решении которых обращение к корпусам параллельных текстов представляется разумным.

1. Как ведут себя определённые структуры входного языка (L1) и их соответствия выходного языка (L2) в аутентичных контекстах? Насколько системные характеристики этих структур способны предсказать их поведение в реальном дискурсе? Какие типы контекстов оказываются релевантными для выбора адекватного эквивалента в языке L2? Иными словами, если исследование корпусов показывает, что стандартные «словарные» L2-эквиваленты данной L1-структуры оказываются неприемлемыми в контекстах определённых типов, необходимо выявить релевантные свойства этих контекстов и соответствующим образом переформулировать условия эквивалентности.

2. Для произведений, достаточно далеко отстоящих во времени, дополнительно встаёт вопрос о соотношении представленных в корпусе L1-структур (с их L2-переводами) и норм современного узуса. Насколько изменился узус? В чём причины подобных изменений? Существуют ли более или менее регулярные механизмы, управляющие языковыми изменениями? Если да, можно ли на основе этих данных предсказать дальнейшие изменения языковых норм? Являются ли соответствующие тенденции уникальными для каждого языка или в них просматриваются некоторые общие закономерности?

3. В каких случаях переводчики предлагают нестандартные решения? С чем это связано? Мотивированы ли отклонения от оригинала субъективными факторами или объективными межъязыковыми различиями между L1 и L2, накладывающими определённые ограничения на способы перевода исходных структур? Если одному и тому же месту оригинала в разных переводах соответствуют различные эквиваленты, встаёт вопрос о семантических отношениях между этими эквивалентами. Являются ли они в языке L2 квазисинонимами или же речь идёт о различных интерпретациях L1-структуры? Если соответствующие выражения L2 квазисинонимичны, в чём состоят их семантические, прагматические и сочетаемостные различия? Если же речь идёт о

различных интерпретациях, чем мотивированы отклонения от соответствующих структур оригинала? При каких условиях они могут быть признаны допустимыми? Проблемы данного типа решаются особенно эффективно в случае, если параллельный корпус содержит более одного перевода одного и того же оригинального текста…

4. Какие решения переводчики находят для тех L1-структур, которые не вписываются в современные нормы? Какими средствами языка L2 могут быть переданы особенности подобных структур? Естественно, ответы на такие вопросы могут быть получены только при использовании текстов, достаточно далеко отстоящих во времени (ср., например, произведения русской классической литературы XIX века).

Из данного каталога вопросов видно, что использование корпусов параллельных текстов даёт нетривиальные результаты для целого ряда филологических направлений. Среди них сопоставительная лексикология, двуязычная лексикография, лексическая семантика (в том числе её диахронные аспекты), а также теория перевода. Обсуждению чисто лингвистических вопросов посвящён следующий раздел. В заключение этого раздела укажем на те аспекты использования параллельных корпусов, которые относятся скорее к области критики перевода и текстологии.

Корпус параллельных текстов позволяет выявить переводческий брак и редакторский произвол. Во многих переводах имеется неоправданный пропуск значимых с содержательной и эстетической точек зрения фрагментов текста. Это относится и к английскому переводу «Капитанской дочки», и к переводу «Мёртвых душ», в которых опущена «Повесть о капитане Копейкине», и к русскому переводу «Дракулы» или «Хижины дяди Тома». Параллельные тексты заставляют задуматься о границах свободы переводчика в переводе названий произведений. Например, заглавие рассказа А.П. Чехова «На подводе» переведено как «Schoolmistress»; рассказ «Холодная кровь» получил заглавие «The cattle-dealers», а повесть А.С. Пушкина «Капитанская дочка» в одном из английских переводов озаглавлена «Mary».

4. Современное состояние сравнительной лексикологии и практики составления двуязычных словарей характеризуется ориентацией на сопоставление более или менее изолированных языковых структур. Отрицательным последствием подобной ориентации является недостаточный учёт узуса, то есть тех особенностей синтаксического и сочетаемостного поведения единиц языка, которые нельзя объяснить их системными признаками. Так, в принципе известно, что та или иная структура одного языка не может быть во всех контекстах переведена на другой с помощью своего стандартного эквивалента. В определённых контекстах язык L2 традиционно прибегает к другим способам описания соответствующей ситуации. Известно также, что не су-

ществует продуктивных правил, по которым можно было бы вывести подобные отклонения от «стандартной эквивалентности» из неких более общих принципов. Единственный способ описания подобных отклонений – это их тщательная фиксация на аутентичном материале. Только так можно построить исчерпывающие сопоставительные описания и создать словари, удовлетворяющие современным требованиям.

Корпус параллельных текстов представляет собой наиболее адекватный инструмент для выполнения этих задач. Та или иная языковая структура, интересующая исследователя, может быть найдена во всех представленных в корпусе контекстах с их переводами на соответствующий язык. Таким образом, исследователь получает в своё распоряжение набор аутентичных контекстов, представляющих интересующую его структуру в её естественном окружении, а также самые разнообразные эквиваленты этой структуры в языке-цели. Поскольку эти эквиваленты также оказываются встроенными в естественные контексты, на основе полученных с помощью параллельного корпуса материалов могут быть сделаны выводы о зависимости выбора эквивалента от типа контекста. Подобные результаты практически всегда расходятся с теми сведениями, которые мы можем почерпнуть из существующих словарей…

<…>»

(*Добровольский Д.О., Кретов А.А., Шаров С.А. Корпус параллельных текстов: архитектура и возможности использования // Национальный корпус русского языка: 2003 – 2005. М.: Индрик, 2005. С. 271 – 274*).

Учебное издание

Грудева Елена Валерьевна

КОРПУСНАЯ ЛИНГВИСТИКА

Учебное пособие

Подписано в печать 01.10.2012
Электронное издание для распространения через Интернет