Быстрый морфологический алгоритм с угадыванием неизвестного слова на основе словаря для веб-поиска система

Илья Сегалович
Яндекс
iseg@yandex-team.ru

Аннотация

В этой статье описывается {простой, но практичный} алгоритм морфологического анализа и синтеза, который использует ограниченный словарь для получения {довольно точной} морфологии с широким лексическим охватом. Это не подразумевает какой-либо конкретной морфологической модели словаря и реализовано для русского, польского и английского языков. Конструкция алгоритм подходит сдерживает современного веб поисковые системы.

Преамбула: нужна ли веб-поисковой системе морфология?

Некоторые ИК-исследования показали очень небольшое улучшение эффективности поиска при применении морфологического анализа или вообще его отсутствии [harman1991]. Хотя более поздние результаты доказали успех даже в языках, которые обычно имеют мало словоформ, таких как английский [hull1996], все еще остается вопрос, нужен ли веб-поисковой системе вообще морфологический анализ. Google, поисковая система № 1 по рейтингу в мире, утверждает, что она намеренно не использует stemming для предоставления в наиболее точных Результаты Для его Пользователи [google1998]. Такая крайняя позиция была хорошей ревизионистской точкой зрения в конце 90-х, прежде чем анализ ссылок повысил точность веб- поиска. Но действительно ли отзыв не нужен? Вот несколько аргументов "за". Количество страниц, возвращаемых поисковыми системами, распределяется в соответствии с законом Zipf, что означает, что хотя по популярным запросам оно очень велико, количество найденных всего нескольких документов запросов С является значительным. Например, более 30% ответов, полученных по адресу www.yandex.ru on 06.09.2001, содержали менее 100 документы, в то время как только 5-10% запросов содержат орфографические ошибки.

В пользователь поведение, координат рейтинг и морфология

Другое наблюдение в пользу от морфологическая обработка в Интернете - это поведение и ожидания пользователей поиска. У пользователей есть свои собственные ментальные модели того, как должны работать поисковые системы [muramatsu2001], и они обычно предпочитают ранжирование на уровне координат [heimstra2002]. Чтобы соответствовать этой модели (пожалуйста, обратите внимание, что мы не упоминаем точность и повторяемость в качестве основных целей) Поисковые системы в Интернете сначала ищут точное соответствие фразе. Когда это невозможно (более 50% запросов не имеют "совпадения фраз" нигде в Интернете), поисковые системы ранжируют результаты в соответствии с термином близость [muramatsu2001], чтобы ответы были как можно более "похожи" на запросы. Можно заметить, глядя на типичный ответ веб-поисковой системы , что документы примерно перечислены в порядке уменьшения расстояния редактирования ("вероятности") между запросом и *фрагменты* из документов. В то же время 75% веб-поисковых запросов состоят более чем из 1 слова [onestat2003]. Так почему же "сходство" ответов на более длинные запросы позволяет вставлять большие интервалы символов (слов, предложений) между поисковыми терминами, но не допускает "небольших изменений суффиксов терминов", когда термины близки друг к другу?

Введение & текущие тенденции

В самые современные алгоритмы для морфологического анализа основаны на конечных преобразователях состояния различных вкусов

([kimo1983], [kartunen1992], [mohri2000], [daciuk2000]), где фонологические правила описаны вручную и каждому слову из словаря присвоена соответствующая (словоизменительная / деривационная) модель. Эти преобразователи позволяют проводить как анализ, так и синтез словоформ; они очень быстры и надежны. К сожалению, количество неизвестных лексических единиц, извлекаемых из Интернета при каждом обходе, очень велико и может быть оценено по закону Кучи $V_k = Kn^{\beta}$, где V_k является частью словаря, представленного текстом экземпляра размера n. K и β являются свободными параметрами, определенными эмпирически. В Интернете β ближе к 1.0, чем к 0.5 из-за (не) преднамеренных орфографических ошибок, иностранных слов, слов, изобретенных частным образом, таких как взято из *Блоги* и т.д. Это означает, что словарь растет сублинейно с ростом индекса. Один из подходов здесь заключается в том, чтобы просто игнорировать все слова, которых нет в основном словаре [www.aport.ru] надеясь, что охвата будет достаточно.

В последнее время проблема морфологического анализа неизвестных слов привлекает все больше внимания, главным образом из-за успеха в неконтролируемом изучении морфологии из самих корпусов. [Jackuemin1997] проанализировал статистику *слияний k-n* (где k - длина предполагаемого суффикса, обычно 3 буквы, и n - ширина контекстного окна - обычно 2 слова) и получили достойные результаты по сравнению с знаменитыми стеммерами ручной работы Ловинса и Портера ([lovins1968], [porter1980]). [gaussier1999] использовал аналогичный подход (*p-подобие* - количество общих букв между двумя словами) для изучения словообразовательных морфологических семейств и даже словообразовательных деревьев. Более обобщенные подходы корпусного анализа суффиксов представлены в [goldsmith2001] и [snover2002]. Они используют принцип MDL (минимальной длины описания), известный из теории информации, для создания набора основ, сигнатур (парадигм) и аффиксов, которые могут быть закодированы в минимальном количестве битов [goldsmith2001] или которые являются наиболее вероятными (Brent), что в некотором смысле делает морфологическое описание корпуса минимальным. Linguistica [goldsmith2001] также является общедоступным инструментом, который мы будем использовать позже в этой статье.

Многообещающий подход [schone2001] использование контекста слова для обозначения дистилляции гипотетические модели получено От чистый суффиксальный анализ. В нем используется примитив *PPMV - пара потенциальных морфологических вариантов* и меры *семантическое сходство* между ними, что понимается как нормализованная корреляция между их векторами в скрытом семантическом пространстве (которое фактически представляет собой дословную матрицу соседей, факторизованную с помощью LSI).

Все упомянутые выше подходы являются неконтролируемыми в том смысле, что они не используют никаких предварительных знаний о языке и его морфологических моделях. К сожалению, есть по крайней мере, два препятствия, которые не позволяют напрямую использовать в неконтролируемые методы в Интернете Поиск двигатели как есть. Первый - это качество морфологии наиболее употребляемых слов, которая должна быть как можно более точной. Во-вторых, это усложнение обновления индекса: индекс распределен по сотням и тысячам компьютеров, поэтому морфологическая интерпретация новых слов, которые появляются при ежедневных обходах, не должна меняться слишком часто, иначе может потребоваться ежедневное исправление индекса. Стоит отметить, что если у языка есть веб-корпус, достаточно значительный, чтобы представлять общественный интерес, и коммерческая поисковая система, к которой стоит стремиться, обычно у него есть множество словарей, в которых уже накоплены некоторые знания. Например, широко распространенные орфографические инструменты, использующие компактное описание всех возможных словоформ, таких как [ispell] или [aspell], имеют словари для 37 и 26 языков соответственно. Конечно, задача компактного перечисления всех допустимых форм в языке не является в точности задачей описания всех слов и соответствующих им парадигм, тем не менее эти словари успешно используются в веб- поисковых системах ([mnogosearch], [glimpse], [aspseek] и т.д.). Важное замечание о существующих словарях: они всегда (и, надеюсь, правильно) описывают наиболее часто используемые слова языка. Здесь мы предполагаем, что все сложные и нетривиальные [словоизменительные / деривационные] модели всегда принадлежат наиболее используемым словам языка - что фактически является еще одним законом Ципфа - "чем больше

частота слова тем больше, чем в большем количестве морфологически сложных форм оно будет использоваться " [manning1999]).

Идея применения относительно небольшого словаря для угадывания морфологии новых слов не нова. Например, [woods1999] использовал набор агрессивных правил вместе с небольшим словарным запасом для улучшения лексического охвата, [михеев1995] представил метод автоматического получения морфологии неизвестных слов с помощью лексики общего назначения и частот слов,

в Классический Русский морфология алгоритм

[belonogov1985] использовал один и тот же словарь как для известных, так и для неизвестных слов, также все машины FST позволяют писать универсальные правила для слов, которых нет в словаре. В то время как процесс описания морфологии конкретного слова кажется детерминированным, универсальные правила довольно сложно написать и отладить. Пример применения процедуры одноразового обучения вместе с существующим морфологическим словарем к корпусу с целью получения морфологического угадайщика представлен в [kovalenko2002].

Описанный здесь подход основан на [segalovich1998] и использует очень простую идею морфологического сходства. Неизвестное слово морфология берется из всех ближайших слов из словаря, где близость - это количество букв на его конце. От [belonogov1985] подхода он отличается тем, что он не выбирает один вариант, а скорее берет все возможные варианты, которые имеют одинаковую общую длину, и в отличие от [kovalenko2002] он использует для индукции гипотез весь словарь, а не только N нескольких последних букв основ. Для создания такого словаря нам не нужно знать структуру морфемы или какой-либо конкретный формализм какой-либо конкретной морфологии, компилятор принимает входные данные в виде полного списка всех парадигм слов из словаря. Если грамматические теги доступны, они также принимаются . Такой словарь способен не только анализировать известные слова, но и синтезировать все формы, как известные, так и предполагаемые. В алгоритмическом идея этого алгоритма заключается в том, что после того, как мы проанализировали слово, пытаясь найти его точное форма в словаре у нас уже есть достаточно информации (мы уже рассмотрели все ее буквы), чтобы найти наиболее вероятный неточный эквивалент. Подход FST также использует один предварительно скомпилированный автомат с точными и всеобъемлющими правилами но в отличие от [Karttunen1992] нам не требуются универсальные правила, мы скорее считаем их вредными и полностью полагаемся на вероятностный характер анализа неизвестных слов. В этом заключается идея алгоритма - использовать детерминированные знания, когда это возможно (для всех "известных" слов) и вероятностный подход, когда точная интерпретация недоступна.

Интересным применением этого алгоритма является объединенный словарь нескольких языков, который полезен в ситуациях, когда язык неоднозначен, поэтому объединенный словарь выберет наиболее вероятные морфологические интерпретации на основе вероятности для всех слов всех языков. (Такой комбинированный польско-английский словарь используется в нашем экспериментальном проекте по адресу www.yandex.pl как часть интерпретации запроса).

Проблемы с дизайном

Есть есть некоторые вопросы о нас морфологическая модель и алгоритмы, на которые необходимо ответить, прежде чем мы опишем сам алгоритм . Все они проистекают из характера поиска информации или из технических требований поисковых систем. Какой морфологический анализ выполнять: словоизменительный или деривационный? Требуются ли грамматические теги (или POS-теги) в результате анализа? Нужны ли нам основы (roots) или базовая форма (другими словами - нужен ли нам стемминг или лемматизация)? Как обрабатываются неизвестные слова? Должны ли мы использовать контекст слов для облегчения анализа? Зависит ли анализ от корпуса, и если зависит, то в какой степени? Чтобы полностью ответить на все эти вопросы, нам понадобится гораздо более длинная статья, вкратце ответы таковы: флективный, без грамматических тегов, лемматизация, без контекста, встроенного в морфологию. Вот очень короткое рассуждение.

Словоизменительная морфология. Ради точности нам не нужна деривационная морфология, хотя разница часто очень тонкая; рассмотрим, например *вид, род существительных, уменьшительных форм.*

Грамматических тегов нет.. Разные языки имеют разную морфологию с разными грамматическими системами, и поисковая система часто не может различить ни язык запросов (люди никогда не выбирают соответствующие переключатели), ни документ (рассмотрим многоязычный документ, технические документы и т.д.). Таким образом, индексные ключи должны иметь чисто текстовое представление без каких-либо грамматических или языковых тегов.

Леммы не являются основой. Основа - это не только соединение разных частей речи или производных форм (чего мы не хотим), но и создание ложных сочетаний. Таким образом, поисковым системам обычно нужны словарные формы в результате морфологического анализа. Это, в свою очередь, поднимает вопрос об устранении неоднозначности между ними, даже если мы полностью отбросим POS-теги; рассмотрим *stocking -> (запас Или заготовка).*

Контекст анализ. The морфологический сам алгоритм не должен полагаться на контекст слова или на предположение, что все слова будут представлены строго в порядке потока текста . Требования к скорости индексации современных поисковых систем могут этого не допускать (их скорость составляет около 50-100 документов в секунду [najork2001]), морфологический модуль часто вызывается в многопоточной среде один раз для каждой словоформы, встречающейся где-либо в части текстов.

Неоднозначность. Важно отметить , что неоднозначность не будет стоить больше 10-20% от размера индекса. И лингвистическая неоднозначность невозможна в коротких запросах (на самом деле, не-лингвистическая неоднозначность гораздо более успешна при ранжировании по координации).

Алгоритм

Словарь представлен в виде набора *попыток* [cormen1990] перевернутых основ и *дерева* всех возможных суффиксов. Граница между основой и суффиксом берется либо из входного файла, если это необходимо является явно представленным или вычисляется автоматически как длина общей части всех словоформ в парадигме. Вот описание алгоритма.

1. Введите слово с правого конца, используя the *trie* из всех возможных суффиксов. В результате мы все возможные позиции имеют основы/суффикса границы за один проход.

2. Начните с как можно более глубокой границы основы / суффикса и выполните шаги 3-7

3. Используйте две последние буквы возможной основы в качестве индекса для получения подходящей основы *попробуйте.* Если ни у одной основы нет последних двух букв, подобных этой, перейдите к следующей границе основы / суффикса

4. Погрузитесь в соответствующее корневое дерево и попытайтесь найти конечный лист на краю слова, собирая все точки разветвления за один проход

5. *Словарное слово.* Если на краю слова есть конечный лист , сравните соответствующую словоизменительную модель (ее идентификатор хранится в дереве основы в виде специальной буквы после первой буквы основы) со словом-суффиксом. Если оно совпадает, это означает, что мы нашли слово из словаря

6. *Неизвестное слово.* Если на краю слова нет окончания или флективная модель не соответствует суффиксу, то выполните следующие шаги

7. Пройдитесь по всем ранее собранным точкам ветвления базового дерева, начиная с самой глубокой, и найдите все возможные основы, которые могут быть моделями для данного неизвестного слова. Проверьте их словоизменительные модели на соответствие данному суффиксу

Алгоритм поддерживает 2 дополнительных режима: проверять только слова из словаря; находить только одного кандидата (это полезно для однозначного определения).

Ускорить. Мы сокращаем обход как можно раньше, используя показатели "наилучшего кандидата", т.е. Количество общих букв в конце слова между данным словом и моделью-кандидатом. Все точки ветвления в дереве, которые имеют только одну модель перегиба, отмечены ниже, так что это помогает ограничить перемещение.

Изучение. Некоторые эвристические приемы, которые были изучены и теперь встроены в алгоритм: полученная основа должна содержать гласную, основы модели должны иметь продуктивный тег POS (при наличии), должна быть минимальная длина основы, должна быть минимальная общая часть примера и неизвестное слово, парадигма модели должна иметь

минимальная частота (например, встречается как минимум дважды в словаре).

Также весьма полезно [segalovich1998] использовать статистику корпуса для выполнения некоторых базовых исправлений неоднозначности и устранения дополнительных морфологических вариантов: удалите леммы с парадигмами, полностью "вложенными" в парадигмы других лемм (если мы встречались *глумление-> (глумление | глумление), глумления-> (глумление),* но не *глумление* или *потрясенный* мы можем отбросить лемму *шмок*, или как противоположность, если бы мы встретились *шмок, шмок* и *шмокнутый* но не *шмокинги* мы можем отбросить лемму *насмешливо*), предпочесть парадигмы с более частыми леммами, предпочесть парадигмы, которые содержат лемму в корпусе и т.д. Эти и другие эвристические методы могут быть получены с помощью обучения с помощью corpus. В любом случае, в этой статье мы концентрируемся на качестве самой морфологии и не рассматриваем фазу устранения неоднозначности как ее часть.

Эксперимент

Хотя наш словарь реализован для нескольких языков (теоретически для всех, у которых есть словари полной парадигмы, на практике - только для русского, польского и английского), мы решили измерить его качество для русского. Прежде всего, существует очень мало доступных сравнений по русской морфологии, особенно для тех, кто пытается угадать. За последние годы появилось по меньшей мере 3 новых инструмента, которые справляются с русской морфологией. Новая версия Porter stemmer [snowball] использует рукописный свод правил на специальном языке "snowball" и доступна для русского языка. Лингвистика [goldsmith2001] изучает морфологию из корпуса. "Стемка" [kovalenko2002] - это русско-украинский морфологический угадайщик , созданный с помощью полноценного морфологического модуля на основе [Zaliznak1980] и собранной статистики корпуса. Поскольку он производит несколько вариантов основ для каждого слова, мы рассматриваем два крайних варианта, которые он производит: самый глубокий или *агрессивный*, и самый мелкий или *консервативный*. "Mystem" - это алгоритм, представленный здесь (первоначально он был разработан в 1996 году в рамках разработки поисковой системы Яндекса), он использует полный словарь [Zaliznak1980] как машина для угадывания в смысле, описанном выше.

Другой частью эксперимента является корпус с каноническими отображениями между словоформами . Для этого мы взяли недавно появившийся www.ruscorpora.ru [ruscorpora2003] в настоящее время это 1302329 слов морфологически аннотированный корпус русского языка. Подобно CELEX или Brown corpus, он содержит леммы, POS и другие грамматические теги для каждого слова и т.д. В настоящее время он содержит 130823 разных слова {и состоит из двух частей: из которых вторая часть (834255 слов) получена с помощью независимого морфосинтаксического инструмента, в то время как меньшая часть (468074 слова) была предварительно обработана с помощью mystem, поэтому мы не рассматривали ее в следующем исследовании}.

Вопрос о том, как сравнивать качество морфологических процессоров для целей IR, очень расплывчатый . Очевидные показатели это индексы превышения и недопускания (UI и OI), которые должны быть получены в результате такого эксперимента [Paice1996]. Традиционные подходы применяют разную морфологию к одной и той же поисковой системе и пытаются оценить выигрыш или потерю в точности и отзыве. Вряд ли это актуально, в основном из-за бессмысленного значения точности и запоминаемости в Интернете, а также из-за другого способа использования поисковыми системами морфологии. Другой подход заключается в сравнении отображений (PPMVs [Shone2000]) с некоторыми каноническими отображениями, например, закодированными вручную в помеченном корпусе. Этот подход в значительной степени зависит от грамматической модели, выбранной редакторами корпуса - например, от того, что они считают деривацией и что они считают флексией (в русском языке распространенными ошибочными суждениями лингвистов являются причастия против глаголов, различные аспекты, наречие против прилагательного, страдательный залог и т.д.).). Это зависит от того, что они считают. Идеальной мерой было бы семантическое сходство между вариантами PPMV. Семантическое сходство часто рассматривается как контекстуальная взаимозаменяемость [manning1999] и как таковое использовалось в [Shone2000] для дистилляции поддельных PPMV. К сожалению, в языках с богатой флексией сам контекст синтаксически зависит от изучаемой формы, поэтому невозможно использовать контекстные слова как есть

без морфологической обработки. Другая проблема этого подхода заключается в том, что корпус, каким бы большим он ни был, не содержит достаточного количества статистической информации, чтобы представить семантику, масштабируемую для Интернета.

Здесь мы предлагаем следующий подход к измерению семантического сходства между вариантами PPMV. Если две разные формы достаточно близки, они должны быть близки с точки зрения результатов поиска поисковой системы (или даже " Поисковой системы", то есть Google, что является хорошей универсальной мерой еще и потому, что она не использует морфологическую обработку). Современные поисковые системы активно используют статистику слов; обычно они пытаются уловить семантику как можно ближе, используя методы социальных показателей (например, анализ ссылок) и все другие возможные источники информации. Также, кажется, это хорошее подспорье для поисковой системы - обнаружить, что другие формы представленного слова дают удивительно близкие результаты. Давайте посмотрим, например, как это можно применить к английскому языку. Допустим, у нас есть два основных элемента: один сопоставляет *Чулки* Для *запас*, в то время как other сопоставляет его с *stocking* и *запасы* Для *stock*. Итак, мы берем первые N (30) результатов из списка Google и видим, что *запасы* и *stocks* имеют много общих хостов (например, www.nasdaq.com), так же как и у *stocking / чулок* PPMV (например, www.stockingstore.com). У первого PPMV (*чулки / stock*), конечно, нет общих хостов. Итак, давайте назовем семантическим сходством двух разных запросов количество хостов, которые являются общими для первых 30 позиций обоих списков. Но какие запросы мы должны использовать? В идеале нам следовало бы найти самые популярные (скажем, 3) запроса, содержащие определенную словоформу, и сравнить их с такими же запросами с вариантом PPMV. В этом случае мы увидели бы реальную степень сходства , а также более точно уловили бы, что люди подразумевают под той или иной формой слова (ее "значением").. Здесь по соображениям простоты мы сделали только односложные запросы.

Мы применили Для www.ruscorpora.ru корпуса и сравнил полученные PPMV от каждого основного элемента с каноническими PPMV из корпуса. PPMV в нашем понимании - это все пары, которые сопоставляют с одинаковыми всеми доступными основами текстовое представление, лемма или основа. Чтобы сократить выборку, мы оставили только словоформы, которые встречаются в корпусе с частотами от 10 до 100, что близко к наилучшей терминологической специфичности (10-100 ppm). Модуль Total PPMVs PPMVs с помощью частота 10-100.

Каноническая	484462	70028
Стемка	628154	82895
(агрессивная) Стемка	108248	18014
(консервативная)		
Мистема	718216	93863
Снежного кома	519262	72568
Лингвистики	575960	75515

Затем мы удалили все канонические PPMV, то есть те, которые были взяты непосредственно из www.ruscorpora.ru сопоставлений. Таким образом, мы получили отдельный список PPMV как для добавленных PPMV, так и для удаленных PPMV для каждого стеммера. Идея здесь заключается в том, чтобы измерить максимальный эффект, который стемминг оказывает на поисковую систему, как положительный, так и отрицательный. Фактически, мы рассматриваем корпус как источник новых слов и контрольных точек (таких как ежедневный поиск) и используем *семантическое сходство* по всему индексу, чтобы выяснить, насколько плохими были PPMV , добавленные конкретным stemmer, и насколько хороши были те PPVM, которые конкретный stemmer потерял по сравнению с каноническими PPMV. Итак, мы взяли 30 наиболее частых форм и их PPMV из каждого списка добавленных и утраченных PPMV для каждого основного элемента. Частота была взята в соответствии с www.yandex.ru журнал поиска (51387 слов за июль 2002 года, частота которых превышает 100 в месяц).

Модуль	Добавлен PPMV	Хосты	Потерян PPMV	Хосты
стемка консервативна.	136	46	1384	997
стемка агрессивна.	787	210	493	269
снежный ком	643	219	487	308
лингвистическая	953	175	648	585
загадка	778	403	41	7

Примечания по скорости

Все наблюдаемые алгоритмы написаны на C ++ без использования виртуальных функций и шаблонов. Для Pentium IV с частотой 1600 МГц мы измерили скорость на 1 миллионе уникальных словоформ. Результаты представлены в следующей таблице: Алгоритм Тысяч слов в секунду Snowball 180-190 Mystem 60-65 Stemka 380-390

Обсуждение

Мы попытались показать здесь, что использование всего доступного словаря в качестве правила угадывания превосходит как чисто корпусную морфологию, так и рукописный набор правил угадывания . Хотя количество дополнительных PPMV больше, чем в других алгоритмах, они намного более точны и редко приводят к неправильным ассоциациям. Кроме того, количество потерянных ассоциаций минимально. Чисто корпусная индуцированная морфология (Linguistica) показала наихудшие показатели с точки зрения дополнительных PPMV и низкого количества ее семантических ассоциаций. Самый глубокий вариант stemka и snowball показали очень похожие результаты, несмотря на то, что snowball - это набор правил ручной работы, а stemka изучен алгоритм Автор: corpus суффикс-зачистка is .

Список литературы

[1] [aspell], Aspell, ~~http://aspell.sourceforge.net/,~~ http://ftp.gnu.org/gnu/aspell/dict/

[2] [белоногов, 1985]

[3] [bosch1999], Морфологический анализ на основе памяти Анализ, A. v. d. Bosch, W. Дейлманс, ACL'99, 1999

[4] [cormen1990], Введение в алгоритмы, Кормен, ТН, Лейзерсон, CE, Ривест, RL, Лондон: MIT Press, 1990

[5] [daciuk2000], Поэтапное построение Минимальные ациклические конечные автоматы, Дж. Дачюк; Б. В. Уотсон; С. Михов; Р.Э. Компьютерная лингвистика Ватсона, Том 26, Номер 1, март 2000 г. [6] [furnas1988], Поиск информации с использованием модель сингулярной декомпозиции скрытой семантической структуры, Г. В. Фурнас, С. Дирвестер, С. Т. Дюме, Т. К. Ландауэр, Р. А. Харшман, Л. А. Стритер, К. Э. Лохбаум, 11-й ACM SIGIR, 1988, Гренобль, Франция

[7] [gaussier1999], Неконтролируемое изучение словообразовательная морфология из флективных лексиконов, Э. Гауссиер, семинар ACL'99: Неконтролируемое обучение обработке естественного языка , 1999

[8] [goldsmith2001], Неконтролируемое изучение морфология естественного языка, Дж. Голдсмит, сост. Линг. 2001

[9] [Google1998], Справка Google: основы Поиск в Google, Google, http://www.google.com/help/basics.html [10] [губин2002], Разработка морфологического словаря для поисковой системы, М. Губин, Личная страница, декабрь 2002 г.

[11] [harman1991] Насколько эффективен суффикс? Д. Харман, JASIS, том 42, 1991 г.

[12] [heimstra2002], Сглаживание для конкретного термина. для подхода к языковому моделированию для поиска информации: важность термина запроса, Д. Химстра, 25 сентября 2002 г.

[13] [Hull1996], Исходные алгоритмы Случай Исследование для детальной оценки, Д. А. Халл (Исследовательский центр Rank Xerox), JASIS, том 47, 1996 г.

[14] [ispell], Словари Ispell, http://fmg-www.cs.ucla.edu/fmg-members/geoff/ispell-dictionaries.html

[15] [jacquemin1997] Угадывание морфологии из "терминов и корпусов", К. Жакмен, СИГИР'97

[16] [karttunen1992], Двухуровневое правило

Составитель Л. Карттунен и К. Р.
Бисли , Исследовательский центр Xerox в
Пало-Альто, Пало-Альто, 1992 г.

[17] [koskonniemi1983], Двухуровневый

Морфология: общая вычислительная
модель для распознавания и создания
словоформ, К. Коскенниеми,
Публикация № 11, Хельсинкский университет.

[18] [ловинс1968] Разработка базового алгоритма

Алгоритм, Ловинс, Дж.Б.,Механический

Перевод и
компьютерная лингвистика, Том 11

[19] [manning1999] Основы статистики

Обработка естественного
языка, C.D. Мэннинг, X. Шутце, 1999

[20] [manber1989], Массивы суффиксов: новое

метода онлайн-поиска строк, U.

Манбер, Г. Майерс, Материалы Первого
ежегодного ACM-SIAM, май 1989 г.

[21] [михеев1997], Автоматическое введение правил

для угадывания неизвестного слова, А. Михеев
1997 Эдинбургский университет

[22] [mohri2000], Принципы проектирования

Библиотеки взвешенных конечных преобразователей,
М. Мори, Фернандо Перейра, Майкл Райли,
Теоретическая информатика, 2000

[23] [Muramatsu2001], Прозрачные запросы:

исследование ментальных моделей пользователей
поисковых систем, Дж. Мурамацу, Ванда Пратт, 24-е
место
ACM SIGIR, 2001

[24] [najork2001], Высокопроизводительный веб-браузер

Сканирование, М. Найорк, А. Хейдон,
Compaq
Отчет Центра системных исследований, 2001 г.

[25] [onestat2003], Onestat.com Пресс-релиз,

http://www.onestat.com,

http://www.pressi.com/int/release/65369.html

[26] [Paice1996], Метод оценки

исходные алгоритмы, основанные на подсчете ошибок
, C. D. Paice, JASIS, том 47, выпуск
8 , август 1996 г.

[27] [porter1980], алгоритм для суффикса

стриптиз, М. Ф. Портер, Программа, 14:130-
137, июль 1980 г.

[28] [сегалович98], Морфологический анализ русского языка

Анализ и синтез С автоматической
генерацией моделей словоизменения Для
Неизвестные слова, И. Сегалович, М.
Маслов, Диалог'98 (на русском языке)
http://company.yandex.ru/articles/article1.html

[29] [Shone2000], Индукция без знаний

морфологии с использованием скрытого
семантического анализа, П. Шоне, Д. Юрафски,
4-я конференция по вычислительному изучению
естественного языка и 2-й семинар по
изучению языка в логике, Лиссабон, 2000 г.

[30] [snover2002], вероятностная модель для

Изучение конкатенативной морфологии,
М. Г. Сновер, М.
Р. Брент Труды NIPS- 2002

[31] [снежный ком] Снежный ком,

http://snowball.tartarus.org/

[32] [woods1999], Агрессивная морфология для

Надежный лексический охват, W.A. Woods,

Sun Технический отчет

http://research.sun.com/techrep/1999/smli_tr -99-82.pdf

[33] [zaliznak1980]. Грамматический словарь

русский язык. А.А. Зализняк,
Опубликовано 1980 г.

[34] [kovalenko2002]

http://linguist.nm.ru/stemka/stemka.html

[35] [ruscorpora2003] Русский морфологический

Corpus http://corpora.narod.ru/article.html