Язык запросов ГИКРЯ

Татьяна Шаврина

http://int.webcorpora.ru/drake/

В Интернет-корпусе действует свой язык запросов CQL, так что, если вы хотите сделать ваш запрос наиболее подробным и удобным, вы можете как задать в поисковую строку точную форму (регистр учитываться не будет) или же пользоваться предложенным синтаксисом запросов.

Сложный запрос можно составить и не зная языка запросов, через «Конструктор запросов», см.рисунок:

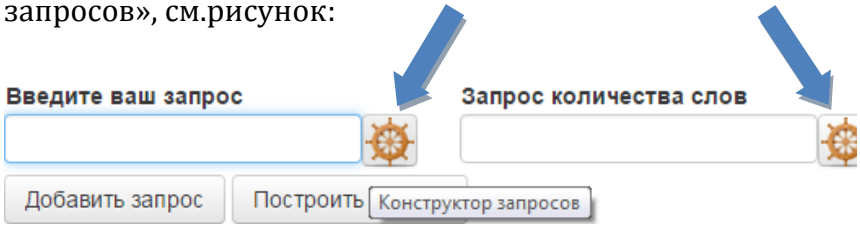

Но если Вы планируете использовать такие возможности, как «отрицание», «регулярные выражения», искать по дефисным написаниям – пожалуйста, ознакомьтесь с данной инструкцией.

Оглавление

Основы языка запросов ГИКРЯ: 2
Основные операторы: 2
Атрибуты: 2
Метаатрибуты: 3
Теперь объединим инструменты: 3
Переменные и дополнительные условия: 4
Отрицание 5
Регулярные выражения: 5
Особенности токенизации: 6
Примеры на все типы запросов: 6
Приложение – кодировка всех частей речи 7

Основы языка запросов ГИКРЯ:

Как устроен такой сложный запрос и что он значит?

[lemma="дать" pos="V"] [pos="N"]

Ответ: корпус, дай мне словосочетания из формы глагола «дать» на первом месте и существительного на втором месте.

Нам потребуются: операторы (выделены черным), атрибуты (красные) и их значения (зеленые).

Основные операторы:

Скобки:
() - обычные логические скобки, полезны для расстановки приоритетов

[] - скобки, в которые записываются атрибуты. Атрибуты записанные в одних скобках будут применены к одной корпусной позиции (о возможных атрибутах см. далее).

Интервал между словами:
[]{x,y}- оператор ставится между условиями к каждому слову. [] означает интервал, в {} записывается численный интервал между словами. Например, [word="Хитрук"][]{1,3}[word="мультфильм"], где количество слов между указанными словоформами – от 1 до 3.

Логическое И:
& или пробел - внутри квадратных скобок (пробел является оператором, потому будьте внимательны и не допускайте лишних пробелов в запросе)
& или пробел - между квадратными скобками - операция следования, т.е. это должны быть две следующих друг за другом корпусные позиции, первая из которых удовлетворяет условиям из первых квадратных скобок, вторая - из вторых.

Логическое ИЛИ:

| - (по умолчания у ИЛИ приоритет ниже чем у И)

Отрицание:
- - (много нюансов употребления, см.далее)

Сопоставление:
= - оператор сравнения либо сопоставления регулярному выражению, используется для задания атрибутов внутри квадратных скобок.

Атрибуты:

Атрибуты можно использовать для задания условий к корпусной позиции

word - задает вид слова. Нужно задавать либо явно, либо частично а-ля в регулярные выражения (допустим оператор . который означает некоторое количество символов). Пример использования: [word="протуберанец"] — точная форма слова

lemma - начальная форма слова. Правила оформления такие же, как и у word (и у

регулярных выражений)
Пример использования: [word="протуберанец"] — выдаст все формы слова
pos - используется для задания дополнительных, грамматических свойств слова (для большей информации смотрите отдельный раздел pos)
Пример использования: [pos="N.m"|pos="N.f"] — выдаст все существительные мужского и женского рода.
признак композита — признак композита позволяет искать составные части сложного слова, разбитого дефисом. При токенизации мы разбиваем слова с изменяемыми частями ("диван-кровать") на три части [word="диван"][word="-"][word="кровать"].
! Мы не разбиваем токены, содержащие "-либо", "-нибудь", "-нить", "кое-", "кой-", "пол-", так как они влияют на разряд местоимений, к которым присоединяются. При этом мы отделяем "-то" и "-де", так как они присоединяются ко всем классам слов.

Признак композита работает так:
[word="то" & composite=true]
Таким синтаксисом можно получить и первый элемент композита, и второй.
Чтобы получить "ему-то" в столбце "результат":
(3 токена, связанные признаком композита)
[word="ему" & composite=true][]{0,1}[word="то" & composite=true]

или просто **[word="ему" & composite=true][word="-"][word="то" & composite=true].**

Метаатрибуты:

1. Год написания текста [year="2012"]
2. Источник текста (сайт) [source="bmr"]
3. Пол автора [gender="F"]
4. Интернет-жанр [genrei="blog"]
5. Год рождения автора [birth="1984"]
6. Город нахождения автора и город рождения автора: [loc="NA"] [city="NA"]
7. Поиск в найденном: [query="имя сохраненного ранее запроса"]

Набор метаатрибутов для разных сегментов различается.

Теперь объединим инструменты:

[word="стекло" pos="V"] – такой запрос даст нам все примеры со словоформой «стекло», где она является глаголом.

Теперь чуть подробнее о значении атрибута POS: в нем содержится частеречная информация, а так же все остальные грамматические признаки, приписываемые той или иной части речи (она примерно соответствует MULTEXT-East Russian).

Система морфотэгов позиционная, это значит, что литералы на разных местах морфотега кодируют разную информацию (см.таблицу).

Например, для существительного (N) будут такие характеристики: тип (нарицательное или собственное), род, число, падеж, одушевленность, доп.падежи

(второй генитив=партитив и второй локатив).

P	Attribute (en)	Value (en)	Code (en)
0	Часть речи	Noun	N
1	Тип	common	c
		proper	p
2	Род	masculine	m
		feminine	f
		neuter	n
		common	c
3	Число	singular	s
		plural	p
4	Падеж	nominative	n
		genitive	g
		dative	d
		accusative	a
		vocative	v
		locative	l
		instrumental	i
5	Одушевленность	no	n
		yes	y
6	Падеж-2	partitive	p
		locative	l

Таблицы кодирования всех частей речи в таблицах см.приложение в конце документа.

Итак, в полной форме запрос будет выглядеть так: [pos="Ncmsgnp"] – мы ищем все существительные нарицательные мужского рода, единственного числа в генитиве, неодушевленные и в форме генитива-2.

Если задавать какие-то из этих характеристик не нужно (а так обычно часто и бывает), на месте ненужных характеристик ставится оператор . (точка).

Запрос [pos="N.m.n."] означает, что мы ищем существительные(N), любого типа (.), мужского рода (m), любого числа (.), именительного падежа (n) и любой одушевленности (.). Значения Падеж-2 тут быть не может.

Если же мы хотим, например, одушевленное существительное, то будет уместен запрос [pos="N....y"] (мы поставили точки на месте всего, что нам неважно).

Последние точки в цепочке типа "N.m.n." можно опускать и писать просто [pos="N.m.n"].

Переменные и дополнительные условия:

Еще одна возможность при задании запроса – операции с условиями равенства/неравенства строк или подстрок из нашего запроса. Для этого мы введем буквенные метки-переменные. Каждая метка присваивается выражению в квадратных скобках: a:[pos="A"] – метка выделена красным.

Рассмотрим запрос:

a:[pos="A"][pos="N"][lemma="такой"]b:[pos="A"] with equal(a.lemma, b.lemma)

В нем мы присваиваем метки (красные) строкам **[pos="A"] (ищет прилагательное),** затем следует существительное (**[pos="N"])**, затем слово, приводимое к лемме «такой» (**[lemma="такой"])**, а затем еще одно прилагательное. Зеленым выделена функция, накладывающее условие равенства лемм прилагательных **a** и **b**. Таким образом, мы получаем результаты типа «Быстрый интернет такой быстрый».

Если метка присутствует на нескольких элементах в запросе, то мы можем явно указать, какая позиция нас интересует (см.номер, выделенный красным):

a:([lemma="купить"][lemma="яблоки"][pos="N"]) with notEqual(a.2.word, a.3.word)

Возможны и другие атрибуты функций, накладывающих условия: **pos** или **lemma.**

Задается так: **метка.индекс.атрибут –** например, чтобы указать на pos второго слова с меткой **a** надо написать: **a.2.pos**

Теперь подробнее о функциях, которыми можно оперировать с метками.

Функции, накладывающие условия:

equal(поле1, поле2) - равенство строк в [поле1] и [поле2]

notEqual(поле1, поле2) - неравенство строк в [поле1] и [поле2]

pref(поле1, поле2, длина) - равенство префиксов заданной длины у строк в [поле1] и [поле2]

suff(поле1, поле2, длина) - равенство суффиксов заданной длины у строк в [поле1] и [поле2]

Отрицание

Чтобы использовать отрицание, нужно ставить круглые скобки вокруг той позиции, которую вы отрицаете. Например: [x1]([x2] - [x2.3])[x4] – показывает все результаты, у которых x1 на первой позиции, x4 на третьей и все разновидности x2, кроме x2.3, на второй.

Если вы не ставите круглые скобки, то вычитается из всего, что стоит слева от минуса:

[word="евро.*"]-[lemma="Европа"] – дает нам все результаты с словами, начинающимися на евро-, но только не "Европа".

Регулярные выражения

На текущий момент можно употреблять 2 оператора – точка и точка-астериск:

. (точка) – пропуск одного символа

.* (точка-астериск) – пропуск сколько угодно символов (от 0 до бесконечности)

Важно! В новых версиях индекса (пока это не /drake) нельзя отделять операторами последовательность из одной буквы.

Примеры (со словом «квантитативный»):

Можно	Нельзя
[word=квантитативны.*]	[word=к..нтитативн.*]
[word=.*анти.*вные]	[word=кван.и.ативн.*]
[word=.*титативн.*]	
[word=...нтит..ивные]	
[word=.вантит...вные]	

Особенности токенизации

1. Знаки препинания считаются отдельными токенами
2. Дефис – в общем случае тоже отдельный токен
3. Части сложных существительных, такие как «фитнес-зал» и «Ростов-На-Дону», не отделяются. Такие неотделимые части заданы списком. Не отделяются также составные части местоимений и местоименных наречий.
4. Остальные слова с дефисом делятся на 3 токена. Например, «пошел-то» - это 3 токена: «пошел», «-» и «то».
5. Числа и латиница пока не индексируются. Получить их вместе с выдачей можно, но искать по ним нельзя.

Примеры на все типы запросов

Запрос:	Результат:
[pos="A...sd."][pos="Np.sd."]	Пары из прилагательного и существительного (собственного) в дательном падеже единственном числе
[pos="A...sd."][]{0,2}[pos="Np.sd."]	То же самое, только на расстоянии от 0 до 2
[word=".*идзе.*" pos="Np"]	Грузинские фамилии на -изде
[word="стекло" pos="N"]	Все примеры со словом «стекло», где оно существительное.
[(word=".*на.*"&word=".*ва.*")]-[word=".*ти.*]	Все слова, в которых есть подстрока "на" и подстрока "ва" и в которых нет подстроки "ти"
[pos="N.m"|pos="N.f"]	все существительные мужского или женского рода
[lemma="дать"]([ALL]-[word="Боже"|word="Бог"])	Все примеры с леммой «дать», кроме тех, в которых после «дать» следует «Боже» или «Бог»
a:([word=".*ни.*"][word=".*на.*"][pos="N"]) with notEqual(a.2.word, a.3.word)	Все словосочетания со словами: первое — с подстрокой «ни», второе – с подстрокой «на», третье – существительное, несовпадающее с формой второго слова.
[lemma=".*кий.*" pos="A"][word="проспект"]	Словосочетания типа «комендантский проспект»
[lemma=".*ица.*" pos="N"]	Все существительные с подстрокой «ица» (плащаница, чечевица...)
[lemma="славься"][word=","]-	Все примеры с первым словом «славься», запятой и не

[word="страна"]	словом «страна» после
[pos="N"][word=","][word="пожалуйста"]	Примеры типа «счет, пожалуйста»
[pos="V"][word="против"][word="воли"]	глагол+против воли
[pos="Np.s"][lemma="и"][pos="N..p"]	Сочетание имени собственного в ед.ч. и существителного во множественном, как «Маша и медведи»
a:([pos="A"] & [pos=".....d"] [pos="N"] & [pos="....d"]) with equal (a.2.pos, a.4.pos)	Прилагательное и существительное в одном падеже ???
[pos="Mc"][]{0,3}[pos="N"][word=","][lemma="который"]	50 художественных книг, которые...
[word="помогите"][]{0,2}[lemma="с"]	Конструкции типа «помогите с выбором»
[lemma="как"][]{0,2}[lemma="здорово"][pos="V"]	Как (же) (ты) здорово пишешь запросы!
a:[pos="A"][pos="N"][lemma="такой"]b:[pos="A"] with equal(a.lemma, b.lemma)	Конструкции типа «быстрый интернет такой быстрый»
[word="я"][word="случайно"][pos="N"]	Интернет-сленг: «Я случайно X»
[word="Нургалиев"][]{0,2}[word="разрешил"]	«Нургалиев» на расстоянии от 0 до 2 от «разрешил»

Приложение – кодировка всех частей речи

Существительное

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Noun	N
1	Type	common	c
		proper	p
2	Gender	masculine	m
		feminine	f
		neuter	n
		common	c
3	Number	singular	s
		plural	p
4	Case	nominative	n
		genitive	g

		dative	d
		accusative	a
		vocative	v
		locative	l
		instrumental	i
5	Animate	no	n
		yes	y
6	Case2	partitive	p
		locative	l

Глагол

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Verb	V
1	Type	main	m
		auxiliary	a
2	VForm	indicative	i
		imperative	m
		conditional	c
		infinitive	n
		gerund	g
3	Tense	present	p
		future	f
		past	s
4	Person	first	1
		second	2
		third	3
5	Number	singular	s
		plural	p
6	Gender	masculine	m
		feminine	f
		neuter	n
7	Voice	active	a
		passive	p
		medial	m
8	Definiteness	-	-
9	Aspect	progressive	p
		perfective	e
		biaspectual	b

Прилагательное

Внимание: все причастия получают метки "прилагательное"! Их леммы не привязаны к глаголу.

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Adjective	A
1	Type	qualificative	f
		possessive	s
2	Degree	positive	p
		comparative	c
		superlative	s
3	Gender	masculine	m
		feminine	f
		neuter	n
4	Number	singular	s
		plural	p
5	Case	nominative	n
		genitive	g
		dative	d
		accusative	a
		locative	l
		instrumental	i
6	Definiteness	short-art	s
		full-art	f

Местоимение

Примечание: по типам местоимения лучше не искать, разметка очень страдает.

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Pronoun	P
1	Type	personal	p
		demonstrative	d
		indefinite	i
		possessive	s
		interrogative	q
		relative	r
		reflexive	x
		negative	z
		nonspecific	n
2	Person	first	1
		second	2

		third	3
3	Gender	masculine	m
		feminine	f
		neuter	n
4	Number	singular	s
		plural	p
5	Case	nominative	n
		genitive	g
		dative	d
		accusative	a
		vocative	v
		locative	l
		instrumental	i
6	Syntactic_Type	nominal	n
		adjectival	a
		adverbial	r
7	Animate	no	n
		yes	y

Наречие

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Adverb	R
1	Degree	positive	p
		comparative	c
		superlative	s

Предлог

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Adposition	S
1	Type	preposition	p
2	Formation	simple	s
		compound	c
3	Case	genitive	g
		dative	d
		accusative	a
		locative	l
		instrumental	i

Союз

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Conjunction	C

Числительное

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Numeral	M
1	Type	cardinal	c
		ordinal	o
		multiple	m
		collect	l
2	Gender	masculine	m
		feminine	f
		neuter	n
3	Number	singular	s
		plural	p
4	Case	nominative	n
		genitive	g
		dative	d
		accusative	a
		locative	l
		instrumental	i
5	Form	digit	d
		roman	r
		letter	l
9	Animate	no	n
		yes	y

Частица

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Particle	Q

Междометие

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Interjection	I

Аббревиатура

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Abbreviatio n	Y
1	Syntactic_Type	nominal	n
		adverbial	r
2	Gender	masculine	m
		feminine	f
		neuter	n
3	Number	singular	s
		plural	p
		paucal	c
4	Case	nominative	n
		genitive	g
		dative	d
		accusative	a
		locative	l
		instrumental	i

Предикатив

P	Attribute (en)	Value (en)	Code (en)
0	CATEGORY	Verbal adverb	Rv